Escuela Politécnica Superior

Clasificación de cáncer gástrico en imágenes histopatológicas mediante aprendizaje profundo



Máster Universitario en Ciencia de Datos

Trabajo Fin de Máster

Autor/a:
Lucila Vázquez Soriano
Tutor/es:
Manuel Curado Navarro
José F. Vicent

Septiembre 2026



Universitat d'Alacant
Universidad de Alicante

Clasificación de cáncer gástrico en imágenes histopatológicas mediante aprendizaje profundo

Autor/a
Lucila Vázquez Soriano

Tutor/es
Manuel Curado Navarro
José F. Vicent



Máster Universitario en Ciencia de Datos



Escuela
Politécnica
Superior



Universitat d'Alacant
Universidad de Alicante

ALICANTE, septiembre 2026

Abstract

Gastric cancer is among the cancers with the highest incidence and mortality worldwide. Its diagnosis relies on the histopathological examination of tissue samples, a manual and time-consuming task that is subject to inter-observer variability. This Master's thesis addresses the binary classification (*Normal*/*Abnormal*) of haematoxylin and eosin (H&E) stained gastric histopathology patches from the public GasHisSDB dataset, which contains 245,196 images split into three collections of 80, 120 and 160-pixel patches.

The baseline configuration uses an ImageNet-pretrained EfficientNetV2-B0 with frozen weights as the feature extractor and CatBoost as the classifier. Hyperparameters are selected through stratified five-fold cross-validation on 80 % of the data, class imbalance is handled with class weights, and every experiment is repeated with five random seeds. Two modifications are evaluated separately on top of this baseline: data augmentation based on patch rotations and reflections, and the insertion of a CBAM attention module between the extractor and global average pooling. In addition, transfer across patch sizes is analysed, and predictions are explored through CBAM attention maps and spatial projections of SHAP values.

The baseline achieves a mean accuracy of 89.64 %, 92.24 % and 93.24 % on the 80, 120 and 160-pixel patches, respectively. Data augmentation improves it by about one percentage point for all three sizes and in all five seeds, whereas CBAM yields the best results (91.80 %, 93.46 % and 94.70 %), with the largest gain on 80-pixel patches. Transfer across patch sizes is strongly asymmetric: training on 80-pixel patches and testing on 160-pixel patches retains 85.28 % accuracy, compared with 67.38 % in the opposite direction. The spatial attention maps show weights close to saturation and provide little evidence of region-specific selection. SHAP projections allow correct and incorrect predictions of both models to be examined, but they do not link the decisions to specific histological structures. Since patches cannot be grouped by origin, the reported metrics may be optimistic with respect to performance on unseen patients.

Resumen

El cáncer gástrico se encuentra entre los tumores con mayor incidencia y mortalidad a escala mundial. Su diagnóstico se apoya en el examen histopatológico de muestras de tejido, una tarea manual, costosa en tiempo y sujeta a variabilidad entre especialistas. En este trabajo se estudia la clasificación binaria entre las clases *Normal* y *Abnormal* de parches histopatológicos gástricos del conjunto público GasHisSDB, que contiene 245.196 imágenes distribuidas en tres colecciones de parches de 80, 120 y 160 píxeles de lado.

Como configuración de referencia se emplea EfficientNetV2-B0, preentrenado en ImageNet y con los pesos congelados, como extractor de características, y CatBoost como clasificador. Los hiperparámetros se seleccionan mediante validación cruzada estratificada de cinco pliegues sobre el 80 % de los datos, el desbalance se compensa con pesos de clase y cada experimento se repite con cinco semillas. Sobre esta base se evalúan por separado dos modificaciones: un aumento de datos de los parches y la incorporación del módulo de atención CBAM entre el extractor y la agrupación global promedio. Además, se analiza la transferencia entre tamaños de parche y se exploran las predicciones mediante los mapas de atención de CBAM y proyecciones espaciales de valores SHAP.

Finalmente, dentro del protocolo evaluado la configuración de referencia alcanza un *accuracy* medio del 89,64 %, 92,24 % y 93,24 % para los parches de 80, 120 y 160 píxeles, respectivamente. El aumento de datos la mejora en torno a un punto porcentual en los tres tamaños y en las cinco semillas, mientras que CBAM obtiene los mejores resultados del proyecto (91,80 %, 93,46 % y 94,70 %). La transferencia entre tamaños resulta marcadamente asimétrica: entrenar con parches de 80 píxeles y evaluar con los de 160 conserva un accuracy del 85,28 %, frente al 67,38 % en la dirección inversa. Los mapas de atención espacial presentan pesos próximos a la saturación y aportan poca evidencia de una selección de regiones concretas. Las proyecciones SHAP permiten examinar aciertos y errores de ambos modelos, pero no asocian sus decisiones a estructuras histológicas concretas. Dado que los parches no pueden agruparse por su origen, las métricas obtenidas podrían resultar optimistas respecto al rendimiento sobre pacientes no vistos.

Agradecimientos

Me gustaría expresar mi gratitud a mis tutores, Manuel Curado Navarro y José F. Vicent, por su orientación a lo largo de este trabajo, por su disponibilidad y por sus palabras de apoyo.

Asimismo, agradezco a mis amigos, especialmente al de las noches largas, al crítico constructivo y al que siempre está, por todas sus distintas formas de motivarme a completar este proyecto. Agradezco también a mi familia por su apoyo incondicional este último año. Por último, agradecer a mi pareja, el que siempre estuvo ahí y el que nunca ha dejado de creer en mí, más incluso que yo misma. Sin ninguno de ellos habría llegado tan lejos como hoy.

Índice general

Lista de Acrónimos y Abreviaturas xvii

1. Introducción 1
1.1. Cáncer gástrico . . . 1
1.2. Planteamiento del problema . . . 3
1.3. Objetivos . . . 4
1.3.1. Objetivos específicos . . . 4

2. Estado del arte 7
2.1. Clasificación de imágenes y aprendizaje por transferencia . . . 7
2.1.1. Redes neuronales convolucionales . . . 7
2.1.2. Modelos preentrenados y extractores de características . . . 9
2.1.3. Aplicación a imágenes histopatológicas . . . 11
2.2. EfficientNetV2 y CatBoost . . . 13
2.2.1. De EfficientNet a EfficientNetV2 . . . 13
2.2.2. EfficientNetV2-B0 como extractor . . . 13
2.2.3. CatBoost . . . 14
2.2.4. Justificación de la combinación . . . 16
2.3. Evaluación de modelos con datos desbalanceados . . . 16
2.3.1. Desbalance de clases y elección de métricas . . . 16
2.3.2. Validación cruzada y selección de hiperparámetros . . . 17
2.3.3. Múltiples semillas y variabilidad . . . 17
2.3.4. Prevención de fugas de información . . . 18
2.4. Aumento de datos, atención e interpretabilidad . . . 19
2.4.1. Aumento de datos en histopatología . . . 19
2.4.2. Mecanismos de atención y CBAM . . . 20
2.4.3. Interpretabilidad de las representaciones y del clasificador . . . 21

3. Metodología 23
3.1. Entorno experimental y organización del proyecto . . . 23
3.1.1. Hardware . . . 23
3.1.2. Software . . . 24
3.1.3. Organización del repositorio . . . 26
3.1.4. Contenedor Docker . . . 27
3.2. Conjunto de datos y Análisis exploratorio de datos . . . 27
3.2.1. Conjunto de datos, GasHisSDB . . . 27
3.2.2. Análisis exploratorio de datos . . . 28

3.2.3. Inventario y dependencia entre imágenes . . . 30
3.3. *Pipeline* del trabajo . . . 31
3.4. Preprocesamiento y extracción de características . . . 32
3.4.1. Preprocesamiento de las imágenes . . . 32
3.4.2. Extracción y almacenamiento de características . . . 33
3.5. Clasificación y diseño experimental . . . 34
3.5.1. Separación de entrenamiento y prueba . . . 34
3.5.2. Validación cruzada y búsqueda de hiperparámetros . . . 35
3.5.3. Compensación del desbalance de clases . . . 36
3.5.4. Control de la aleatoriedad y reproducibilidad . . . 37
3.6. Experimentos realizados . . . 38
3.6.1. Configuración de referencia . . . 39
3.6.2. Aumento de datos . . . 40
3.6.3. Incorporación del módulo de atención CBAM . . . 43
3.6.4. Robustez ante cambio de escala . . . 49
3.6.5. Análisis de interpretabilidad . . . 50
3.7. Evaluación . . . 54
3.7.1. Métricas . . . 54

4. Resultados **57**
4.1. Resultados del análisis exploratorio . . . 57
4.1.1. Aspecto de los parches . . . 58
4.1.2. Estadísticos de intensidad . . . 59
4.1.3. Diferencias cromáticas entre clases . . . 60
4.1.4. Similitud perceptual y duplicados . . . 61
4.1.5. Recuperación de la procedencia de los parches . . . 63
4.2. Resultados de clasificación de la configuración de referencia . . . 64
4.2.1. Variabilidad y selección de hiperparámetros . . . 65
4.3. Resultados del experimento de aumento de datos . . . 66
4.3.1. Comparación con la configuración de referencia . . . 66
4.3.2. Consistencia de las mejoras . . . 67
4.4. Resultados del experimento CBAM . . . 67
4.4.1. Comparación con experimentos previos . . . 68
4.5. Resultados de la evaluación entre tamaños . . . 69
4.6. Resultados de la interpretabilidad . . . 69
4.6.1. Mapas de CBAM sobre parches de tejido . . . 70
4.6.2. Mapas del análisis de las predicciones mediante SHAP . . . 72
4.6.3. Selección estratificada de ejemplos . . . 77
4.6.3.1. Aciertos con alta confianza . . . 79
4.6.3.2. Aciertos con baja confianza . . . 81
4.6.3.3. Falsos positivos . . . 81
4.6.3.4. Falsos negativos . . . 82
4.7. Matrices de confusión . . . 84

4.8. Comparación completa de resultados 86

5. Discusión **91**
5.1. Interpretación de los resultados 91
5.1.1. Efecto del tamaño del parche 91
5.1.2. Efecto del aumento de datos 92
5.1.3. Efecto de incorporar CBAM 93
5.1.4. Interpretación de los mapas de atención y SHAP 94
5.1.5. Generalización entre tamaños de parche 97
5.2. Comparación con los trabajos previos 97
5.2.1. Respecto a la configuración arquitectónica 98
5.2.2. Relación con el trabajo que motivó la incorporación de atención . 99
5.2.3. Sobre el coste computacional 100
5.3. Limitaciones del estudio 101
5.3.1. Limitaciones de los datos 101
5.3.2. Limitaciones metodológicas 102
5.3.3. Limitaciones de interpretabilidad 103
5.4. Aportaciones del trabajo 103

6. Conclusiones y trabajo futuro **105**
6.1. Conclusiones principales 105
6.2. Trabajo futuro 107

Bibliografía **111**

A. Guía de reproducibilidad **115**
A.1. Repositorio y documentación del entorno 115
A.2. Secuencia general de ejecución 115

B. Resultados detallados por semilla **117**
B.1. Métricas de clasificación 117
B.2. Matrices de confusión por ejecución 119
B.3. Hiperparámetros seleccionados 120

C. Resultados de transferencia entre tamaños de parche **123**

Índice de figuras

2.1. Estructura de una red convolucional formada por capas convolucionales, de agrupación y completamente conectadas. Fuente: Albelwi y Mahmood [1] 9
2.2. Comparación entre la extracción de características con pesos congelados y el ajuste fino de una red preentrenada en ImageNet. Las capas congeladas se muestran en amarillo y las entrenables, en azul. Fuente: Gonçalves e Gonçalves et al. [2] 10
2.3. Ejemplos de parches de GasHisSDB de las clases `Normal` y `Abnormal` en los tres tamaños disponibles. Cada parche se representa con una anchura proporcional a su tamaño en píxeles. Fuente: elaboración propia a partir de GasHisSDB [3]. 12
2.4. Proceso iterativo de construcción progresiva de árboles de decisión en CatBoost mediante *gradient boosting*. Fuente: elaboración propia 15
2.5. Validación cruzada estratificada de cinco pliegues aplicada sobre el conjunto de entrenamiento. En cada ronda, un pliegue se utiliza para validar y los cuatro restantes para ajustar el clasificador. El conjunto de prueba se reserva para la evaluación final. Fuente: elaboración propia 18

3.1. Arquitectura general de clasificación y variantes estudiadas. El bloque y la ruta verde discontinua representan el aumento de datos, aplicado solo durante el entrenamiento. La ruta discontinua *Sin CBAM* corresponde a la configuración de referencia y la ruta continua a través de CBAM, a la variante con módulo de atención. 31
3.2. Las ocho transformaciones empleadas sobre los parches 41

4.1. Distribución de las imágenes de GasHisSDB por resolución y clase. 58
4.2. Ejemplos aleatorios de parches de 160 píxeles para cada clase 59
4.3. Distribución de la intensidad media por imagen en los canales RGB, desglosada por clase y resolución de parche. 60
4.4. Mapas de atención espacial de CBAM sobre parches de 80 píxeles: `Abnormal` izquierda y `Normal` derecha. 70
4.5. Mapas de atención espacial de CBAM sobre parches de 120 píxeles: `Abnormal` izquierda y `Normal` derecha. 70
4.6. Mapas de atención espacial de CBAM sobre parches de 160 píxeles: `Abnormal` izquierda y `Normal` derecha. 71
4.7. Escalas de color de las proyecciones espaciales 72
4.8. SHAP-CAM del parche `Normal` 0 de 80 píxeles 74
4.9. SHAP-CAM del parche `Normal` 1 de 80 píxeles 74

4.10. Falso positivo `Normal` 2 de 80 píxeles 75
4.11. SHAP-CAM de los parches `Abnormal` de 80 píxeles 75
4.12. SHAP-CAM del parche `Normal` 0 de 120 píxeles 76
4.13. SHAP-CAM de los parches `Normal` 1 y 2 de 120 píxeles 76
4.14. SHAP-CAM del parche `Abnormal` 1 de 120 píxeles 77
4.15. SHAP-CAM de los parches `Normal` de 160 píxeles 78
4.16. Escalas de color de la selección estratificada 79
4.17. Aciertos con alta confianza en parches de 160 píxeles 80
4.18. Aciertos con baja confianza en parches de 160 píxeles 81
4.19. Falsos positivos en parches de 160 píxeles 82
4.20. Falsos negativos en parches de 160 píxeles 83
4.21. Matrices de confusión medias para parches de 80 píxeles. De izquierda a derecha: referencia, aumento de datos y CBAM. Los valores son promedios de cinco semillas. 85
4.22. Matrices de confusión medias para parches de 120 píxeles. De izquierda a derecha: referencia, aumento de datos y CBAM. Los valores son promedios de cinco semillas. 85
4.23. Matrices de confusión medias para parches de 160 píxeles. De izquierda a derecha: referencia, aumento de datos y CBAM. Los valores son promedios de cinco semillas. 86
4.24. Matrices de confusión normalizadas. De arriba abajo: configuración de referencia, aumento de datos y CBAM. En cada fila, de izquierda a derecha: parches de 80, 120 y 160 píxeles. 87
4.25. Comparación del *accuracy*, la sensibilidad y la especificidad entre la configuración de referencia, el aumento de datos y CBAM para los tres tamaños de parche. Se muestran las medias de cinco semillas, expresadas en porcentaje. 89

Índice de tablas

3.1. Especificaciones del ordenador utilizado en los experimentos. 24
3.2. Herramientas y bibliotecas empleadas, versiones y funciones en el trabajo. 25
3.3. Distribución de las imágenes de GasHisSDB por resolución y clase. 28
3.4. Tamaño de las particiones de entrenamiento y prueba en cada resolución. Entre paréntesis, el número de imágenes de la clase `Abnormal`. 34

4.1. Media y desviación típica de las intensidades de los píxeles por canal RGB. 59
4.2. Media y desviación típica de las intensidades medias por imagen en cada canal RGB, desglosadas por clase y tamaño de parche. Intensidades reescaladas al intervalo $[0, 1]$, calculadas sobre una muestra estratificada de 5.000 imágenes por tamaño. 60
4.3. Similitud perceptual 62
4.4. Duplicados exactos identificados en la totalidad de las imágenes de los datos disponibles. Las copias adicionales se calculan conservando conceptualmente una imagen por grupo. 63
4.5. Resultados de la configuración de referencia por tamaño de parche. Media ± desviación típica de las cinco ejecuciones 64
4.6. Resultados del experimento de aumento de datos por tamaño de parche. . 66
4.7. Mejora del aumento de datos respecto a la configuración de referencia. . . 67
4.8. Resultados del experimento CBAM por tamaño de parche. 68
4.9. *Accuracy* entre tamaños de parche. 69
4.10. Probabilidad estimada de pertenencia a la clase `Abnormal` para los ejemplos visualizados. 73
4.11. Comparación conjunta de resultados. Se presenta la media ± desviación típica de cinco semillas, con todas las métricas expresadas en escala de 0 a 100. La precisión, la sensibilidad y F1 de `Abnormal` se calculan considerando esta clase como positiva. 88

B.1. Métricas de clasificación por configuración, tamaño de parche y semilla. . 117
B.2. Recuentos de las matrices de confusión por configuración, tamaño de parche y semilla. 119
B.3. Hiperparámetros seleccionados de CatBoost por configuración, tamaño de parche y semilla. 120

C.1. Resultados de transferencia entre tamaños de parche por semilla. 123

Lista de Acrónimos y Abreviaturas

CBAM Convolutional Block Attention Module.

CNN Convolutional Neural Networks.

RGB Red, Green, Blue.

WSI Whole Slide Image.

OMS Organización Mundial de la Salud.

SEOM Sociedad Española de Oncología Médica.

GLOBOCAN Global Cancer Observatory de la World Health Organization.

REDECAN Red Española de Registros de Cáncer.

SEER Surveillance, Epidemiology, and End Results.

H&E Hematoxilina y eosina.

SHAP SHapley Additive exPlanations.

CSV Comma-Separated Values.

PNG Portable Network Graphics.

BGR Blue, Green, Red.

GAP Global Average Pooling.

AUC Area Under the Curve.

FN False Negatives.

FP False Positives.

TN True Negatives.

TP True Positives.

MLP Multilayer Perceptron.

ReLU Rectified Linear Unit.

ROC Receiver Operating Characteristic.

EDA Exploratory Data Analysis.

D. T. Desviación Típica.

1. Introducción

El cáncer es una de las enfermedades más letales a nivel mundial. En un paciente con cáncer, algunas células de su cuerpo crecen y se dividen de forma descontrolada, pudiendo invadir tejidos cercanos y expandirse a otras zonas del cuerpo. Debido a su alta incidencia y elevada tasa de mortalidad, se trata de uno de los principales problemas de salud a escala global. Según la OMS (Organización Mundial de la Salud), en el año 2020 fue la causa de cerca de 10 millones de fallecimientos, lo que equivale aproximadamente a una de cada seis muertes. Tan solo en España, el informe *Las cifras del cáncer en España 2025*, publicado por la Sociedad Española de Oncología Médica (SEOM), recogía una estimación de 296.103 nuevos casos de cáncer para 2025, elaborada por la Red Española de Registros de Cáncer (REDECAN). Esta estimación excluye los tumores cutáneos no melanoma. Asimismo, el informe recoge una proyección que sitúa el número de nuevos casos anuales por encima de los 350.000 en 2050 [4].

La detección temprana de esta enfermedad es crucial para aumentar las posibilidades de que su tratamiento sea exitoso. Retrasar el diagnóstico reduce las posibilidades de supervivencia del paciente, mientras que un diagnóstico a tiempo mejora los resultados, ya que permite intervenir en las fases iniciales de la enfermedad, cuando los tratamientos son más efectivos, menos complejos e incluso menos costosos, lo que supone una menor carga para los sistemas sanitarios.

1.1. Cáncer gástrico

Entre los diferentes tipos de cáncer se encuentra el que se aborda en este proyecto: el cáncer gástrico, comúnmente conocido como cáncer de estómago. Según datos de GLOBOCAN (Global Cancer Observatory de la World Health Organization), en 2022 el cáncer de estómago fue el quinto con mayor incidencia, con más de 950.000 casos nuevos. También fue la quinta causa de muerte por cáncer, con 660.175 defunciones durante ese mismo año. Estos datos ponen de manifiesto que el cáncer gástrico constituye un problema de salud a escala global.

Los proyectos de diagnóstico del cáncer son importantes no solo por la frecuencia de la enfermedad, sino también por las consecuencias de su detección tardía. Cuando este tipo de cáncer se diagnostica en etapas tempranas, aumentan las posibilidades de recuperación. Sin embargo, en la actualidad el cáncer gástrico suele diagnosticarse en fases avanzadas. Según los registros estadounidenses del programa Surveillance, Epidemiology, and End Results (SEER), la supervivencia relativa a cinco años fue del 78,1 % para el cáncer gástrico localizado, es decir, cuando la detección se produce antes de que el cáncer se expanda fuera del órgano. Del 39,0 % para la enfermedad regional, cuando el cáncer, a pesar de haberse extendido fuera del estómago, solo alcanza órganos cercanos. Y del 8,1 % cuando existían metástasis a distancia, cuando el cáncer se ha extendido más allá del estómago hacia partes lejanas del cuerpo. Estas estimaciones corresponden a personas diagnosticadas entre 2016 y 2022 e incluyen ambos sexos y todos los grupos raciales de los registros SEER 21, excluido Illinois [5].

El estudio histopatológico de muestras de tejido se utiliza para diagnosticar el cáncer gástrico y se considera una fuente de información crucial en la medicina moderna. La obtención de estas muestras puede realizarse mediante una biopsia durante una endoscopia digestiva alta, que permite visualizar el interior del esófago, el estómago y el duodeno. Posteriormente, un patólogo examina la muestra al microscopio para identificar posibles signos de cáncer [6]. Sin embargo, el proceso de identificación continúa siendo manual, consume tiempo del personal médico y depende en gran medida de la interpretación del especialista. Se ha observado que, ante unas mismas pruebas, los profesionales no siempre alcanzan la misma conclusión diagnóstica. Además, existen situaciones en las que resulta más complicado llegar a una conclusión clara, por ejemplo, cuando la muestra de tejido es muy pequeña. Todo ello motiva el desarrollo de herramientas automáticas de apoyo al diagnóstico y es en este contexto donde el presente trabajo adquiere valor.

La inteligencia artificial ha mostrado un gran potencial para mejorar la precisión y la eficiencia en la detección y el diagnóstico de enfermedades, incluido el cáncer. Recientemente, los métodos de aprendizaje profundo y las redes neuronales convolucionales han demostrado ser muy útiles para reconocer patrones complejos en imágenes médicas y asistir al especialista en tareas de clasificación y diagnóstico. En el ámbito de la patología gástrica, diferentes investigaciones sostienen que la inteligencia artificial puede mejorar la rapidez y la precisión del análisis histológico.

En este proyecto se trabaja con el conjunto de datos GasHisSDB, que resulta especialmente útil porque contiene casi un cuarto de millón de parches de imágenes histopatológicas de tejido gástrico, previamente clasificados como normales o anómalos y disponibles en tres tamaños diferentes: 80×80, 120×120 y 160×160 píxeles. Al ser de acceso público, permite reproducir y comparar los resultados con los de trabajos previos, que se analizarán con mayor profundidad en el estado del arte.

Por tanto, este proyecto busca explorar los campos de la visión por computador, el aprendizaje profundo y la patología digital con el fin de estudiar la clasificación binaria de imágenes histopatológicas de tejido gástrico.

1.2. Planteamiento del problema

La tarea abordada es un problema de clasificación binaria supervisada sobre imágenes: dada una imagen de un parche de tejido gástrico teñido con H&E, el sistema debe asignarla a una de dos categorías, *normal* (tejido sin evidencia de malignidad) o *anómalo* (*abnormal*, tejido con presencia de cáncer gástrico). No se aborda, por tanto, ni la clasificación en subtipos tumorales ni la segmentación o localización de la lesión dentro del parche, tareas que quedan fuera del alcance de este trabajo.

El conjunto de datos empleado, GasHisSDB, presenta ciertas particularidades que condicionan de forma directa el diseño experimental y que conviene enunciar desde el principio.

1. **Múltiples tamaños de parche.** El conjunto se distribuye en tres subconjuntos de datos correspondientes a tamaños de parche de 80×80, 120×120 y 160×160 píxeles. Cada una de ellas contiene sus propias carpetas de imágenes normales y anómalas.

2. **Desbalance de clases moderado.** En las tres resoluciones, el número de imágenes de la clase normal supera al de la clase anómala, en una proporción aproximada de 60/40. Este desbalance, sin ser extremo, resulta suficiente para desaconsejar el uso del *accuracy* global como métrica única y para recomendar algún mecanismo de compensación durante el entrenamiento.

3. **Origen común de las tres resoluciones.** Los tres subconjuntos no constituyen conjuntos de imágenes independientes entre sí, sino que proceden de la misma colección de imágenes de tejido, recortada a tres escalas distintas. En consecuencia,

combinarlas en un mismo experimento supondría introducir observaciones redundantes bajo la apariencia de un aumento del tamaño muestral.

1.3. Objetivos

El objetivo principal de este proyecto es desarrollar y evaluar un sistema de clasificación binaria de parches histopatológicos gástricos de GasHisSDB basado en la combinación de un extractor de características convolucional preentrenado con un clasificador de *gradient boosting*. Además, se investigan mediante experimentos controlados posibles vías de mejora, la capacidad de generalización del sistema entre distintos tamaños de parche y la interpretabilidad de sus predicciones.

1.3.1. Objetivos específicos

1. **Estudiar la problemática** del cáncer gástrico en la sociedad actual, su impacto y su relevancia en el contexto de la detección y el diagnóstico tempranos. Revisar el estado del arte del análisis histopatológico y de la clasificación automática de imágenes gástricas mediante herramientas de inteligencia artificial.

2. **Analizar en profundidad el conjunto de datos empleado**. Estudiar la distribución de clases, los tamaños de parche, la integridad de las imágenes y las implicaciones de utilizar imágenes recortadas, o parches, obtenidas a partir de imágenes originales de mayor tamaño.

3. **Diseñar, implementar y evaluar una configuración de referencia.** Construir un sistema basado en EfficientNetV2-B0 preentrenado y congelado y un clasificador CatBoost. Definir el preprocesamiento, el tratamiento del desbalance y la evaluación con validación cruzada para la selección de hiperparámetros y múltiples semillas, documentando el entorno y las configuraciones para facilitar su reproducción.

4. **Evaluar el efecto del aumento de datos.** Incorporar transformaciones de aumento de datos durante el entrenamiento y comparar su efecto sobre el rendimiento respecto a la configuración de referencia, utilizando las mismas particiones de prueba.

5. **Evaluar CBAM como mecanismo de adaptación de las características.** Diseñar y evaluar un experimento de incorporación de un mecanismo de atención convolucional y estudiar su efecto sobre la clasificación.

6. **Estudiar el comportamiento entre tamaños de parche.** Analizar las diferencias de rendimiento entre las colecciones de 80, 120 y 160 píxeles y evaluar la transferencia al entrenar con parches de un tamaño y utilizar el clasificador sobre parches de otro.

7. **Explorar la interpretabilidad de las predicciones.** Examinar los mapas de atención espacial de CBAM y las contribuciones SHAP del clasificador, proyectadas sobre los parches, para analizar qué información utiliza el sistema en sus aciertos y en sus errores.

8. **Analizar de forma objetiva y crítica los resultados obtenidos**, identificando sus posibles limitaciones y las mejoras que podrían abordarse en trabajos futuros.

2. Estado del arte

Este capítulo revisa los conceptos y trabajos relacionados con la clasificación de imágenes histopatológicas mediante aprendizaje profundo. En primer lugar, en la sección 2.1, se explica cómo las redes convolucionales permiten obtener representaciones de las imágenes y cómo estas pueden aprovecharse mediante aprendizaje por transferencia. A continuación, en la sección 2.2, se presentan EfficientNetV2 y CatBoost, los dos componentes principales de la configuración de referencia. Después, en la sección 2.3, se abordan las dificultades que plantea la evaluación cuando las clases tienen tamaños diferentes o existen relaciones entre las imágenes. Por último, en la sección 2.4, se introducen el aumento de datos, los mecanismos de atención y las técnicas de interpretabilidad que fundamentan los experimentos complementarios del trabajo.

2.1. Clasificación de imágenes y aprendizaje por transferencia

2.1.1. Redes neuronales convolucionales

La clasificación de imágenes consiste en asignar una categoría a una imagen a partir de su contenido. En el aprendizaje supervisado, esta tarea se aprende utilizando ejemplos acompañados de una etiqueta. El objetivo es que el modelo identifique patrones que le permitan clasificar imágenes diferentes de las utilizadas durante su entrenamiento.

Las redes neuronales convolucionales, conocidas por las siglas CNN (*Convolutional Neural Networks*), son arquitecturas diseñadas para aprovechar la organización espacial de datos como las imágenes. Una de sus características principales es que procesan regiones locales y comparten parámetros entre distintas posiciones. Los trabajos de LeCun *et al.* mostraron la utilidad de este planteamiento en el reconocimiento de documentos y caracteres [7].

Para comprender su funcionamiento, puede considerarse un filtro que recorre una imagen y combina los valores de pequeños grupos de píxeles. La respuesta obtenida en cada posición forma un mapa de características. Durante el entrenamiento se aprenden los

coeficientes de estos filtros, de manera que sus respuestas resulten útiles para resolver la clasificación. El mismo filtro se aplica en diferentes posiciones, lo que permite buscar un patrón sin definir parámetros distintos para cada zona de la imagen [7].

Esta estructura introduce una diferencia respecto a una capa completamente conectada aplicada directamente a todos los píxeles. En esta última, la relación de proximidad entre píxeles no queda incorporada explícitamente en las conexiones. Las convoluciones, en cambio, aprovechan esa relación y permiten construir representaciones a partir de regiones pequeñas [8].

Las capas convolucionales se combinan con funciones de activación y otras operaciones que transforman las características obtenidas. Al utilizar varias capas una detrás de otra, la red puede aprender características cada vez más complejas. Las primeras capas pueden detectar elementos sencillos, como bordes o cambios de intensidad, mientras que las capas posteriores pueden combinar estas características para representar estructuras más complejas. De esta forma, la red aprende automáticamente qué características son útiles para clasificar las imágenes, sin necesidad de definirlas manualmente [8].

En la Figura 2.1 se representa la estructura de una red convolucional sencilla. La imagen de entrada atraviesa una primera capa convolucional, cuyos filtros generan un conjunto de mapas de características. A continuación, una capa de agrupación, o *pooling*, reduce su tamaño espacial resumiendo los valores de regiones próximas. Este par de operaciones se repite, de modo que las capas más profundas operan sobre representaciones de menor tamaño espacial. Finalmente, las capas completamente conectadas combinan las características obtenidas para estimar la probabilidad de cada clase y dada la imagen de entrada x, representada como $p(y \mid x)$.

Como se observa en la figura, las capas convolucionales y de agrupación transforman la imagen en una representación numérica, mientras que las capas completamente conectadas se encargan de la clasificación. Esta separación resulta relevante para el proyecto ya que el sistema desarrollado conserva la parte de extracción de una red preentrenada y sustituye su etapa final por un clasificador independiente.

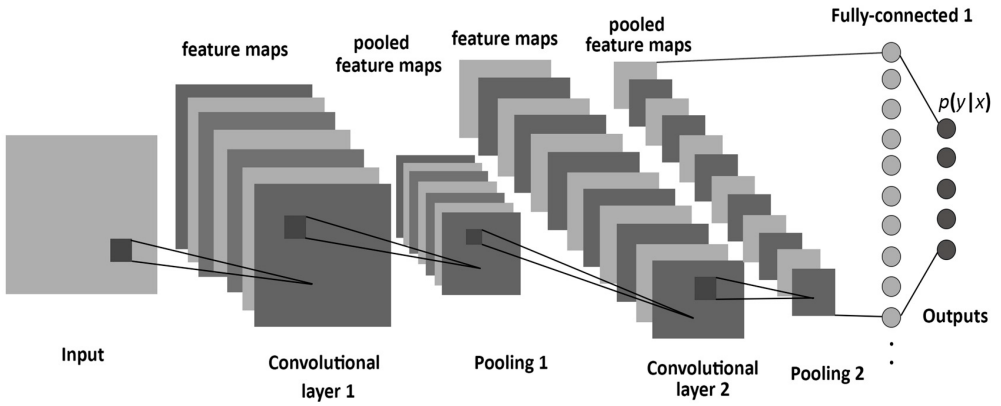


Figura 2.1.: Estructura de una red convolucional formada por capas convolucionales, de agrupación y completamente conectadas. Fuente: Albelwi y Mahmood [1]

2.1.2. Modelos preentrenados y extractores de características

Entrenar una red desde cero implica aprender sus parámetros utilizando los datos disponibles para la tarea. Una alternativa es partir de un modelo que ya ha sido entrenado y aprovechar parte de las representaciones que ha aprendido. Esta estrategia recibe el nombre de aprendizaje por transferencia, o *transfer learning*.

ImageNet constituye uno de los conjuntos de datos de referencia para el aprendizaje de representaciones visuales. Contiene imágenes organizadas en categorías y ha servido como base para el desarrollo de una gran cantidad de modelos de clasificación [9]. Aunque sus imágenes no corresponden específicamente a tejido histológico, algunas características aprendidas pueden resultar útiles en otras tareas.

La transferencia no afecta por igual a todas las capas. los autores observaron que las primeras capas de una red pueden aprender características relativamente generales, mientras que las representaciones posteriores tienden a especializarse en la tarea original. También mostraron que la utilidad de la transferencia depende de la relación entre la tarea de origen y la de destino [10].

Existen dos formas habituales de aprovechar un modelo preentrenado:

- **Extracción de características con pesos congelados.** Se conserva la parte de la red que transforma la imagen en una representación numérica y se mantienen fijos sus parámetros. Sobre esa representación se entrena un nuevo clasificador.

- ***Fine-tuning.*** Se actualiza una parte o la totalidad de los parámetros de la red utilizando los datos de la nueva tarea. Este procedimiento, denominado *fine-tuning*, permite adaptar las representaciones, aunque incorpora más parámetros al proceso de aprendizaje.

La Figura 2.2 ilustra ambas estrategias aplicadas a imágenes histopatológicas gástricas. A la izquierda se representa la preparación de los datos, en la que una imagen de mayor tamaño se divide en parches que se filtran antes de introducirse en la red. A la derecha, las capas representadas en amarillo conservan los pesos obtenidos durante el preentrenamiento en ImageNet, mientras que las representadas en azul se actualizan con los nuevos datos. En la extracción de características únicamente se entrena la capa de clasificación añadida, mientras que en el ajuste fino también se actualizan los últimos bloques convolucionales.

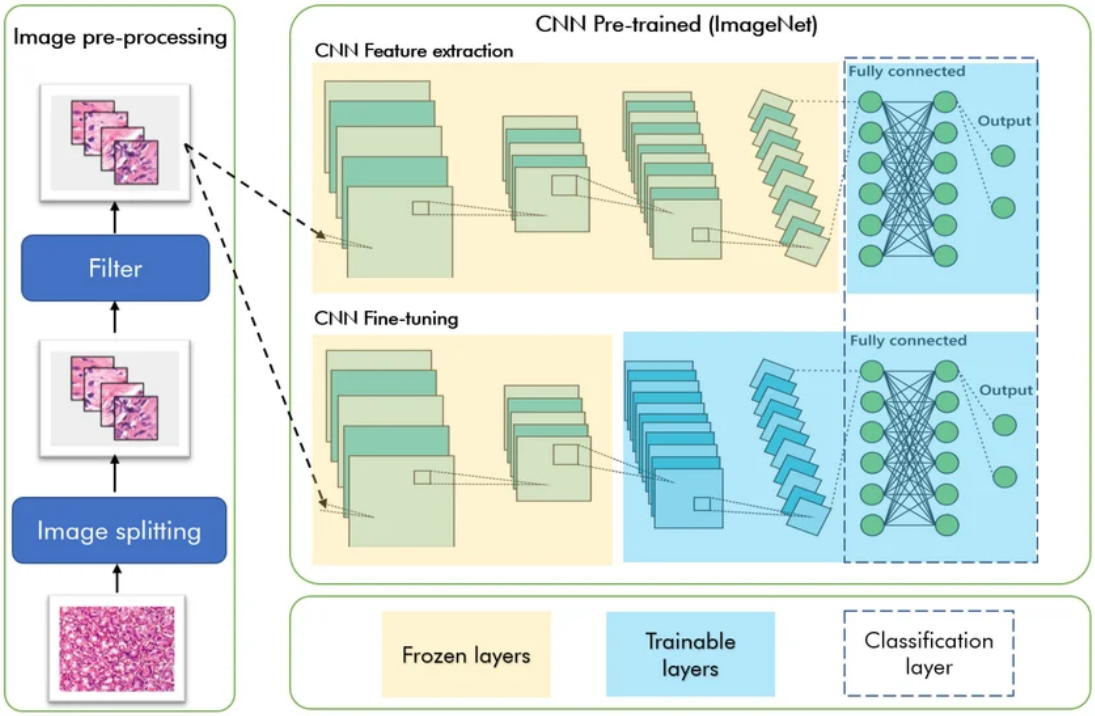


Figura 2.2.: Comparación entre la extracción de características con pesos congelados y el ajuste fino de una red preentrenada en ImageNet. Las capas congeladas se muestran en amarillo y las entrenables, en azul. Fuente: Gonçalves e Gonçalves et al. [2]

La primera opción, representada en la parte superior de la figura, separa el aprendizaje

del clasificador de la extracción de características. El sistema desarrollado en este trabajo sigue esta estrategia, aunque la capa de clasificación no forma parte de la red: se sustituye por CatBoost, que recibe las representaciones obtenidas por EfficientNetV2-B0. Esta separación permite estudiar distintas configuraciones del clasificador sin repetir la extracción.

2.1.3. Aplicación a imágenes histopatológicas

Una imagen histopatológica es la representación digital de una muestra de tejido preparada para su observación al microscopio. La muestra, obtenida habitualmente mediante biopsia, se fija y se corta en secciones muy finas que se montan sobre un portaobjetos. Para que las estructuras celulares resulten visibles, estas secciones se tiñen. La tinción más utilizada, la de hematoxilina y eosina (H&E), tiñe los núcleos de color azul violáceo y el citoplasma y la matriz extracelular en tonos rosados. El contraste entre ambos colores permite distinguir las distintas estructuras del tejido.

La digitalización de estas preparaciones mediante escáneres específicos produce imágenes de portaobjetos completo, conocidas como WSI (*Whole Slide Images*), que pueden alcanzar dimensiones muy elevadas [11]. Por este motivo, en lugar de procesar la imagen completa, es habitual dividirla en fragmentos de menor tamaño, denominados parches. GasHisSDB (Gastric Histopathology Sub-size Image Database), el conjunto de datos público empleado en este trabajo, sigue este planteamiento: sus parches se obtuvieron recortando 600 imágenes de tejido gástrico de 2048×2048 píxeles en tres tamaños, de 80, 120 y 160 píxeles de lado, y cada uno está etiquetado como `Normal` o `Abnormal`. La Figura 2.3 muestra un ejemplo de cada clase en los tres tamaños.

Como se observa en la figura, ambas clases comparten la gama de colores propia de la tinción H&E, y un parche de mayor tamaño abarca una región de tejido más amplia. Las diferencias entre clases pueden manifestarse en rasgos como la densidad celular o la organización del tejido, que no siempre resultan evidentes en un recorte pequeño. Por ello, el tamaño del parche constituye un factor relevante en el diseño experimental de este trabajo.

El análisis de imágenes histopatológicas puede plantearse a diferentes niveles. Una tarea puede consistir en clasificar un parche de tejido, identificar regiones dentro de una

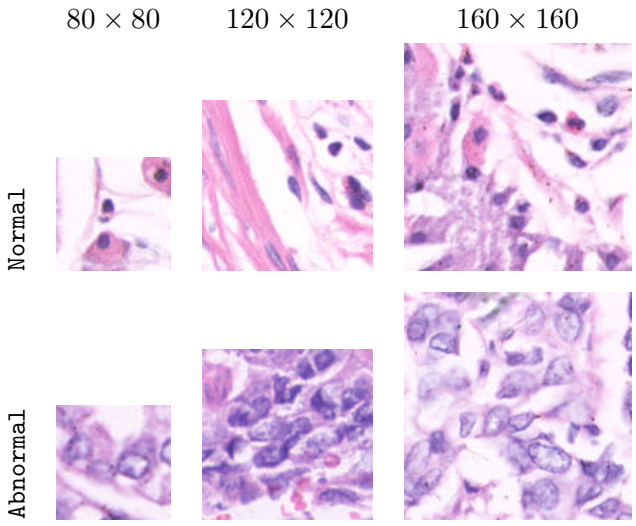


Figura 2.3.: Ejemplos de parches de GasHisSDB de las clases `Normal` y `Abnormal` en los tres tamaños disponibles. Cada parche se representa con una anchura proporcional a su tamaño en píxeles. Fuente: elaboración propia a partir de GasHisSDB [3].

imagen o combinar información de múltiples regiones para obtener una predicción más global. Estas tareas requieren información y procedimientos de evaluación diferentes. En esta memoria se aborda el primero de estos niveles: la clasificación de parches individuales en las clases `Normal` y `Abnormal` [3].

El preentrenamiento también se ha extendido a colecciones específicas de histopatología. Un ejemplo es UNI, que utiliza aprendizaje autosupervisado para obtener representaciones a partir de imágenes de tejido y transferirlas a distintas tareas [12]. Esta línea de investigación muestra que no solo es importante la arquitectura escogida, sino también el origen de las representaciones.

El presente trabajo se centra en un extractor preentrenado en ImageNet y estudia modificaciones concretas de su uso. Los modelos especializados en histopatología constituyen, por tanto, una alternativa relacionada con el problema, aunque su comparación experimental queda fuera del alcance de esta memoria.

2.2. EfficientNetV2 y CatBoost

2.2.1. De EfficientNet a EfficientNetV2

La familia EfficientNet fue presentada con el objetivo de estudiar cómo aumentar la capacidad de una red convolucional manteniendo un uso eficiente de los recursos. Su propuesta de escalado compuesto combina cambios en tres dimensiones: la profundidad de la red, su anchura y la resolución de las imágenes de entrada [13].

La profundidad se relaciona con el número de capas, la anchura con el número de canales y la resolución con el tamaño espacial de la entrada. Modificar cualquiera de estas dimensiones afecta tanto a la capacidad del modelo como a su coste. El escalado compuesto plantea aumentarlas de forma coordinada, en lugar de modificar una sola de las dimensiones de manera aislada [13].

EfficientNetV2 continúa esta línea, incorporando el tiempo de entrenamiento como criterio de diseño. Para ello combina búsqueda de arquitecturas y escalado, e incluye bloques especializados encargados de reorganizar determinadas operaciones convolucionales para aprovechar mejor el hardware en algunas etapas de la red [14].

El artículo también presenta una estrategia de aprendizaje progresivo que aumenta el tamaño de las imágenes durante el entrenamiento y adapta la regularización a ese cambio. Esta estrategia pertenece al procedimiento de entrenamiento propuesto para la familia EfficientNetV2.

2.2.2. EfficientNetV2-B0 como extractor

En este trabajo se utiliza EfficientNetV2-B0 mediante la implementación disponible en `timm`, identificada como `tf_efficientnetv2_b0`. Los pesos utilizados proceden de un entrenamiento en ImageNet-1k y permiten emplear el modelo como extractor de características [15].

Para realizar esta extracción se retira el clasificador original y se conserva la representación anterior a esa salida. La agrupación mediante promedio global, denominada GAP (*Global Average Pooling*), resume cada canal del mapa de características mediante su valor medio. De esta forma se obtiene un vector que puede utilizarse como entrada de otro clasificador [15].

En la configuración empleada, cada imagen queda representada mediante 1280 componentes. Estas componentes son características aprendidas por la red y no deben interpretarse directamente como medidas histológicas identificables. Por ejemplo, no puede suponerse que una componente concreta represente por sí sola el número de núcleos o la presencia de una estructura determinada.

Mantener los pesos del extractor congelados permite reutilizar sus representaciones durante la selección de CatBoost. Esta decisión reduce el número de parámetros que deben ajustarse con las etiquetas de GasHisSDB, aunque también limita la adaptación del extractor a las particularidades de las imágenes del trabajo.

2.2.3. CatBoost

CatBoost es un método basado en conjuntos de árboles de decisión y en aprendizaje por refuerzo de gradiente, habitualmente denominado *gradient boosting* [16]. En este contexto, el término se refiere a la construcción progresiva de un conjunto de modelos, donde cada árbol nuevo utiliza información de la función de pérdida para mejorar la predicción del conjunto.

Un árbol de decisión toma una serie de decisiones para llegar a una predicción. En lugar de utilizar un único árbol, CatBoost combina varios árboles, así el modelo puede representar relaciones que un único árbol solo no podría. El proceso de construcción es progresivo. En cada iteración se añade un nuevo árbol que intenta mejorar la predicción obtenida hasta ese momento. La Figura 2.4 ilustra este proceso. En ella, F_t representa la predicción acumulada tras la iteración t, h_t el árbol añadido en esa iteración y η la tasa de aprendizaje, que escala su contribución. CatBoost utiliza por defecto árboles simétricos, en los que todos los nodos de un mismo nivel aplican la misma condición de división, como indican las líneas punteadas de la figura [16]. .

Como se observa en la figura, cada árbol se suma a la predicción acumulada y la pérdida del conjunto disminuye a medida que avanzan las iteraciones. El desarrollo de este proceso depende de los hiperparámetros del modelo.

Los hiperparámetros son valores que se fijan antes del entrenamiento y determinan cómo aprende el modelo. Se diferencian de los parámetros, como las condiciones de división o los valores de las hojas, que el algoritmo ajusta a partir de los datos. En

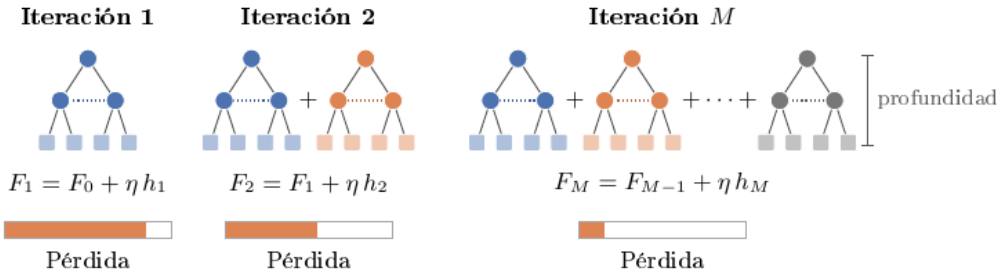


Figura 2.4.: Proceso iterativo de construcción progresiva de árboles de decisión en CatBoost mediante *gradient boosting*. Fuente: elaboración propia

CatBoost, tres de los más relevantes, que se emplean en este proyecto son los siguientes:

- **Número de iteraciones.** Fija cuántos árboles componen el conjunto. Añadir árboles permite seguir reduciendo la pérdida sobre los datos de entrenamiento, aunque a partir de cierto punto el modelo puede empezar a ajustarse a particularidades que no se generalizan.
- **Tasa de aprendizaje.** Controla cuánto modifica cada árbol la predicción acumulada. Con un valor pequeño, el modelo avanza con pasos más cortos y necesita más iteraciones para completar su entrenamiento.
- **Profundidad.** Determina el número de niveles de cada árbol. Una mayor profundidad permite representar combinaciones más complejas de características, a costa de un mayor riesgo de sobreajuste.

No existe una combinación de valores adecuada para cualquier problema. Además, estos hiperparámetros interactúan entre sí: una tasa de aprendizaje reducida puede compensarse con un mayor número de iteraciones, y la profundidad adecuada depende de la complejidad de las relaciones presentes en los datos. Una configuración que limite en exceso la capacidad del modelo puede producir subajuste, mientras que una que la amplíe demasiado puede favorecer el sobreajuste. Por este motivo, es habitual evaluar varias combinaciones y seleccionar la que obtiene mejor rendimiento sobre datos de validación. Los valores explorados en este trabajo se detallan en la sección 3.5.

En este proyecto, CatBoost recibe características numéricas extraídas por EfficientNetV2-B0. El interés se encuentra en utilizar un clasificador capaz de aprender relaciones entre las componentes del vector y separar esta etapa del procesamiento de las imágenes.

2.2.4. Justificación de la combinación

La combinación de EfficientNetV2-B0 y CatBoost permite dividir la tarea en dos partes: obtener una representación de cada parche y aprender a clasificarla. Esta separación facilita estudiar el efecto del aumento de datos y de la incorporación de atención manteniendo una estructura común de comparación.

La elección inicial estuvo motivada por el artículo de Khayatian *et al.* [17], el cual se encuentra retractado [18], por lo que se conserva únicamente como antecedente de la elección arquitectónica.

La justificación experimental de la combinación depende de los resultados obtenidos con los datos y el protocolo de esta memoria. No se presupone que sea superior a otras arquitecturas ni que las conclusiones de un estudio con un particionado diferente puedan trasladarse directamente a este trabajo.

2.3. Evaluación de modelos con datos desbalanceados

2.3.1. Desbalance de clases y elección de métricas

Un conjunto de datos está desbalanceado cuando las clases tienen frecuencias diferentes. Esta situación puede hacer que una medida global oculte un comportamiento deficiente sobre la clase menos frecuente. Como ejemplo ilustrativo, si nueve de cada diez imágenes pertenecieran a una misma clase, un modelo que predijera siempre esa clase alcanzaría un *accuracy* del 90 %, aunque no identificara ningún ejemplo de la otra.

Una forma de abordar el desbalance durante el entrenamiento consiste en ponderar los errores de cada clase dentro de la función de pérdida. Así, la contribución de una clase no depende únicamente de cuántos ejemplos aporta. Esta ponderación debe distinguirse de la selección de métricas: modificar la pérdida no elimina la necesidad de evaluar por separado los distintos tipos de aciertos y errores.

Por este motivo, en esta memoria el *accuracy* se acompaña de métricas que describen el comportamiento del modelo sobre cada clase: la sensibilidad, la especificidad, la precisión, la puntuación F1 y el *balanced accuracy*. Además, se emplea el área bajo la curva ROC (AUC-ROC). Esta curva representa la relación entre la tasa de verdaderos positivos y la tasa de falsos positivos al variar el umbral de decisión, por lo que su área no depende

de un umbral concreto. Todas estas métricas se definen en el apartado 3.7.1.

2.3.2. Validación cruzada y selección de hiperparámetros

La evaluación requiere distinguir entre los datos utilizados para aprender los parámetros del modelo, los empleados para elegir su configuración y los reservados para comprobar el resultado final con respecto a las etiquetas originales. Si se seleccionasen los hiperparámetros observando repetidamente el conjunto de prueba, este dejaría de proporcionar una evaluación independiente de esa selección.

La validación cruzada permite comparar configuraciones dentro del conjunto de entrenamiento. En su forma de k pliegues, los datos se dividen en k partes. Cada ajuste utiliza $k - 1$ partes para entrenar y la restante para validar, hasta que todas han desempeñado este último papel. Las puntuaciones obtenidas se resumen para comparar las configuraciones [19].

En clasificación, la variante estratificada mantiene aproximadamente la proporción de clases en los distintos pliegues. Esto facilita que las particiones conserven representación de ambas categorías, aunque no corrige por sí mismo las relaciones que puedan existir entre las observaciones.

La validación cruzada utilizada para seleccionar hiperparámetros debe distinguirse de la evaluación final. Al emplear validación cruzada deja de ser necesario un conjunto de validación separado, pero debe seguir reservándose un conjunto de prueba para la evaluación final [19]. La Figura 2.5 muestra este esquema tal como se ha aplicado en este trabajo. Los datos se dividen primero en una partición de entrenamiento y otra de prueba, y la validación cruzada se realiza únicamente sobre la primera. Una vez seleccionada la configuración de CatBoost, el clasificador se ajusta con todo el conjunto de entrenamiento y se evalúa una única vez sobre la partición de prueba reservada para cada semilla.

2.3.3. Múltiples semillas y variabilidad

Una única división de los datos puede producir un resultado condicionado por las imágenes que hayan quedado en entrenamiento y prueba. Además, algunos algoritmos incorporan operaciones aleatorias durante su ajuste. Las semillas permiten controlar los generadores utilizados por esas operaciones y documentar cómo se obtuvieron determi-

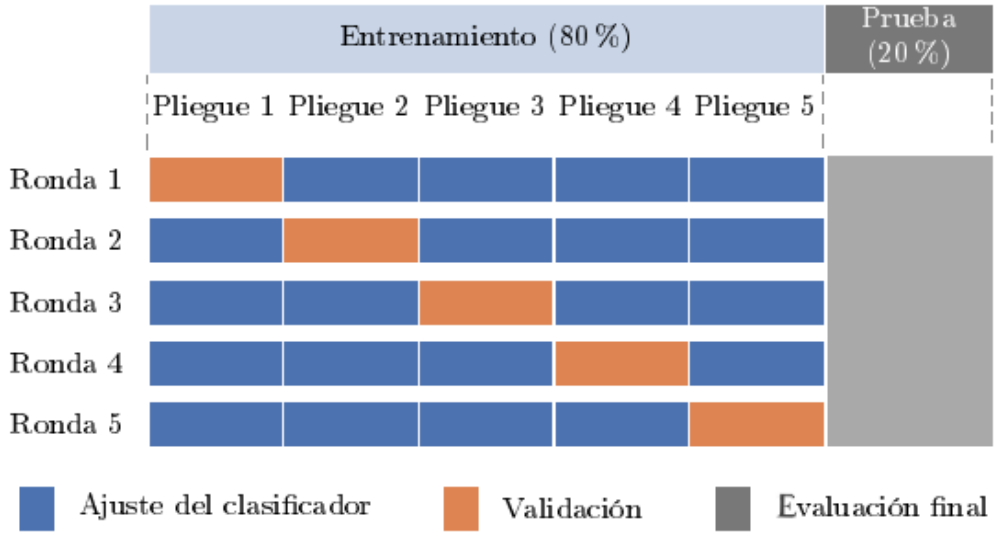


Figura 2.5.: Validación cruzada estratificada de cinco pliegues aplicada sobre el conjunto de entrenamiento. En cada ronda, un pliegue se utiliza para validar y los cuatro restantes para ajustar el clasificador. El conjunto de prueba se reserva para la evaluación final. Fuente: elaboración propia

nadas ejecuciones [20].

Repetir el experimento con varias semillas permite observar cuánto cambia el rendimiento bajo las variaciones introducidas. La media resume los resultados y la desviación típica describe su dispersión. Sin embargo, estas repeticiones no equivalen a disponer de varias colecciones independientes: una misma imagen puede intervenir en diferentes particiones.

También debe especificarse qué fuentes de aleatoriedad controla cada semilla. Fijar la utilizada para dividir los datos no implica fijar automáticamente la inicialización de una red o todas las operaciones de las bibliotecas empleadas. Por ello, la reproducibilidad requiere documentar tanto las semillas como su aplicación en el procedimiento [20].

2.3.4. Prevención de fugas de información

Se produce una fuga de información cuando el aprendizaje o la selección del modelo utiliza información que debería quedar reservada para su evaluación. Esto puede suceder

de forma directa, al reutilizar ejemplos, o indirectamente a través de operaciones previas, como ajustar una transformación con datos de entrenamiento y prueba conjuntamente.

En histopatología, el problema no se limita a encontrar imágenes idénticas. Distintos parches pueden proceder de una misma imagen de tejido y compartir estructuras, condiciones de tinción o características de adquisición. Bussola *et al.* estudiaron cómo la distribución de fragmentos relacionados entre entrenamiento y evaluación puede alterar las estimaciones de rendimiento en patología digital [21]. Cuando se dispone de identificadores adecuados, el particionado debe respetar la unidad sobre la que se desea estudiar la generalización. Si se pretende evaluar el comportamiento en nuevos pacientes, las imágenes de un mismo paciente deben permanecer en un único grupo. Además, exponen que eliminar duplicados exactos no garantiza esa separación, porque dos imágenes diferentes pueden seguir estando relacionadas [21].

Este principio también afecta al aprendizaje de características. Un extractor preentrenado en una colección externa y mantenido fijo no se ajusta a las etiquetas de la tarea durante la validación. En cambio, si se entrena un módulo adicional, su ajuste y selección deben considerarse parte del proceso que se evalúa. Separar únicamente los datos del clasificador final no garantiza una validación independiente del sistema completo.

En GasHisSDB, la ausencia de identificadores suficientes en los datos utilizados limita la posibilidad de garantizar una separación por paciente o imagen de origen. Por esta razón, los resultados del trabajo se interpretan como una evaluación a nivel de parche. Esta limitación debe mantenerse presente al comparar configuraciones o relacionar los resultados con los de otros estudios.

2.4. Aumento de datos, atención e interpretabilidad

2.4.1. Aumento de datos en histopatología

El aumento de datos consiste en generar variaciones de los ejemplos de entrenamiento mediante transformaciones que se consideran compatibles con sus etiquetas. Su propósito es exponer al modelo a una mayor variedad de apariencias y reducir su dependencia de características que no deberían determinar la clasificación.

En imágenes histopatológicas se han estudiado transformaciones geométricas y mo-

dificaciones del color. Tellez *et al.* analizaron distintas estrategias de aumento y normalización de tinción, incluyendo rotaciones y reflexiones entre las transformaciones básicas [22]. La utilidad de cada operación depende de la tarea y de que conserve la información relevante para distinguir las clases.

En este trabajo se estudian cambios de orientación. Un parche original y sus versiones transformadas pueden producir vectores distintos al atravesar un extractor congelado. Al proporcionar esas representaciones al clasificador con una etiqueta común, se busca comprobar si mejora su comportamiento frente a dichas variaciones.

Las imágenes transformadas siguen procediendo del mismo ejemplo original. Por ello, deben conservar su asignación al grupo de entrenamiento correspondiente y no distribuirse entre entrenamiento y evaluación como si fueran observaciones independientes.

2.4.2. Mecanismos de atención y CBAM

Los mecanismos de atención permiten modificar el peso de distintas partes de una representación en función de la entrada. En una red convolucional, esta ponderación puede aplicarse a los canales o a las posiciones espaciales de sus mapas de características.

En el artículo *CBAM: Convolutional Block Attention Module* [23] los autores presentaron CBAM como un módulo que combina ambas operaciones de forma secuencial. Primero calcula una atención de canal y después una atención espacial, aplicando sus pesos sobre las activaciones recibidas.

La atención de canal regula la representación correspondiente a cada canal completo. La atención espacial, por su parte, modifica el peso de las posiciones del mapa. Aunque ambas se aprenden para resolver la tarea, sus valores no constituyen directamente probabilidades de que una región pertenezca a una clase ni una segmentación del tejido [23].

Dentro del análisis de tejido gástrico, la prepublicación CoAtNeXt [24] combina componentes convolucionales y de tipo *transformer*, e incorpora CBAM para reforzar la extracción de características. El modelo se estudia en GasHisSDB y en otro conjunto de clasificación histológica gástrica.

Este antecedente sitúa la atención entre las alternativas relacionadas con el problema.

La propuesta de esta memoria mantiene EfficientNetV2-B0 y examina la incorporación de CBAM antes de GAP, con el objetivo de estudiar esa modificación concreta.

2.4.3. Interpretabilidad de las representaciones y del clasificador

Las métricas describen el rendimiento del sistema, pero no muestran por sí solas cómo utiliza la información de entrada. Las técnicas de interpretabilidad permiten explorar este comportamiento y buscar patrones que ayuden a analizar sus predicciones.

En redes convolucionales, una familia de técnicas muy extendida genera mapas que señalan qué regiones de la imagen se relacionan con una predicción. Zhou *et al.* propusieron los mapas de activación de clase (CAM, *Class Activation Mapping*), que combinan los mapas de características de la última capa convolucional ponderándolos con los pesos que el clasificador asigna a cada canal tras la agrupación global promedio [25]. Grad-CAM generaliza esta idea y obtiene la ponderación de cada canal a partir de los gradientes de la puntuación de la clase respecto a esos mapas [26]. En ambos casos, el mapa resultante tiene la resolución de la última capa convolucional, por lo que proporciona una localización aproximada.

Los módulos de atención ofrecen otra vía de inspección, ya que sus pesos pueden visualizarse directamente. En el caso de CBAM, los mapas de atención espacial muestran la ponderación aplicada dentro del módulo, aunque no explican cómo utiliza el clasificador posterior el vector resultante.

Para analizar las contribuciones de las características a una predicción concreta, Lundberg y Lee propusieron SHAP (*SHapley Additive exPlanations*), un marco de explicaciones aditivas basado en los valores de Shapley de la teoría de juegos [27]. Estas contribuciones se interpretan respecto a un valor de referencia y dependen del modelo y de la observación analizada. Al tratarse de un marco general, puede aplicarse también a clasificadores basados en árboles, como CatBoost.

En este trabajo se combinan ambas perspectivas: los mapas de atención de CBAM y una proyección de las contribuciones SHAP sobre los mapas de características, análoga a CAM, descrita en el apartado 3.6.5. Ambos análisis son complementarios y tienen un carácter exploratorio, por lo que no validan la relevancia histológica de las regiones observadas.

3. Metodología

Este capítulo, en el que se describe el procedimiento seguido para construir y evaluar el sistema de clasificación, se divide en varios apartados: la sección 3.1, en la que se describen el entorno experimental y la organización del proyecto; la sección 3.2, donde se presentan el conjunto de datos GasHisSDB y el análisis exploratorio realizado sobre él; las secciones 3.3 y 3.4, en las que se ofrece una visión general del sistema y se detallan el preprocesamiento de las imágenes y la extracción de sus características; y, finalmente, la sección 3.5, en la que se expone el protocolo de clasificación, junto con los experimentos realizados sobre la configuración de referencia y las métricas empleadas para evaluarlos.

3.1. Entorno experimental y organización del proyecto

3.1.1. Hardware

Todos los experimentos realizados en este proyecto se ejecutaron en un ordenador de sobremesa. El tiempo necesario para reproducir el trabajo depende de las especificaciones del equipo usado, por eso es interesante contar con un ordenador con buenas especificaciones, sobre todo ya que un procesador y una tarjeta gráfica más potentes permiten reducir los tiempos de ejecución.

Conviene señalar una consideración relativa al consumo de memoria. Durante el desarrollo se observó que, al ejecutar las cinco semillas seguidas dentro de un mismo proceso, el consumo de memoria aumentaba progresivamente. Parte de la memoria utilizada por las bibliotecas permanecía ocupada al terminar cada repetición. En las colecciones con más imágenes, este comportamiento llegaba a agotar la memoria disponible antes de completar las cinco ejecuciones.

Para evitar la acumulación de memoria entre repeticiones, el programa principal de experimentos ejecuta las cinco semillas de forma secuencial, cada una en un proceso independiente. Al finalizar una repetición, el proceso devuelve los resultados al programa principal y termina antes de iniciar la siguiente. Esto permite que el sistema operativo

libere la memoria asociada al proceso y evita que la memoria retenida durante una repetición se acumule en las posteriores.

Desde el punto de vista del hardware, la mayor parte del cálculo en GPU se concentra en la extracción de características con EfficientNetV2-B0 y en el entrenamiento de CBAM. Las características obtenidas se almacenan en caché y se reutilizan en los ajustes posteriores, como se detalla en el apartado 3.4.2, por lo que esta fase no se repite en cada ajuste del clasificador. La búsqueda de hiperparámetros de CatBoost se realiza a partir de los vectores almacenados, en CPU o en GPU según la disponibilidad de esta última. Esta organización ha permitido ejecutar los experimentos por etapas con los recursos del equipo descrito en la Tabla 3.1.

Tabla 3.1.: Especificaciones del ordenador utilizado en los experimentos.

Componente	**Especificación**
Placa base	Gigabyte Z490 UD
Procesador	Intel Core i5-10400F, 6 núcleos y 12 hilos, hasta 4,30 GHz
Tarjeta gráfica	NVIDIA GeForce RTX 3060 Ti, 8 GB
Memoria RAM	16 GB DDR4
Sistema operativo	Windows 10 de 64 bits

3.1.2. Software

Todo el código del proyecto se ha programado íntegramente en `Python`, mediante una combinación de archivos de *script* con extensión `.py` y cuadernos `Jupyter` con extensión `.ipynb`. Los cuadernos de `Jupyter` reúnen tablas, código y figuras centrados en el análisis exploratorio de los datos. Por otra parte, `Python` se ha utilizado como lenguaje principal a la hora de organizar el flujo de trabajo. Este lenguaje ha permitido seleccionar las configuraciones de los experimentos a través de argumentos que acompañan la ejecución de los archivos, para ello se han utilizado módulos ejecutables desde terminal. Esta separación permite conservar el cuaderno como herramienta de exploración y utilizar un flujo más estructurado para las ejecuciones repetidas. Visual Studio Code se ha utilizado como entorno principal para la programación, ejecución y depuración del código. Además, el proyecto se ha apoyado en GitHub para el control de versiones y la gestión del repositorio.

Las principales bibliotecas empleadas y sus versiones se especifican más adelante, conviene remarcar que se han fijado. La fijación encuentra su motivación en el hecho de que los cambios entre versiones de una biblioteca de aprendizaje profundo pueden alterar la inicialización de las capas y el comportamiento de determinadas operaciones.

La Tabla 3.2 recoge las principales herramientas y bibliotecas, sus versiones y su función en el trabajo.

Tabla 3.2.: Herramientas y bibliotecas empleadas, versiones y funciones en el trabajo.

Biblioteca	**Versión**	**Función**
Python	3.11.9	Lenguaje base
PyTorch + timm	2.4.0 / 1.0.9	*Backbone* EfficientNetV2-B0 y módulo CBAM
CatBoost	1.2.7	Clasificador de *gradient boosting*
scikit-learn	1.5.2	Particionado, métricas y utilidades
NumPy	1.26.4	Álgebra y almacenamiento de características
pandas	2.2.2	Gestión de resultados tabulares
Matplotlib	3.9.2	Figuras y visualizaciones
seaborn	0.13.2	Figuras estadísticas del análisis exploratorio
OpenCV	4.10.0	Lectura y transformación de imágenes
Pillow	10.4.0	Apertura y verificación de imágenes
Image*hash*	4.3.1	Detección de duplicados mediante *hashing* perceptual
PyYAML	6.0.1	Lectura de los ficheros de configuración

3.1.3. Organización del repositorio

El código se organiza siguiendo una separación según el funcionamiento de los archivos:

- `src/data/`: carga de GasHisSDB, particionado de los datos, verificación de integridad, análisis exploratorio, preprocesamiento de imágenes y definición de las transformaciones de aumento de datos.
- `src/features/`: definición del extractor convolucional congelado, entrenamiento del módulo CBAM y extracción y almacenamiento en caché de las características de las distintas configuraciones experimentales.
- `src/models/`: definición de la arquitectura del módulo CBAM, configuración del clasificador CatBoost, selección de hiperparámetros mediante validación cruzada y entrenamiento del clasificador final.
- `src/training/`: coordinación y ejecución de los experimentos con múltiples semillas, así como de la evaluación de transferencia entre distintos tamaños de parche.
- `src/evaluation/`: cálculo de métricas y matrices de confusión, y agregación de resultados entre semillas.
- `src/visualization/`: generación de mapas de atención espacial de CBAM y de visualizaciones basadas en los valores SHAP del clasificador CatBoost.
- `configs/`: almacenamiento de las estadísticas de normalización de las imágenes para cada resolución.
- `results/`: almacenamiento de resultados experimentales en formato JSON, características extraídas, pesos del módulo CBAM, matrices de confusión y figuras generadas.
- `Dockerfile` y `docker-compose.yml`: Dockerfile y la configuración de ejecución del contenedor.
- `requirements.txt` y `requirements-lock.txt`: archivos situados en la raíz del repositorio que recogen, respectivamente, las dependencias declaradas para la instalación y el inventario de paquetes del entorno consultado.

3.1.4. Contenedor Docker

Docker es una plataforma de contenerización que permite empaquetar una aplicación junto con el código, las bibliotecas, las herramientas del sistema y el resto de las dependencias necesarias para su ejecución. Gracias a esto, la aplicación puede comportarse de forma consistente en distintos equipos [28].

Con el objetivo de facilitar la reproducibilidad del proyecto, todo el entorno de ejecución se ha encapsulado en un contenedor Docker. Su utilización también ha permitido ampliar los conocimientos sobre esta tecnología. En concreto, Docker se ha empleado para cubrir las siguientes necesidades:

- **Aislamiento de dependencias.** La combinación de una biblioteca de aprendizaje profundo con aceleración por GPU y una biblioteca de *gradient boosting* impone restricciones cruzadas entre las versiones de los controladores y las bibliotecas del sistema, difíciles de reproducir manualmente.
- **Reproducibilidad verificable.** El archivo Dockerfile documenta, en un fichero legible y versionado, el entorno exacto en el que se obtuvieron los resultados. De esta forma, cualquier lector puede reconstruirlo sin depender de la configuración local de su equipo.
- **Separación entre código y datos.** Las imágenes de GasHisSDB, las características extraídas y los resultados se montan como volúmenes externos al contenedor. De este modo, la costosa fase de extracción de características se conserva aunque se reconstruya la imagen de Docker.

La configuración del contenedor y los archivos que documentan el entorno se encuentran en el repositorio del proyecto, cuya localización se indica en el Anexo A.

3.2. Conjunto de datos y Análisis exploratorio de datos

3.2.1. Conjunto de datos, GasHisSDB

Antes de trabajar con cualquier tipo de datos es importante conocerlos. En este trabajo se utiliza el conjunto de datos GasHisSDB, una base de datos pública de imágenes histopatológicas orientada al diagnóstico asistido por computador del cáncer gástrico. Consta de cerca de un cuarto de millón de imágenes en color de tejido gástrico humano

teñido, etiquetadas en dos clases: `Normal` y `Abnormal` [3].

Al estudiar más en profundidad la estructura del *dataset* se observa que las 245.196 imágenes no son un único conjunto, sino que realmente son tres subconjuntos obtenidos a partir de recortar ciertas imágenes completas de tejido histopatológico. Se obtienen por lo tanto al final tres subconjuntos los cuales dividen los parches por resoluciones: 160, 120 y 80 píxeles de lado. Cada subconjunto cuenta a su vez con las imágenes ya clasificadas entre normales y anormales. La distribución de imágenes por resolución y clase se resume en la Tabla 3.3.

Tabla 3.3.: Distribución de las imágenes de GasHisSDB por resolución y clase.

Resolución	**Normal**	**Abnormal**	**Total**	**% Abnormal**
80×80	87 500	59 151	146 651	40,3 %
120×120	40 460	24 801	65 261	38,0 %
160×160	20 160	13 124	33 284	39,4 %
Total	**148 120**	**97 076**	**245 196**	**39,6 %**

Los parches de la clase `Normal` se obtuvieron a partir de recortar las imágenes sin región tumoral, mientras que los de la clase anormal, recortando las regiones señaladas como cancerosas en las imágenes de referencia. Esto trae consecuencias. Lo primero es que los tres subconjuntos no son conjuntos independientes: comparten las imágenes completas originales, por lo que un mismo fragmento de tejido puede aparecer representado en las tres a distinta escala. Esto impide tratarlas de manera conjunta y, al mismo tiempo, genera una nueva duda acerca de que si el contenido es el mismo y solo cambia la escala de análisis. Más adelante en el proyecto, se estudia si lo aprendido a una escala se sostiene en otra. La segunda es que el número de imágenes crece de forma pronunciada al reducir el tamaño de parche. Por lo tanto el subconjunto de 80 píxeles tiene muchas más imágenes que el de 160, lo que significa que las tres tareas difieren no solo en la escala, sino también en la cantidad de datos de entrenamiento.

3.2.2. Análisis exploratorio de datos

Antes de construir ningún modelo se realizó un análisis exploratorio con cuatro objetivos:

1. **Verificar la integridad del conjunto de datos.** Comprobar que todos los

ficheros son legibles, que los formatos y dimensiones son correctos, y especialmente, que coinciden exactamente con lo declarado en la fuente original.

2. **Estudiar el balanceo de clases**. Realizar un recuento por clase y subconjunto para determinar la necesidad de aplicar técnicas de balanceo de clases en el clasificador y seleccionar las métricas de evaluación adecuadas.

3. **Estadísticas de intensidad.** El objetivo de este estudio es comprobar que no existan diferencias sistemáticas de intensidad entre clases que el modelo pueda aprovechar como atajo. El procedimiento empezó analizando las intensidades de los canales RGB para caracterizar las diferencias de color global entre las clases. Para ello, se seleccionó una muestra y para cada imagen se calculó la intensidad media de los canales rojo, verde y azul. Posteriormente, estos valores se agruparon por resolución y clase para obtener su media y desviación típica. Por tanto, la desviación típica describe la variabilidad entre las intensidades medias de las imágenes, no la dispersión de sus píxeles individuales. Los resultados de este análisis se presentan en el apartado 4.1.3.

4. **Búsqueda de imágenes duplicadas y visualmente similares.** La presencia de imágenes idénticas en los conjuntos de entrenamiento y prueba puede introducir una fuga de información y producir una estimación demasiado favorable del rendimiento. Por este motivo, se realizaron dos comprobaciones complementarias, considerando tanto las coincidencias dentro de cada subconjunto como entre clases.

   En primer lugar, se realizó una exploración de similitud visual sobre una muestra de 10.000 imágenes por tamaño de parche. Para cada imagen se calculó un *hash* perceptual mediante pHash, una representación resumida de su apariencia formada por 64 bits, cada uno con valor 0 o 1. A continuación, se compararon los *hashes* de todas las parejas de la muestra mediante la distancia de Hamming, que cuenta el número de posiciones en las que difieren sus bits, es decir, cuántos bits habría que cambiar del *hash* de una imagen para convertirla en el *hash* otra. Se identificaron como parejas visualmente cercanas aquellas cuya distancia era menor o igual que cinco, distinguiendo las coincidencias completas de hash, con distancia cero. Estas coincidencias no garantizan que las imágenes tengan exactamente los mismos píxeles, puesto que el hash, al ser una secuencia numérica abreviada de la imagen original puede perder información.

   En segundo lugar, se realizó una búsqueda de duplicados exactos sobre todas las imágenes de cada tamaño de parche. Las imágenes se convirtieron a RGB y se

agruparon según el grupo de resolución a la que pertenecían y una huella calculada sobre sus píxeles. Para los grupos con huellas coincidentes, se comparó directamente el contenido RGB de las imágenes y se confirmó su igualdad. De esta forma, la identificación de duplicados exactos se basó en la coincidencia de dimensiones y píxeles, con independencia de posibles diferencias en los metadatos o la compresión de los archivos.

Los grupos detectados, las rutas de sus imágenes y sus etiquetas se almacenaron en un fichero CSV para facilitar su revisión.

3.2.3. Inventario y dependencia entre imágenes

Además, se investigó la posibilidad de descubrir para cada parche la imagen original a la que pertenece. Al tratar con imágenes que son realmente parches de una imagen más completa (WSI), existe un riesgo con respecto al tratamiento de los datos y es la posibilidad de que diferentes parches de una misma imagen o paciente se encuentren dispersos entre los conjuntos de entrenamiento, validación y prueba. Si se da este caso, el modelo puede memorizar textura/tinción local en lugar de aprender zonas malignas en las imágenes de forma generalizable, inflando las métricas.

El artículo original describe 600 imágenes de 2048×2048 píxeles a partir de las cuales se obtuvieron los parches de GasHisSDB [3]. Cada imagen original da lugar, por tanto, a muchos parches: la colección de 80 píxeles contiene 146.651, la de 120 píxeles, 65.261, y la de 160 píxeles, 33.284. Como ninguna de estas cantidades es múltiplo de 600, tampoco puede asumirse que todas las imágenes aporten el mismo número de parches. Además, los nombres de archivo siguen una estructura formada por la clase y un índice numérico, como `Abnormal-00001.png`. A partir de ellos se construyó un inventario recorriendo los PNG de una sola carpeta de tamaño y ordenando sus rutas. Sin embargo, este inventario no contiene un identificador de paciente ni de imagen de procedencia, por lo que no es posible reconstruir el origen de cada parche a partir del nombre de los ficheros. En consecuencia, no se puede garantizar la independencia entre los parches asignados a cada conjunto a nivel de tejido o de paciente, y los resultados deben interpretarse teniendo en cuenta esta restricción. Esta es la motivación de la partición escogida en los experimentos.

3.3. *Pipeline* del trabajo

Antes de describir las operaciones de preprocesamiento y extracción de características, la Figura 3.1 permite observar una visión general de la arquitectura utilizada. En la arquitectura utilizada como base los parches se redimensionan a 224×224 píxeles y se procesan mediante EfficientNetV2-B0, cuyos pesos permanecen congelados. Posteriormente, las características obtenidas se utilizan como entrada del clasificador CatBoost.

La Figura 3.1 además muestra las dos variantes estudiadas. La primera consiste en la incorporación de aumento de datos durante el entrenamiento, y la segunda, la introducción del módulo de atención CBAM. Ambas se evalúan por separado respecto al modelo de referencia para poder comparar sus resultados. En los siguientes apartados se detalla el proceso, las operaciones y cada componente representado en el esquema.

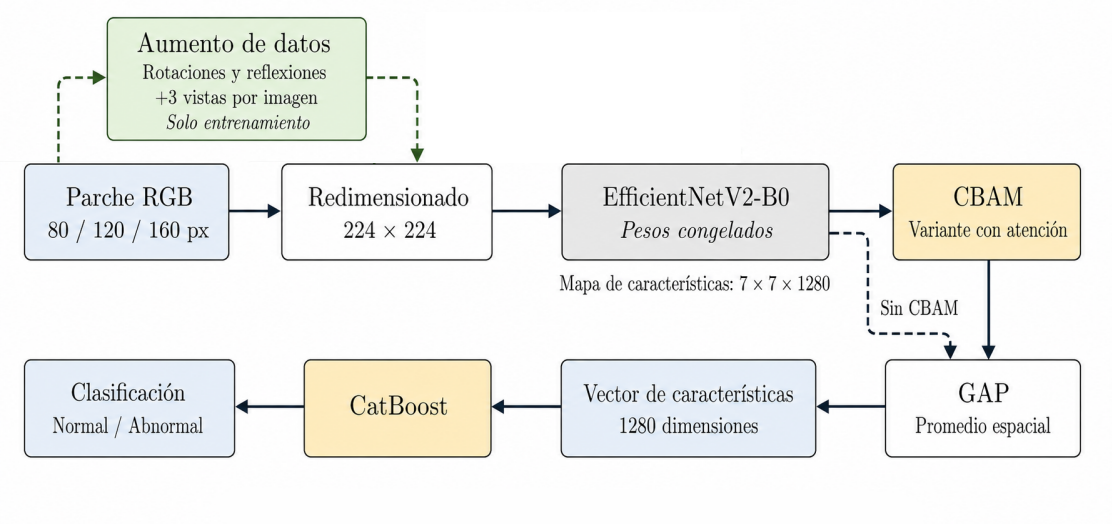


Figura 3.1.: Arquitectura general de clasificación y variantes estudiadas. El bloque y la ruta verde discontinua representan el aumento de datos, aplicado solo durante el entrenamiento. La ruta discontinua *Sin CBAM* corresponde a la configuración de referencia y la ruta continua a través de CBAM, a la variante con módulo de atención.

El esquema permite situar los componentes que se describen en los siguientes apartados: primero se detallan el preprocesamiento y la extracción de características; después, el protocolo de clasificación y evaluación; y, finalmente, las particularidades de cada experimento.

3.4. Preprocesamiento y extracción de características

En esta sección se describen las transformaciones aplicadas a las imágenes antes de su procesamiento por la red y la obtención de sus representaciones numéricas. Se detallan la conversión de canales, el redimensionamiento y la estandarización, así como la extracción de características mediante EfficientNetV2-B0 y su almacenamiento para reutilizarlas durante el ajuste de CatBoost. Las particularidades de cada variante se presentan en el apartado de experimentos realizados.

3.4.1. Preprocesamiento de las imágenes

Cada imagen se lee con OpenCV, sin embargo, esta librería devuelve los canales en orden BGR. Por lo tanto, antes de continuar, es importante aplicar una conversión explícita a RGB para mantener la misma correspondencia de canales que las estadísticas de normalización. Esta conversión es necesaria porque intercambiar rojo y azul modificaría la entrada del extractor aun cuando visualmente el parche continuara siendo reconocible.

Por otro lado, las imágenes de GasHisSDB tienen tamaños de 80, 120 o 160 píxeles de lado, mientras que EfficientNetV2-B0 espera entradas de 224×224. Por lo tanto, se redimensiona la imagen completa mediante interpolación bilineal. Todos los parches llegan a la red con el mismo tamaño, pero inicialmente cuentan con diferentes resoluciones, por lo tanto no todos se amplían en la misma proporción. Al aumentar cada imagen en diferentes factores, se consigue que sea más grande, pero no recupera estructuras que la imagen original no permitía distinguir, únicamente se amplía. Entonces los tres subconjuntos no solo se diferencian por la cantidad de tejido que abarca cada parche, sino también por la intensidad de la interpolación que sufren antes de entrar en la red.

A continuación, los valores de los píxeles se convierten a números de 32 bits en coma flotante y se dividen entre 255 para expresarlos en el intervalo $[0, 1]$. Después, cada canal RGB se estandariza restando su media y dividiendo el resultado por su desviación típica. Estas estadísticas se estimaron previamente sobre una muestra del inventario completo de GasHisSDB para cada tamaño de parche y se cargan desde el fichero de configuración. Su estimación se realizó antes del particionado y no se restringió a las imágenes de entrenamiento de cada repetición. Esta decisión introduce una limitación en el aislamiento del conjunto de prueba.

Por último, el lote pasa de la disposición número de imágenes, alto, ancho y canales

a la disposición número de imágenes, canales, alto y ancho, esperada por PyTorch. Se obtiene así un tensor contiguo de forma $N \times 3 \times 224 \times 224$. El procesamiento por lotes evita mantener todas las imágenes redimensionadas simultáneamente en memoria.

3.4.2. Extracción y almacenamiento de características

El extractor de características es una red convolucional EfficientNetV2-B0 con pesos preentrenados, sin su capa de clasificación original. Durante la extracción, sus pesos permanecen congelados y la red se utiliza en modo de evaluación. A partir de una imagen de entrada de 224×224 píxeles, se obtienen 1280 mapas de características de tamaño 7×7. A continuación, se aplica una capa de GAP, que calcula el valor medio de cada mapa y genera un vector de 1280 componentes. Estas características no son medidas histopatológicas definidas manualmente, como el número de núcleos o el tamaño de una glándula. Son respuestas de la red obtenidas a partir de los patrones aprendidos durante el preentrenamiento y son una representación numérica de cada parche. Su utilidad para distinguir las clases `Normal` y `Abnormal` se evalúa posteriormente mediante CatBoost.

Para cada tamaño de parche, los vectores de la configuración de referencia se almacenan en una matriz de dimensiones $N \times 1280$, donde N representa el número de imágenes y cada fila contiene las características de una imagen. Como el extractor permanece fijo, esta matriz se reutiliza en las cinco semillas y en los ajustes de CatBoost realizados durante la validación cruzada. De este modo, se evita repetir la extracción neuronal y se reduce el coste computacional de la búsqueda de hiperparámetros.

Para reutilizar correctamente las características guardadas, debe mantenerse la correspondencia entre las filas de la matriz y las imágenes del inventario además del preprocesamiento y los pesos utilizados en la extracción. Si alguno de estos elementos cambia, deben volver a generarse las características afectadas.

En la variante con aumento de datos, además de las características de las imágenes originales, se almacenan las correspondientes a las vistas transformadas. Estas vistas se generan con una semilla fija y sus características se reutilizan entre las distintas repeticiones. En la variante con CBAM, las características finales dependen del módulo de atención entrenado en cada repetición. Por ello, se almacena una matriz diferente para cada tamaño de parche y semilla. Esta matriz se reutiliza durante la validación cruzada y el ajuste final de CatBoost correspondientes a esa repetición. El almacenamiento evita

repetir la extracción para cada ajuste del clasificador y reduce el coste computacional de la búsqueda de hiperparámetros.

3.5. Clasificación y diseño experimental

En esta sección se describe el protocolo utilizado para entrenar y evaluar los clasificadores. Se detallan la separación de los datos, la selección de hiperparámetros, la compensación del desbalance y el control de la aleatoriedad. Las particularidades de cada variante se presentan en el apartado de experimentos realizados.

3.5.1. Separación de entrenamiento y prueba

Para evaluar el rendimiento del modelo, se distingue entre las imágenes destinadas al entrenamiento, las destinadas a la selección de hiperparámetros y las reservadas para la evaluación final. Esta separación permite realizar el ajuste del clasificador sin utilizar las puntuaciones del conjunto de prueba como criterio de selección.

Para cada resolución, el conjunto se divide en dos particiones mediante muestreo aleatorio estratificado por clase: un 80 % de las imágenes destinado al entrenamiento y a la selección de hiperparámetros, y un 20 % reservado como conjunto de prueba. La separación mantiene aproximadamente la proporción de las clases `Normal` y `Abnormal` en ambas particiones, evitando variaciones importantes en su distribución debidas al muestreo aleatorio.

El tamaño resultante de cada partición se recoge en la tabla 3.4.

Tabla 3.4.: Tamaño de las particiones de entrenamiento y prueba en cada resolución. Entre paréntesis, el número de imágenes de la clase `Abnormal`.

Tamaño de parche	**Entrenamiento (80 %)**	**Prueba (20 %)**	**Total**
80×80	117.320 (47.320)	29.331 (11.831)	146.651
120×120	52.208 (19.840)	13.053 (4.961)	65.261
160×160	26.627 (10.499)	6.657 (2.625)	33.284

El conjunto de prueba no se utiliza para seleccionar los hiperparámetros de CatBoost ni para determinar la parada del entrenamiento de CBAM. Se reserva únicamente para

evaluar y comparar las configuraciones una vez finalizado su ajuste. La única excepción son las estadísticas de normalización, estimadas antes del particionado sobre una muestra del inventario completo.

En los experimentos de aprendizaje profundo de la publicación original de GasHisSDB se utilizó una partición en tres subconjuntos, con el 40 % de las imágenes para entrenamiento, el 40 % para validación y el 20 % para prueba [3]. La proporción reservada para prueba coincide con la empleada aquí, aunque ello no implica que las imágenes evaluadas sean las mismas. La diferencia está en el resto: al sustituir el subconjunto de validación por una validación cruzada dentro del entrenamiento, cada combinación de hiperparámetros se valora sobre cinco pliegues en lugar de sobre una única división fija, y el ajuste final de CatBoost utiliza todas las imágenes de entrenamiento y no solo la mitad.

La partición se genera mediante la semilla correspondiente a cada repetición. Las cinco semillas producen cinco divisiones, que se comparten entre las configuraciones experimentales para cada tamaño de parche. Esta correspondencia permite comparar sus resultados de forma pareada.

Las repeticiones permiten describir la variabilidad observada entre ejecuciones, que puede proceder tanto de las particiones como de los componentes aleatorios del entrenamiento. Dado que las divisiones reutilizan imágenes del mismo conjunto, estas repeticiones no constituyen muestras independientes de pacientes. La división se realiza a nivel de parche, ya que los identificadores disponibles no permiten agrupar las imágenes según su tejido de origen. Un mismo archivo del inventario no se asigna simultáneamente a entrenamiento y prueba. Sin embargo, esta separación no garantiza la ausencia de contenido duplicado entre archivos distintos ni que todos los parches de un mismo tejido queden agrupados en una única partición.

3.5.2. Validación cruzada y búsqueda de hiperparámetros

Sobre el 80 % de los datos reservado para entrenamiento se aplica una validación cruzada estratificada de cinco pliegues. En cada ronda, cuatro pliegues se utilizan para ajustar el clasificador CatBoost y el restante para validarlo. Este procedimiento se repite hasta que cada pliegue se ha utilizado una vez como conjunto de validación.

La validación cruzada se aplica al clasificador CatBoost. En la variante con CBAM, el módulo de atención se entrena previamente y se mantiene fijo durante la búsqueda de

hiperparámetros del clasificador. Las implicaciones de este procedimiento se detallan en el apartado 3.6.3.

La búsqueda de hiperparámetros combina tres valores para el número de iteraciones (300, 500 y 700), tres tasas de aprendizaje (0,05, 0,1 y 0,2) y tres profundidades (4, 6 y 8). En total, se evalúan 27 combinaciones sobre las mismas cinco particiones y se selecciona la que alcanza el mayor *balanced accuracy* medio. Dicha métrica asigna el mismo peso a la sensibilidad de cada clase, por lo que reduce la influencia del desbalance en el criterio de selección. Se conservan tanto la configuración seleccionada como las puntuaciones de las demás alternativas, lo que permite revisar y comparar los resultados de la búsqueda.

Para cada combinación de tamaño de parche, variante experimental y semilla se realizan 135 ajustes de validación cruzada, correspondientes a 27 combinaciones de hiperparámetros evaluadas en cinco pliegues. Una vez seleccionados los hiperparámetros, se realiza un ajuste final de CatBoost sobre todo el conjunto de entrenamiento exterior. Al considerar las cinco semillas, cada combinación de tamaño de parche y variante experimental requiere 675 ajustes de validación cruzada y cinco ajustes finales de CatBoost.

El diseño completo comprende nueve condiciones experimentales, correspondientes a tres variantes y tres tamaños de parche. En total, se realizan 6.075 ajustes de validación cruzada y 45 ajustes finales de CatBoost. Estos recuentos no incluyen la extracción de características, el entrenamiento de CBAM, la evaluación entre tamaños ni posibles repeticiones adicionales de ejecución.

3.5.3. Compensación del desbalance de clases

En las tres configuraciones experimentales, CatBoost se entrena con pesos de clase para compensar la diferente representación de `Normal` y `Abnormal`. Estos pesos son inversamente proporcionales a la frecuencia de cada clase y se calculan mediante:

$$w_c = \frac{N}{2N_c}, \tag{3.1}$$

donde N es el número de ejemplos utilizados para calcular los pesos y N_c es el número de ejemplos pertenecientes a la clase c. El factor 2 corresponde al número de clases del problema.

Dado que `Abnormal` es la clase menos representada, sus ejemplos reciben un peso ma-

yor. Para una misma pérdida individual, un ejemplo de esta clase contribuye más a la función de pérdida que uno de la clase `Normal`. Por tanto, la suma de los pesos de todos los ejemplos de una misma clase es igual a $N/2$, con independencia de cuántos ejemplos tenga, y la suma de los pesos de todo el conjunto es igual a N. Esta ponderación permite equilibrar la contribución potencial de ambas clases al entrenamiento, aunque no garantiza que alcancen el mismo rendimiento ni que produzcan la misma pérdida total.

Los pesos se calculan sobre distintos conjuntos según la configuración:

- En la configuración de referencia y en la variante con CBAM se calculan a partir del conjunto de entrenamiento exterior y se mantienen durante la validación cruzada. Al ser las particiones estratificadas, la proporción de clases apenas varía entre pliegues.
- En la variante con aumento de datos se calculan sobre los ejemplos utilizados para ajustar el clasificador en cada pliegue, incluyendo las imágenes originales y sus vistas transformadas.
- Para el ajuste final de CatBoost se calculan, en todas las configuraciones, sobre el conjunto de ejemplos empleado en dicho ajuste.

No se realiza submuestreo de la clase `Normal` ni sobremuestreo de `Abnormal` para igualar sus frecuencias: el desbalance se compensa únicamente mediante los pesos de clase, lo que permite utilizar todas las imágenes disponibles en cada colección. En el experimento de aumento de datos se generan tres vistas adicionales por imagen en ambas clases, por lo que la proporción entre ellas se mantiene. Así, el aumento de datos amplía la variedad de orientaciones observadas durante el entrenamiento, mientras que los pesos de clase compensan la diferente representación de las clases. La comparación con otras estrategias frente al desbalance queda fuera del alcance de este trabajo y se plantea como línea futura en el apartado 6.2.

3.5.4. Control de la aleatoriedad y reproducibilidad

Para analizar la variabilidad de los resultados, cada experimento se repite utilizando cinco semillas. Cada semilla controla la separación de los conjuntos de entrenamiento y prueba, la construcción de las particiones de validación cruzada y el parámetro de aleatoriedad de CatBoost.

En la variante con CBAM, también determina la división interna del conjunto de entrenamiento utilizada para ajustar el módulo y evaluar su evolución. La parada del entrenamiento presente en esta configuración depende de la evolución de la pérdida en el conjunto de validación interno, del criterio de paciencia del *early stopping* y del límite de épocas establecido. Al finalizar, se recuperan los pesos de CBAM correspondientes a la época con menor pérdida de validación.

Para un mismo tamaño de parche, las configuraciones comparadas utilizan las mismas semillas y el mismo inventario ordenado. Esto se hace para tener una comparación más justa, ya que, de esta forma, cada comparación entre métodos se realiza sobre los mismos índices de prueba. Las transformaciones del aumento de datos se generan con una semilla fija que también se mantiene constante entre repeticiones.

La elección de cinco repeticiones se explica con la intención de encontrar un compromiso entre coste computacional y análisis de variabilidad. Tener cinco semillas diferentes permite estudiar la dispersión observada y realizar comparaciones justas. Las semillas no se utilizan como mecanismo de selección del mejor resultado, se conservan los resultados de las cinco ejecuciones y se presentan agregados mediante su media y desviación típica, sin escoger únicamente la ejecución más favorable. En conclusión, permite comprobar cuánto varía el rendimiento, en lugar de basar la conclusión en una ejecución afortunada.

3.6. Experimentos realizados

Los experimentos de este trabajo tienen como objetivo evaluar la clasificación de parches histopatológicos gástricos mediante la combinación de EfficientNetV2-B0 y CatBoost, así como analizar el efecto de distintas modificaciones sobre su rendimiento.

En primer lugar, se establece una configuración de referencia basada en la extracción de características con EfficientNetV2-B0 y su posterior clasificación mediante CatBoost. A partir de ella, se estudian dos variantes por separado: la incorporación de aumento de datos durante el entrenamiento y la introducción del módulo de atención CBAM antes de la capa GAP. Las tres configuraciones se evalúan en las colecciones de parches de 80, 120 y 160 píxeles, utilizando cinco semillas para analizar la variabilidad de los resultados.

Como análisis complementario, se evalúa la transferencia entre tamaños de parche mediante el entrenamiento del modelo de referencia en una colección y su evaluación en

otra. Además, se analiza la interpretabilidad de las predicciones mediante los mapas de atención de CBAM y las contribuciones SHAP del clasificador, tanto en la configuración de referencia como en la variante con CBAM.

Las siguientes subsecciones describen el objetivo y el procedimiento de cada experimento, así como las modificaciones introducidas respecto a la configuración de referencia.

3.6.1. Configuración de referencia

La configuración de referencia constituye el primer experimento del trabajo y sus resultados se utilizan como punto de partida para valorar y comparar las modificaciones posteriores. Sigue el *pipeline* de la Figura 3.1 sin módulo de atención y sin aumento de datos. Combina EfficientNetV2-B0 como extractor de características congelado y CatBoost como clasificador.

La elección inicial de esta combinación estuvo motivada por el trabajo de Khayatian *et al.* [17], en el que se compararon seis redes preentrenadas como extractores de características y dos clasificadores sobre GasHisSDB. Los autores obtuvieron los mejores resultados en la combinación de EfficientNetV2-B0 y CatBoost, combinándolas como método final. Este antecedente orientó la selección de la arquitectura de referencia del presente trabajo.

En esta configuración, cada parche se representa mediante el vector de 1280 componentes obtenido por el extractor, siguiendo el procedimiento descrito en el apartado anterior. Estos vectores se utilizan para entrenar CatBoost, mientras que los pesos de EfficientNetV2-B0 permanecen fijos. De esta manera, el aprendizaje específico para distinguir las clases `Normal` y `Abnormal` se realiza en el clasificador.

CatBoost se entrena minimizando la pérdida logarítmica binaria, *Logloss*. Esta función se encarga de comparar la etiqueta real de cada imagen con la probabilidad estimada por el modelo de pertenecer a dicha clase. Una probabilidad alta asignada a la clase correcta produce una pérdida pequeña, mientras que una predicción incorrecta realizada con mayor confianza recibe una penalización mayor. La pérdida incorpora los pesos de clase descritos en el apartado 3.5.3.

En la configuración de referencia, los pesos se calculan a partir del conjunto de en-

trenamiento exterior y se mantienen durante la búsqueda de hiperparámetros mediante validación cruzada. La selección de la configuración se realiza utilizando la *balanced accuracy* media de los cinco pliegues. Por tanto, se distingue entre la función que CatBoost minimiza durante el entrenamiento, *Logloss*, y la métrica utilizada para seleccionar los hiperparámetros. Una vez elegidos estos, se ajusta el clasificador final utilizando todo el conjunto de entrenamiento reservado.

Para evaluar el modelo se obtienen dos salidas complementarias. La función `predict` devuelve la etiqueta de clase asignada a cada imagen, utilizada para construir la matriz de confusión y calcular las métricas basadas en decisiones de clasificación. Por otra parte, `predict_proba` devuelve las probabilidades estimadas para ambas clases. La segunda columna corresponde a `Abnormal` y se utiliza como puntuación para calcular el área bajo la curva ROC (AUC-ROC).

3.6.2. Aumento de datos

Motivación El aumento de datos se ha planteado para estudiar si incorporar distintas orientaciones de un mismo parche durante el entrenamiento mejora la clasificación basada en un extractor congelado. Las rotaciones en múltiplos de 90° y las reflexiones horizontales y verticales se han utilizado como transformaciones básicas de aumento en patología computacional [22]. En este trabajo se asume que estas operaciones conservan la etiqueta del parche y se evalúa si proporcionar sus distintas representaciones a CatBoost mejora la clasificación.

Una imagen histopatológica no cuenta con una orientación específica como "la correcta". Un parche histopatológico puede observarse con diferentes orientaciones sin afectar a su clase, "arriba" y "abajo" no tienen significado aquí. Es decir, un parche de tejido rotado noventa grados o reflejado sigue siendo un parche de tejido igual de válido, y su diagnóstico no cambia. La invarianza a diferentes transformaciones a las que puede verse sometida una imagen es, por lo tanto, una propiedad que el clasificador debería poseer, es decir, debería ser capaz de predecir de forma correcta la clase para el parche a pesar de que este haya sido sometido a, por ejemplo, una rotación de su imagen. Es aquí donde se encuentra la motivación tras el experimento de aumento de datos.

EfficientNetV2-B0 puede producir vectores de características diferentes para un parche y su versión transformada. Como sus pesos permanecen congelados, el extractor no se

ajusta durante este experimento para reducir esas diferencias. El aumento de datos proporciona a CatBoost varias representaciones del mismo parche asociadas a una etiqueta común, de modo que pueda aprender a clasificarlas correctamente.

Transformaciones empleadas Se ha utilizado un conjunto dentro de ocho opciones de transformaciones diferentes sobre las imágenes. Este conjunto incluye la identidad (que equivale a la imagen original), las rotaciones de 90°, 180° y 270° y las imágenes invertidas en horizontal y vertical, y las combinaciones de cada una de estas imágenes invertidas sumándole un giro de 90°. Los giros se realizan en sentido antihorario y, en las operaciones combinadas, la imagen se invierte antes de rotarse.

Estas operaciones se aplican sobre la imagen RGB, antes del redimensionado y la normalización. Los giros de los múltiplos de 90° y la inversión de la imagen reordenan los píxeles del parche sin modificar sus valores ni introducir interpolación. Esto significa que cada píxel de la imagen transformada es un píxel de la original sin añadir una interpolación geométrica adicional. El redimensionado posterior a 224×224 píxeles sí utiliza interpolación, como en la configuración de referencia.

La Figura 3.2 muestra las ocho operaciones y permite observar cómo cambia la posición de las regiones del parche.

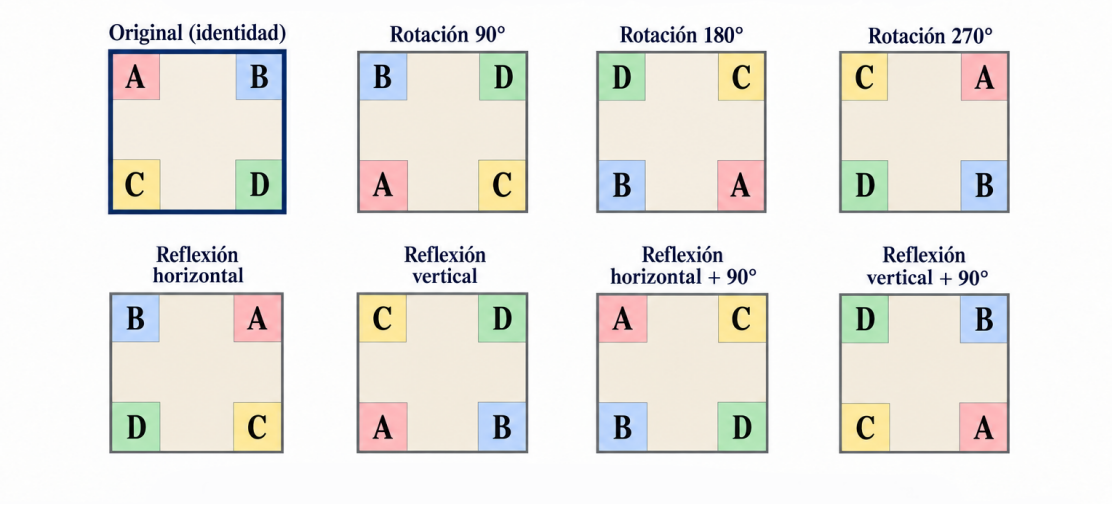


Figura 3.2.: Las ocho transformaciones empleadas sobre los parches

Para cada imagen se seleccionan aleatoriamente tres transformaciones distintas entre las siete diferentes de la identidad, sin reemplazamiento. Esto significa que una misma operación no se selecciona dos veces para el mismo parche. La imagen original se conserva por separado. Por tanto, cuando un parche se utiliza para ajustar CatBoost, aporta en total cuatro representaciones, una original y tres transformadas.

Las características de las vistas transformadas se almacenan en una matriz de dimensiones $N \times 3 \times 1280$, donde N es el número de imágenes de la colección correspondiente. El primer índice identifica el parche original, el segundo la vista transformada y el tercero la componente del vector de características.

La selección de transformaciones utiliza una semilla fija, distinta de las semillas empleadas para generar las particiones. Por lo tanto, las vistas seleccionadas son fijas y se reutilizan entre las búsquedas de hiperparámetros. No se generan nuevas transformaciones en cada iteración de CatBoost. Este diseño facilita repetir las comparaciones y logra un compromiso con respecto a los recursos y rendimientos.

Aplicación dentro del protocolo Lo más importante tras obtener las imágenes transformadas es definir dónde, en qué momento del proceso se aplicaría el aumento de los datos. Las características de las vistas transformadas se precalculan para todo el inventario de cada tamaño. Su incorporación al entrenamiento se realiza después, utilizando los índices de las particiones. En cada pliegue de validación cruzada, únicamente se añaden las vistas correspondientes a los parches utilizados para ajustar CatBoost. La validación se realiza con las características originales de sus propios parches.

De este modo, cada parche aporta sus vistas transformadas únicamente cuando se utiliza para ajustar el clasificador: si queda en el pliegue de validación, interviene solo con su representación original. La misma regla se aplica en el ajuste final, en el que las vistas se añaden a los parches del conjunto de entrenamiento, mientras que la evaluación sobre el conjunto de prueba emplea exclusivamente las representaciones originales. En la práctica, cada parche destinado al ajuste aporta cuatro filas a CatBoost, la original y sus tres vistas, y cada parche de validación o de prueba, una sola.

Esta separación es necesaria porque las vistas transformadas proceden del mismo parche y no constituyen observaciones independientes. Si una vista cayera en entrenamiento y otra vista del mismo parche en evaluación, el clasificador estaría siendo evaluado sobre una imagen que ya ha visto, y el resultado estaría contaminado por fuga de información.

En términos de coste, este diseño implica extraer características de $3 \times 245\,196 = 735\,588$ vistas transformadas, que junto con las 245.196 imágenes originales suman cerca de un millón de extracciones. Esta tarea se realiza una única vez y se almacena en caché, igual que la extracción original. La existencia de una caché que contiene vistas de todo el inventario no implica que todas ellas se utilicen para entrenar.

El experimento mantiene la búsqueda de 27 combinaciones de hiperparámetros de CatBoost y la validación cruzada de cinco pliegues. La configuración de referencia y la variante con aumento de datos seleccionan sus hiperparámetros por separado, utilizando el mismo espacio de búsqueda y criterio de selección. El tratamiento del desbalance se realiza mediante los pesos de clase descritos en el apartado 3.5.3.

La comparación con la configuración de referencia permite analizar si la incorporación de vistas transformadas durante el entrenamiento mejora el rendimiento de clasificación sobre los parches originales del conjunto de prueba.

3.6.3. Incorporación del módulo de atención CBAM

Del trabajo CoAtNeXt [24] procede la motivación para explorar mecanismos de atención en imágenes histopatológicas gástricas. En este experimento se conserva EfficientNetV2-B0 como extractor y se estudia el efecto de incorporar atención. No se reproduce la arquitectura completa de CoAtNeXt ni se comparan directamente sus resultados, debido a las diferencias entre ambos sistemas.

Las características obtenidas mediante el extractor preentrenado no se han optimizado específicamente para distinguir las clases `Normal` y `Abnormal` de GasHisSDB. Este experimento busca explorar si una ponderación aprendida de los canales y de las posiciones del mapa espacial produce una representación más adaptada a esta tarea, sin modificar los pesos del extractor, es decir, sin descongelar el *backbone*.

La segunda modificación experimental consiste, por tanto, en incorporar el módulo CBAM [23] entre el mapa de características producido por EfficientNetV2-B0 y la capa de *Global Average Pooling* (GAP). CBAM recibe un mapa de características $F \in \mathbb{R}^{1280\times7\times7}$, es decir, 1280 canales formados cada uno por una cuadrícula de 49 valores. Primero, la atención de canal calcula un peso para cada canal; después, la atención espacial calcula

un peso para cada posición de la cuadrícula. Ambas ponderaciones se aplican mediante multiplicación sobre las activaciones, de modo que modifican su magnitud antes de que GAP las resuma en el vector que recibe CatBoost, sin alterar las dimensiones del mapa.

Atención de canal La atención de canal determina qué canales deben conservar una mayor proporción de sus activaciones para cada imagen. Estos canales son representaciones internas producidas por EfficientNetV2-B0 (diferentes de los tres canales RGB de la imagen original). Sus respuestas pueden estar relacionadas con patrones de textura, color, bordes o formas.

Para resumir la información de cada canal, se calculan dos valores sobre sus 49 posiciones: la media y el máximo. La media resume el nivel general de activación, mientras que el máximo recoge la respuesta más elevada, aunque aparezca únicamente en una posición.

Dos mapas pueden contar con el mismo valor para la media, pero variar drásticamente en el valor máximo propio. Por ejemplo, considérense los siguientes canales simplificados:

$$F_1 = \begin{pmatrix} 2 & 2 \\ 2 & 2 \end{pmatrix}, \qquad F_2 = \begin{pmatrix} 0 & 0 \\ 0 & 8 \end{pmatrix}. \tag{3.2}$$

Ambos presentan una media igual a 2. Sin embargo, el máximo del primer canal es 2 y el del segundo es 8. Por tanto, el máximo permite identificar una activación intensa y localizada que no se ve reflejada si únicamente se emplease la media.

Al aplicar estas operaciones a los 1280 canales, se obtienen un vector de medias y otro de máximos, ambos de 1280 componentes.

$$\text{AvgPool}(F) \in \mathbb{R}^{1280}, \qquad \text{MaxPool}(F) \in \mathbb{R}^{1280}. \tag{3.3}$$

Los dos se procesan mediante la misma red de dos capas lineales, denominada MLP. El uso de parámetros compartidos significa que ambos vectores atraviesan las mismas capas, con los mismos coeficientes aprendidos.

La primera capa reduce la dimensión de 1280 a 80 componentes. A continuación, la función ReLU sustituye los valores negativos por cero y conserva los valores positivos. La segunda capa lineal produce los 1280 valores, uno por canal. Esta capa recupera la dimensión de entrada, pero no los valores originales.

Las salidas obtenidas a partir de la media y del máximo se suman. Después se aplica una función sigmoidea, que transforma cada resultado en un valor comprendido entre 0 y 1. La operación completa se expresa mediante:

$$M_c(F) = \sigma\left(\mathrm{MLP}(\mathrm{AvgPool}(F)) + \mathrm{MLP}(\mathrm{MaxPool}(F))\right), \tag{3.4}$$

donde $M_c(F)$ es el vector de atención de canal y σ representa la función sigmoidea. Su resultado contiene un peso para cada uno de los 1280 canales.

Por ejemplo, si dos canales reciben pesos de 0,9 y 0,2, el primero conserva el 90 % del valor de sus activaciones, mientras que el segundo conserva el 20 %. Estos valores no representan probabilidades de pertenecer a las clases `Normal` o `Abnormal`, lo que hacen es regular cuánto contribuye cada canal a la clasificación.

Cada peso se aplica a las 49 posiciones del canal correspondiente. El mapa resultante se denota mediante F':

$$F' = M_c(F) \odot F, \tag{3.5}$$

donde $\odot$ representa la multiplicación elemento a elemento. Aunque $M_c(F)$ contiene un único valor por canal, ese valor se aplica a toda su cuadrícula de 7×7. La operación modifica las activaciones, pero conserva las dimensiones originales $1280 \times 7 \times 7$.

Una vez entrenado el módulo, sus parámetros permanecen fijos durante la extracción, pero los pesos de atención pueden cambiar entre imágenes porque se calculan a partir de las activaciones de cada entrada.

La red de atención de canal contiene 206.160 parámetros: 102.480 en la primera capa lineal y 103.680 en la segunda. Aunque la MLP se aplica tanto al resumen medio como al máximo, sus parámetros se comparten y, por tanto, se contabilizan una sola vez.

Atención espacial La atención espacial se aplica sobre el mapa F' obtenido en la etapa anterior. Su objetivo es regular la contribución de las distintas posiciones espaciales. Mientras que la atención de canal aplica un peso a cada mapa completo, esta etapa calcula un peso para cada posición de la cuadrícula de 7×7.

Para ello, se obtienen la media y el máximo a lo largo de los 1280 canales en cada posición. Como resultado, se generan dos mapas de 7×7: uno contiene las medias y el otro los máximos.

Por ejemplo, si en una posición determinada tres canales simplificados presentan los valores 0,2, 0,7 y 0,9, la media de esa posición es 0,6 y su máximo es 0,9. El cálculo se repite en todas las posiciones de la cuadrícula.

Los dos mapas se concatenan como dos canales de una misma entrada, de dimensiones $2 \times 7 \times 7$. Esta entrada se procesa mediante una convolución con un núcleo de 7×7 y un único canal de salida. La convolución combina la información de ambos resúmenes y de sus posiciones vecinas. Se utiliza un relleno con ceros de tres posiciones en cada borde para conservar las dimensiones espaciales.

Una función sigmoidea transforma la salida en un mapa de pesos entre 0 y 1:

$$M_s(F') = \sigma\left(f^{7\times7}\left(\left[\mathrm{AvgPool}_c(F'); \mathrm{MaxPool}_c(F')\right]\right)\right), \tag{3.6}$$

donde $f^{7\times7}$ representa la convolución, los corchetes indican la concatenación y el subíndice c señala que los resúmenes se calculan a lo largo de los canales. El resultado $M_s(F')$ contiene 49 pesos, uno por posición espacial.

Este mapa se multiplica por F' para obtener la salida de CBAM:

$$F'' = M_s(F') \odot F'. \tag{3.7}$$

En esta operación, el peso de cada posición se aplica a los 1280 canales situados en ella. Por ejemplo, una posición con un peso de 0,8 conserva una proporción mayor de sus activaciones que otra con un peso de 0,2. La salida mantiene las dimensiones $1280 \times 7 \times 7$.

La ponderación espacial se aprende a partir de las etiquetas de clasificación. Por tanto, el mapa resultante no constituye por sí solo una segmentación del tejido ni una identificación de regiones tumorales.

La convolución espacial contiene 99 parámetros: 98 coeficientes, correspondientes a los dos canales de entrada y al núcleo de 7×7, y un sesgo. Junto con los parámetros de atención de canal, CBAM contiene un total de 206.259 parámetros entrenables.

Finalmente, sobre F'' se aplica GAP, que calcula el valor medio de cada canal y genera un vector de 1280 componentes. CatBoost recibe el mismo número de características que en la configuración de referencia, aunque sus valores han sido modificados por las dos etapas de atención.

Entrenamiento de CBAM mediante una cabeza temporal Para entrenar CBAM se añade un clasificador lineal temporal después de GAP. Este clasificador recibe el vector de 1280 características y produce dos puntuaciones, una para `Normal` y otra para `Abnormal`.

La función de pérdida compara estas puntuaciones con la etiqueta real de cada imagen. A partir del error calculado, se actualizan los parámetros de CBAM y del clasificador temporal para mejorar la clasificación. Durante este proceso, mientras que los pesos de EfficientNetV2-B0 permanecen congelados

El clasificador temporal permite tanto entrenar CBAM como evaluar su funcionamiento durante la validación. No forma parte del sistema final, ya que el clasificador utilizado en los resultados es CatBoost.

Para cada tamaño de parche y semilla, el módulo se entrena utilizando únicamente el 80 % reservado para entrenamiento. Dentro de ese conjunto se realiza una división interna estratificada: el 90 % de sus imágenes se emplea para actualizar los parámetros y el 10 % restante, para calcular la pérdida de validación que determina la parada temprana. Respecto al conjunto completo, equivale a un 72 % y un 8 %, mientras que el 20 % de prueba permanece al margen. Esta división es específica del entrenamiento de CBAM, la validación cruzada de CatBoost vuelve a emplear el 80 % completo.

La actualización de los parámetros se realiza mediante el optimizador Adam [29], con una tasa de aprendizaje de 0,001. Se utiliza entropía cruzada ponderada como función de pérdida para incorporar los pesos de clase. Las imágenes se procesan en lotes de hasta 64 ejemplos.

Se establece un máximo de 15 épocas, donde cada época corresponde a un recorrido completo por las imágenes de ajuste. Al finalizar cada época se calcula la pérdida sobre el conjunto de validación, sin actualizar parámetros con esas imágenes. También se aplica parada temprana (*early stopping*) con una paciencia de tres épocas. Cada vez que la pérdida de validación alcanza un nuevo mínimo, se guarda una copia de los parámetros

de CBAM. El entrenamiento se detiene tras tres épocas consecutivas sin mejora y, al finalizar, se recuperan los parámetros asociados a la menor pérdida de validación y se elimina el clasificador temporal.

CBAM contiene 206.259 parámetros y el clasificador temporal añade 2.562. Por tanto, durante esta fase se entrenan en total 208.821 parámetros que suponen un gasto de recursos considerable.

Con CBAM ya entrenado, las imágenes de cada tamaño se procesan mediante EfficientNetV2-B0, CBAM y GAP para obtener sus vectores de 1280 características. Estos vectores se almacenan para utilizarlos posteriormente en CatBoost. En esta extracción los parámetros de CBAM permanecen fijos. Finalmente, se seleccionan los hiperparámetros de CatBoost, se ajusta el clasificador y se evalúa sobre el conjunto de prueba, siguiendo el protocolo descrito anteriormente.

Integración en la validación cruzada CBAM se entrena una vez por tamaño de parche y semilla, antes de realizar la validación cruzada de CatBoost. En total, esto suma 15 entrenamientos diferentes de CBAM ya que son tres tamaños evaluados con cinco semillas.

Después se congela CBAM y se obtienen las características utilizadas en la validación cruzada de CatBoost. Por lo tanto, aunque las imágenes de validación de cada pliegue no se utilizan para ajustar CatBoost en esa ronda, sí han intervenido previamente en el aprendizaje o en la selección de los parámetros de CBAM.

Esto significa que la separación entre entrenamiento y validación se aplica al clasificador, pero no a todo el proceso de aprendizaje de las características. Para extenderla a ambas etapas, sería necesario entrenar un CBAM distinto dentro de cada pliegue, utilizando únicamente las imágenes de entrenamiento de ese pliegue.

Entrenar CBAM dentro de los cinco pliegues requeriría 75 entrenamientos durante la validación cruzada, además de los necesarios para los modelos finales. En el contexto de las limitaciones de recursos del entorno utilizado, se adoptó el entrenamiento previo por tamaño y semilla. Esta decisión reduce el número de ajustes, pero introduce la limitación metodológica descrita. La implementación y evaluación del procedimiento por pliegues se plantea como trabajo futuro.

La variante con CBAM se presenta como un experimento exploratorio. La validación cruzada permite seleccionar los hiperparámetros de CatBoost sobre las características obtenidas, pero no constituye una validación independiente de todo el proceso de aprendizaje, puesto que CBAM se entrena previamente a la formación de los pliegues.

El 20 % reservado para prueba queda excluido del ajuste supervisado de CBAM y CatBoost. Sin embargo, la estimación de las estadísticas de normalización antes del particionado y la ausencia de identificadores de paciente o imagen de origen impiden considerar esta evaluación como completamente independiente.

3.6.4. Robustez ante cambio de escala

Los dos experimentos anteriores buscan mejorar el rendimiento dentro de una resolución. Sin embargo, este busca estudiar el comportamiento de la configuración base entre resoluciones. Es decir, estudia el comportamiento cuando las imágenes de evaluación tienen dimensiones originales diferentes de las utilizadas para entrenar.

Por la información aportada por GasHisSDB se sabe que todos los parches de las diferentes resoluciones proceden de la misma colección de 600 imágenes de tejido, solo que recortadas a distintos tamaños. Se busca resolver una duda acerca de si un clasificador preparado para una resolución funcionaría a otra escala de parche.

Se consideran los seis pares ordenados de tamaños distintos entre 80, 120 y 160 píxeles. Para cada par, el primer tamaño corresponde a la resolución de origen y el segundo a la de destino. El procedimiento es el siguiente:

1. Se entrena CatBoost con el 80 % de los datos de la resolución de origen, utilizando los hiperparámetros seleccionados en la configuración de referencia para esa resolución y la semilla correspondiente.
2. Se obtienen las predicciones para las imágenes de la resolución de destino, sin volver a ajustar CatBoost con las etiquetas de estas imágenes.
3. Se repite el procedimiento con cada una de las cinco semillas.

Para evaluar el clasificador en el segundo tamaño de parche, se utilizan los vectores de características obtenidos mediante EfficientNetV2-B0. Antes de extraerlos, las imágenes

se redimensionan a 224×224 píxeles y se normalizan con la media y la desviación típica correspondientes al conjunto de datos de la segunda resolución del estudio.

Por ejemplo, al entrenar con parches de 80 píxeles y evaluar con parches de 160 píxeles, las imágenes de evaluación se normalizan utilizando las estadísticas de la colección de 160 píxeles. El clasificador CatBoost conserva lo aprendido en el primer tamaño, pero el preprocesamiento utiliza información sobre la distribución de las imágenes de destino.

La principal diferencia con respecto al experimento principal es que la evaluación se realiza sobre todas las imágenes del segundo tamaño, es decir, 146.651 para el caso de 80 píxeles, 65.261 para 120 píxeles y 33.284 para los de 160 píxeles. En la configuración base se evalúa únicamente sobre el 20 % reservado para prueba en cada uno de los tamaños.

Por tanto, los resultados de ambos experimentos se obtienen sobre conjuntos de evaluación distintos. Sus diferencias se utilizan para describir los cambios de rendimiento, pero no representan una comparación sobre exactamente las mismas imágenes.

3.6.5. Análisis de interpretabilidad

El último bloque experimental no persigue mejorar ninguna métrica, sino que se centra en realizar un análisis visual en busca de averiguar qué ha aprendido el sistema. Aborda la interpretabilidad, con el objetivo de explorar qué regiones del parche se relacionan con la decisión del clasificador. Para ello, se emplean dos aproximaciones: la visualización de los mapas de atención espacial de CBAM y el análisis de las contribuciones de las características mediante SHAP, acompañado de una proyección sobre la imagen. Ambas permiten explorar patrones asociados a las predicciones, aunque no constituyen por sí solas una validación de su relevancia histológica.

Visualización de los mapas de atención de CBAM Este apartado se centra en realizar un análisis visual específicamente de los pesos de atención del módulo CBAM. El análisis consiste en extraer el mapa de atención espacial producido por el módulo CBAM para imágenes previamente determinadas, redimensionarlo al tamaño del parche original y superponerlo como mapa de calor. Esta inspección resulta útil en aplicaciones médicas, donde interesa la transparencia y comprender el comportamiento del sistema ya que cometer errores en este campo conlleva riesgos muy severos.

Por lo tanto, el proceso empieza obteniendo el mapa de características del extractor para cada una de las imágenes seleccionadas y se aplica la atención de canal. A continuación, se calcula el mapa de atención espacial como la salida de la función sigmoidea de CBAM. Este mapa se redimensiona al tamaño del parche original mediante interpolación y se representa con una escala de color. Finalmente, para interpretarlo de forma visual se superpone a la imagen original mediante una opacidad del 50 %. La escala de color de los mapas se comparte entre los seis mapas de cada resolución. Esto facilita interpretar y comparar la intensidad entre diferentes imágenes.

Las imágenes que se escogen son ejemplos ilustrativos de cada clase y por cada resolución. Por lo tanto, se consigue un total de 18 imágenes, seis imágenes por tamaño, tres de ellas de clase `Normal` y tres de clase `Abnormal`. Estas imágenes son demostrativas, no se seleccionan bajo ningún criterio extra, son ejemplos.

Análisis del clasificador mediante SHAP y proyección espacial Los mapas de atención de CBAM permiten observar cómo el módulo pondera distintas posiciones de la representación. Sin embargo, no explican directamente cómo utiliza CatBoost las características para realizar la clasificación y predecir una u otra clase. Para estudiar este segundo aspecto, se incorpora un análisis mediante valores SHAP, aplicado tanto a la configuración de referencia como a la variante con CBAM.

SHAP permite explicar una predicción mediante contribuciones asignadas a las características de entrada [27]. En este trabajo, CatBoost recibe un vector de 1280 componentes y se calcula una contribución SHAP para cada una de ellas, es decir, cuánta importancia le da el clasificador a cada componente a la hora de realizar la clasificación. Estas contribuciones son específicas de cada imagen y describen cómo se descompone la salida del modelo respecto a un valor base.

Una contribución positiva aumenta la puntuación de `Abnormal` respecto al valor de referencia utilizado por SHAP, mientras que una contribución negativa la reduce. Estas cantidades se expresan en la escala de la salida del modelo anterior a su conversión en probabilidad, por lo que no deben interpretarse como porcentajes.

El cálculo se realiza mediante la opción `ShapValues` de CatBoost [30]. Para cada imagen se obtienen 1280 contribuciones y un valor base. La suma de las 1280 contribuciones más el valor base permite reconstruir la salida del clasificador anterior a su conversión

en probabilidad.

Estas contribuciones explican las características del vector, pero todavía no indican dónde se encuentran sus activaciones dentro de la imagen. Para explorar su distribución espacial, se recuperan los 1280 mapas de características anteriores a GAP, cada uno de tamaño 7×7. Aquí aparecen dos opciones y se utiliza una u otra según lo que se pretende analizar. En la configuración de referencia se utiliza la salida de EfficientNetV2-B0, mientras que para la variante con atención se utiliza la salida posterior a CBAM.

A continuación, cada mapa se multiplica por la contribución SHAP de su característica. Los mapas ponderados se suman y el resultado se divide entre las 49 posiciones espaciales. Este procedimiento es análogo a CAM [25], con las contribuciones SHAP en lugar de los pesos de la capa de salida, por lo que en adelante estas visualizaciones pueden verse denominadas como SHAP-CAM.

El resultado se considera una proyección espacial aproximada. Los valores SHAP ya representan contribuciones a la predicción y, al multiplicarlos por las activaciones, su magnitud vuelve a modificarse. Por tanto, la suma de las posiciones del mapa no coincide, en general, con la suma de las contribuciones SHAP originales. La linealidad de GAP no garantiza esa equivalencia.

El mapa se amplía al tamaño original del parche mediante interpolación cúbica y se superpone a la imagen con una opacidad del 50 %. Se emplea una escala de color centrada en cero donde los valores positivos aparecen en rojo, los negativos en azul y los próximos a cero en blanco.

Para generar las explicaciones se reutilizan los vectores de características almacenados y los hiperparámetros seleccionados en los experimentos anteriores. Con estos elementos se entrena de nuevo un clasificador CatBoost sobre la partición de entrenamiento correspondiente. Este procedimiento evita repetir la búsqueda de hiperparámetros, pero sí realiza un nuevo ajuste del clasificador. Una vez entrenado, se calculan los valores SHAP para las imágenes seleccionadas del conjunto de prueba.

En una primera fase se generaron seis visualizaciones por configuración y tamaño. Esta selección inicial permitió inspeccionar ejemplos concretos, sin buscar expresamente los errores ni las predicciones de mayor confianza. Posteriormente, se amplió el análisis

de SHAP-CAM mediante una selección estratificada para los parches de 160 píxeles.

En el análisis inicial, las seis visualizaciones de cada combinación de configuración y tamaño comparten una escala de color simétrica. Sus límites se calculan a partir del mayor valor absoluto de los mapas de ese grupo. La escala se establece de nuevo para cada combinación, por lo tanto, las intensidades de color no deben compararse directamente entre grupos diferentes.

Ampliación mediante muestreo estratificado La ampliación se realizó para los parches de 160 píxeles, utilizando la semilla 42 y las configuraciones de referencia y CBAM. Para cada variante se obtuvieron las probabilidades de clasificación de los 6657 parches de la partición de prueba.

Se mantuvo el umbral de decisión de 0,5 para asignar la clase. La confianza c de cada predicción se define como la probabilidad asignada a la clase predicha, es decir, $c = \max(p, 1 - p)$, donde p es la probabilidad estimada de `Abnormal`.

Se establecieron cuatro categorías:

- Aciertos de alta confianza: predicciones correctas con $c \geq 0{,}90$.
- Aciertos de baja confianza: predicciones correctas con $c < 0{,}70$.
- Falsos positivos: parches `Normal` clasificados como `Abnormal`.
- Falsos negativos: parches `Abnormal` clasificados como `Normal`.

Los aciertos con confianza intermedia, $0{,}70 \leq c < 0{,}90$, quedaron fuera del muestreo. Los falsos positivos y negativos se seleccionaron con independencia de su confianza.

Se extrajeron aleatoriamente, sin reemplazo, 12 parches de cada categoría. Se generaron así 48 mapas por variante. Las categorías se determinaron por separado para cada modelo, por lo que las selecciones no constituyen una comparación pareada sobre las mismas imágenes. Tampoco se impusieron cuotas por clase real dentro de las categorías de aciertos.

El análisis visual se centra en examinar conjuntamente el parche original, la proyección espacial, la clase real y la predicción del clasificador. La selección permite inspeccionar aciertos con distinto grado de confianza y ambos tipos de error. Las observaciones se interpretan como descripciones de los ejemplos examinados, sin atribuir a las regiones

coloreadas un significado histológico validado.

Cada variante empleó una escala de color simétrica compartida por sus 48 mapas. Las escalas se calcularon por separado para la referencia y CBAM, por lo que sus intensidades visuales no deben compararse directamente.

3.7. Evaluación

Durante la evaluación se considera clase positiva la clase `Abnormal` y negativa la clase `Normal`. Por lo tanto, un verdadero positivo es un parche `Abnormal` clasificado correctamente y un falso negativo es un parche `Abnormal` asignado de forma errónea a la clase `Normal`. Su complementario, un verdadero negativo representa a un parche de clase `Normal` correctamente identificado y un falso positivo a un parche de clase `Normal` clasificado erróneamente como `Abnormal`.

3.7.1. Métricas

A partir de la matriz de confusión, que se construye a su vez a partir de las etiquetas reales y predichas que devuelve el modelo, se pueden calcular las siguientes métricas: *accuracy*, sensibilidad, precisión, puntuación F1, especificidad, *balanced accuracy* y AUC-ROC, siguiendo las definiciones de la documentación de scikit-learn [31]. Estas métricas se utilizan como medida de rendimiento de los experimentos:

Exactitud (*accuracy*)

Mide la proporción de imágenes clasificadas correctamente respecto al total de imágenes predichas, considera tanto la clase `Normal` como la clase `Abnormal` para su cálculo.

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}.$$

Sensibilidad (*Recall*)

Mide la proporción de parches de la clase `Abnormal` que el modelo identifica correctamente. Evalúa la capacidad de detección de los casos positivos.

$$\text{Recall} = \frac{TP}{TP + FN}.$$

Precisión

Indica qué proporción de las imágenes clasificadas como `Abnormal` pertenece realmente a esa clase.

$$\text{Precisión} = \frac{TP}{TP + FP}.$$

F1

Es la media armónica entre la precisión y la sensibilidad. Resume ambas métricas en un único valor, es baja cuando alguna de ellas también lo es.

$$F_1 = 2\,\frac{\text{Precisión} \cdot \text{Recall}}{\text{Precisión} + \text{Recall}}.$$

F1 macro

Es la media aritmética de las puntuaciones F1 calculadas para cada clase, considerando en cada caso esa clase como positiva. A diferencia de la F1 de `Abnormal`, asigna el mismo peso a ambas clases.

$$F1_{\text{macro}} = \frac{F1_{\text{Normal}} + F1_{\text{Abnormal}}}{2}.$$

Especificidad

Mide la proporción de parches de la clase `Normal` que el modelo clasifica correctamente.

$$\text{Especificidad} = \frac{TN}{TN + FP}.$$

Exactitud equilibrada (*Balanced accuracy*)

Es la media de la sensibilidad y la especificidad. Asigna el mismo peso al rendimiento en ambas clases, con independencia de su frecuencia en el conjunto evaluado.

$$\text{Balanced accuracy} = \frac{\text{Recall} + \text{Especificidad}}{2}.$$

Además se reporta AUC-ROC, calculado sobre las probabilidades predichas y por tanto independiente del umbral de decisión.

Agrupación de repeticiones Para cada semilla, la validación cruzada se utiliza para seleccionar los hiperparámetros de CatBoost. A continuación, se ajusta el clasificador final sobre el conjunto de entrenamiento y se evalúa sobre el conjunto de prueba reservado. Esta evaluación proporciona un valor de cada métrica para esa semilla.

El procedimiento se repite en las cinco semillas. Las tablas de resultados presentan la media y la desviación típica de los cinco valores de prueba obtenidos para cada métrica, tamaño de parche y configuración. Estas cantidades se calculan entre semillas, no entre

los pliegues de validación cruzada. La desviación típica reportada mide, por tanto, la variabilidad entre repeticiones completas del experimento, que es la magnitud relevante para juzgar si una diferencia entre configuraciones es sólida.

Además, se conserva una matriz de confusión para cada semilla. Para facilitar la comparación entre configuraciones, en el capítulo de resultados se presentan los recuentos medios y los porcentajes normalizados por fila, promediados entre las cinco ejecuciones.

4. Resultados

Este capítulo, en el que se presentan los resultados obtenidos durante la exploración del conjunto de datos y la evaluación de los modelos, se divide en varios apartados: la sección 4.1, en la que se recogen los resultados del análisis exploratorio; las secciones 4.2, 4.3 y 4.4, donde se muestran los resultados de la configuración de referencia y de sus dos modificaciones, el aumento de datos y la incorporación de CBAM; la sección 4.5, en la que se evalúa la transferencia entre tamaños de parche; la sección 4.6, dedicada al análisis de interpretabilidad mediante los mapas de atención y los valores SHAP; y, finalmente, las secciones 4.7 y 4.8, en las que se analizan los errores de clasificación mediante las matrices de confusión y se comparan conjuntamente los resultados de todas las configuraciones.

4.1. Resultados del análisis exploratorio

La verificación de integridad confirmó que el inventario contiene 146.651 parches de 80 píxeles, 65.261 de 120 y 33.284 de 160. En total, suman las 245.196 imágenes descritas para GasHisSDB. La clase `Normal` contiene 148.120 ficheros y la `Abnormal` 97.076.

La proporción de imágenes de la clase `Abnormal` es del 40,33 % en los parches de 80 píxeles, del 38,00 % en los de 120 y del 39,43 % en los de 160. Por tanto, el desbalance de clases es similar en las tres resoluciones. Como muestra la Figura 4.1, el subconjunto de parches de 80 píxeles contiene el mayor número de imágenes, y la clase `Normal` es mayoritaria en los tres subconjuntos.

Por lo tanto, el conjunto de datos presenta un desbalance moderado, con aproximadamente un 60 % de imágenes de la clase `Normal` y un 40 % de la clase `Abnormal`. Un clasificador que asignara todas las imágenes a la clase mayoritaria alcanzaría un *accuracy* cercano al 60 %, pero su sensibilidad para la clase `Abnormal` sería nula. Por este motivo, en la evaluación se deben estudiar métricas sensibles al desbalance, el *accuracy* se interpreta junto con el *balanced accuracy*, la precisión, el *recall*, la especificidad, las

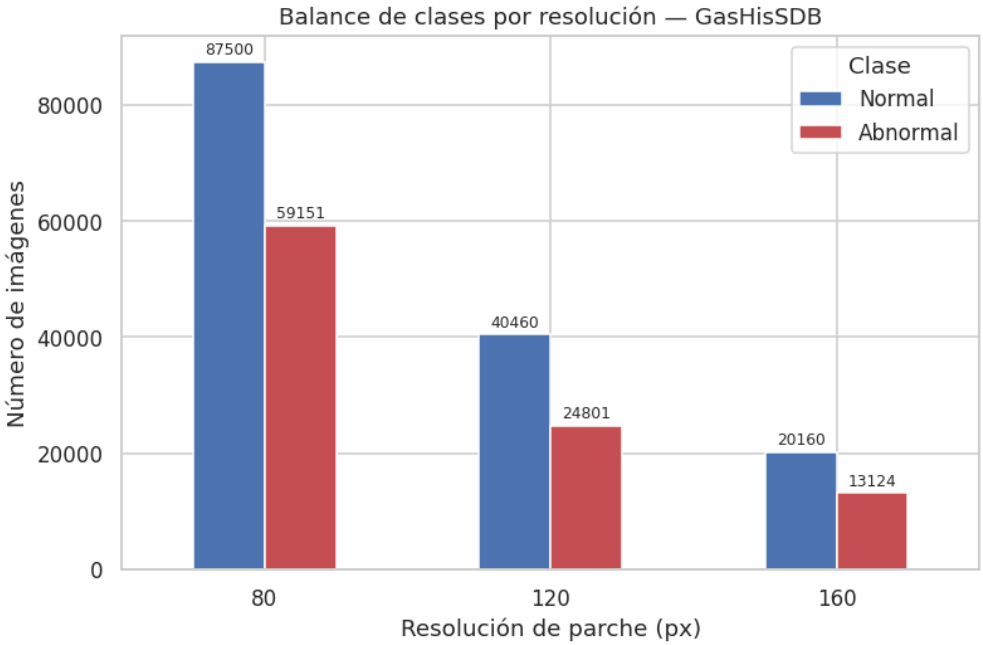


Figura 4.1.: Distribución de las imágenes de GasHisSDB por resolución y clase.

puntuaciones F1, el AUC-ROC y las matrices de confusión.

4.1.1. Aspecto de los parches

Con el objetivo de conocer y facilitar la comprensión de las diferentes estadísticas estudiadas y posteriormente expuestas sobre las imágenes con las que se trabaja, se muestran ejemplos de ambas clases en la Figura 4.2.

Las cuadrículas permiten observar una variación considerable en la intensidad, el tono y los patrones del tejido. Se aprecian fondos claros, zonas más densamente teñidas y patrones con distinta distribución espacial. Estos elementos justifican estudiar el preprocesamiento y las representaciones visuales, pero no basta para establecer un criterio de clasificación validado.

Esta exploración proporciona contexto visual y sirve como punto de partida para un análisis de calidad más exhaustivo.

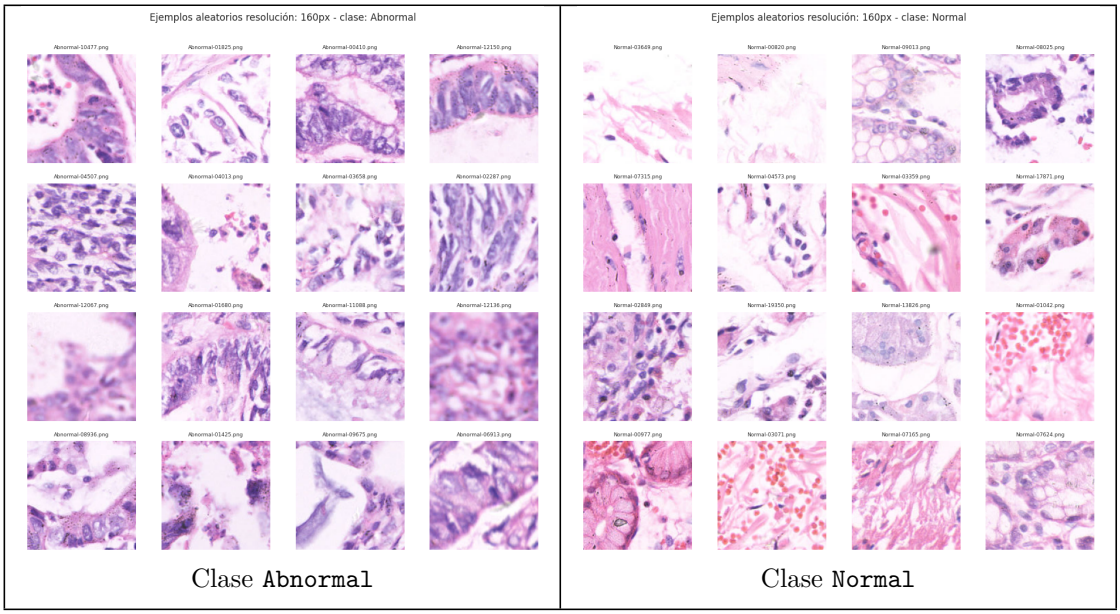


Figura 4.2.: Ejemplos aleatorios de parches de 160 píxeles para cada clase

4.1.2. Estadísticos de intensidad

Los estadísticos de intensidad se calcularon sobre una muestra estratificada de 5.000 imágenes por tamaño de parche, con intensidades reescaladas al intervalo $[0, 1]$. La Tabla 4.1 recoge la media y la desviación típica por canal, considerando conjuntamente los píxeles de las imágenes muestreadas. La comparación entre clases, basada en la intensidad media de cada imagen, se presenta en el apartado 4.1.3.

Tabla 4.1.: Media y desviación típica de las intensidades de los píxeles por canal RGB.

Tamaño (píxeles)	**Media R / G / B**	**Desviación R / G / B**
80	0,9019 / 0,7846 / 0,9066	0,1276 / 0,1786 / 0,0993
120	0,9035 / 0,7863 / 0,9070	0,1262 / 0,1778 / 0,0995
160	0,9041 / 0,7873 / 0,9079	0,1259 / 0,1774 / 0,0983

La comparación de las intensidades medias por imagen entre clases se presenta en el apartado 4.1.3.

Considerando que los valores pueden variar únicamente dentro del rango de valores entre 0 y 1, se puede afirmar que las medias tienen valores elevados en los tres canales, particularmente en los canales rojo y azul, lo que reafirma el predominio de fondo claro señalado en la inspección visual. Asimismo, los valores resultan muy similares entre las

tres resoluciones, lo que constituye una evidencia adicional de que los tres subconjuntos proceden de la misma colección de tejido y no de muestras independientes.

4.1.3. Diferencias cromáticas entre clases

La Tabla 4.2 recoge la media y la desviación típica de las intensidades medias por imagen, desglosadas por clase, canal y tamaño de parche. La tabla revela que los parches de la clase `Abnormal` presentan una intensidad media inferior a los de la clase `Normal` en los tres canales y de forma consistente en los tres tamaños.

Tabla 4.2.: Media y desviación típica de las intensidades medias por imagen en cada canal RGB, desglosadas por clase y tamaño de parche. Intensidades reescaladas al intervalo $[0, 1]$, calculadas sobre una muestra estratificada de 5.000 imágenes por tamaño.

		R		**G**		**B**	
Subconjunto	**Clase**	Media	D. T.	Media	D. T.	Media	D. T.
80	Normal	0,9276	0,0556	0,8136	0,0967	0,9171	0,0501
	Anómala	0,8639	0,0553	0,7418	0,0802	0,8912	0,0393
120	Normal	0,9267	0,0520	0,8127	0,0913	0,9162	0,0483
	Anómala	0,8658	0,0493	0,7434	0,0727	0,8920	0,0357
160	Normal	0,9280	0,0507	0,8139	0,0879	0,9173	0,0446
	Anómala	0,8675	0,0466	0,7464	0,0687	0,8934	0,0336

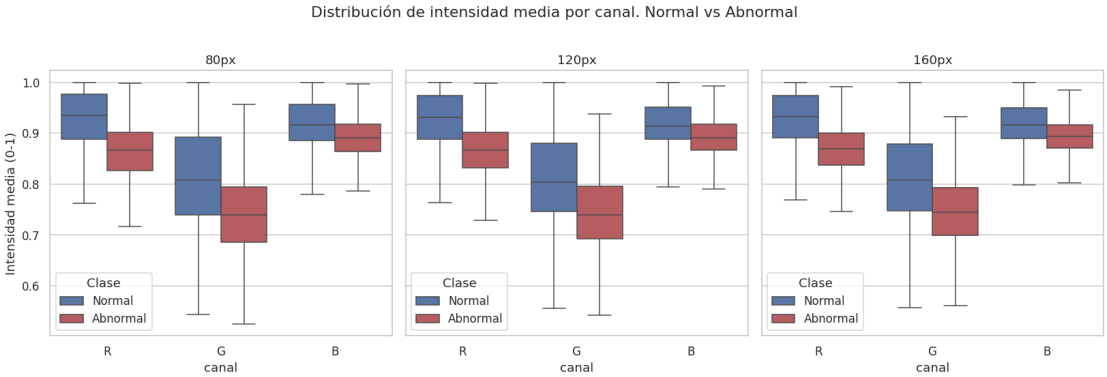


Figura 4.3.: Distribución de la intensidad media por imagen en los canales RGB, desglosada por clase y resolución de parche.

Las diferencias de intensidad media entre clases mantienen el mismo signo en los tres tamaños de parche: la clase `Abnormal` presenta valores inferiores a la clase `Normal`. La mayor diferencia absoluta se observa en el canal verde, seguida del rojo y del azul.

Los diagramas de cajas de la Figura 4.3 muestran solapamiento entre las distribuciones de ambas clases en cada canal. Por tanto, las diferencias entre sus medias no implican una separación completa de los valores individuales.

Una explicación posible de este patrón guarda relación con la propia morfología del tejido. Los parches de tejido anómalo presentan habitualmente una mayor celularidad y densidad nuclear que los de tejido normal, lo que implica una menor proporción de fondo claro dentro del parche y, en consecuencia, una intensidad media inferior. Bajo esta interpretación, la diferencia cromática observada no constituiría un artefacto del proceso de digitalización, sino un reflejo indirecto de una propiedad histológicamente relevante.

No obstante, esta observación obliga a matizar la interpretación del rendimiento del sistema. La existencia de una señal cromática global discriminatoria implica que parte de la capacidad predictiva del clasificador podría apoyarse en la intensidad agregada del parche, y no exclusivamente en la organización morfológica del tejido. Dado que ambas propiedades están correlacionadas por la razón expuesta, no resulta posible con el diseño empleado determinar en qué medida contribuye cada una.

Esta consideración guarda relación con los resultados del análisis de interpretabilidad si una parte relevante de la información discriminatoria reside en una propiedad global del parche antes que en regiones concretas de este, cabría esperar que un mecanismo de atención espacial encontrara escaso margen para discriminar entre posiciones, que es precisamente el comportamiento observado.

4.1.4. Similitud perceptual y duplicados

Como se explicó anteriormente, el análisis se realizó en dos etapas complementarias. En primer lugar, se exploró la similitud perceptual sobre una muestra de 10.000 imágenes por cada resolución. Posteriormente, se comprobó la existencia de imágenes con contenido RGB idéntico sobre todo el contenido del *dataset*.

La búsqueda identificó 68, 8 y 5 parejas con una distancia de Hamming entre sus *hashes* perceptuales menor o igual que cinco para los tamaños de 80, 120 y 160 píxeles, respectivamente. De estas parejas, 55, 4 y 3 presentaban una distancia igual a cero, es decir, *hashes* idénticos. Los resultados incluyen la distancia igual a cero y se pueden observar en la Tabla 4.3.

Tabla 4.3.: Similitud perceptual

Tamaño (píxeles)	**Parejas $d = 0$**	**Parejas $d \leq 5$**	**Imágenes implicadas**	**Muestra (%)**
80	55	68	24	0,24
120	4	8	10	0,10
160	3	5	7	0,07

Las imágenes implicadas representan el 0,24 %, el 0,10 % y el 0,07 % de las muestras por tamaño. El número de parejas puede superar al de imágenes implicadas, ya que un mismo parche puede participar en varias parejas. Por ejemplo, cuatro imágenes cuyos *hashes* coinciden todas entre sí, acabarían generando seis parejas de coincidencias, a pesar de que solo haya cuatro imágenes implicadas.

Estos resultados describen similitudes entre las huellas perceptuales de las imágenes, pero no confirman la igualdad exacta de las imágenes. Por este motivo, se complementó la exploración con una búsqueda sobre todas las imágenes de cada tamaño, agrupándolas mediante sus dimensiones y una huella de sus píxeles RGB. Entonces, se procedió a comparar y comprobar directamente la igualdad de su contenido.

La búsqueda de duplicados exactos identificó por una parte, un grupo de duplicados formado por 137 imágenes de 80×80 píxeles, además de encontrar 23 imágenes con respecto a la colección de 120×120 píxeles. Por último, en la colección 160×160 píxeles no se identificaron duplicados exactos. La Tabla 4.4 recoge estos resultados.

Todas las imágenes de los dos grupos pertenecían a la clase `Normal`, sin coincidencias exactas entre etiquetas diferentes. Además, la inspección de sus píxeles confirmó que eran imágenes completamente blancas, con todos sus píxeles en valores RGB $(255, 255, 255)$. Por tanto, los duplicados detectados correspondían a parches sin contenido tisular visible, y no a repeticiones de estructuras histopatológicas.

Tabla 4.4.: Duplicados exactos identificados en la totalidad de las imágenes de los datos disponibles. Las copias adicionales se calculan conservando conceptualmente una imagen por grupo.

Tamaño (píxeles)	**Grupos**	**Imágenes implicadas**	**Copias adicionales**
80	1	137	136
120	1	23	22
160	0	0	0
Total	**2**	**160**	**158**

La presencia de tres parejas con *hash* perceptual coincidente en la muestra de 160 píxeles no contradice la ausencia de duplicados exactos en esa colección. Dos imágenes pueden compartir una representación de su resumen sin tener los mismos píxeles. Además, los recuentos de ambos análisis no son directamente comparables: el primero se realizó sobre una muestra y contabilizó parejas, mientras que el segundo fue mucho más profundo y examinó toda la colección y contabilizó grupos de imágenes idénticas.

Por último, no se puede garantizar la independencia entre los parches sin conocer su relación con su WSI o imagen original. Imágenes con píxeles diferentes pueden proceder de regiones próximas de una misma imagen de tejido, por lo que se mantiene la limitación asociada a la falta de identificadores de origen.

4.1.5. Recuperación de la procedencia de los parches

Uno de los hallazgos del análisis exploratorio con mayores consecuencias para el diseño experimental fue la imposibilidad de recuperar la procedencia de los parches a partir de los identificadores disponibles. Los nombres de archivo siguen una estructura formada por la clase y un índice numérico, que se repite en los tres tamaños. Sin embargo, esta numeración no proporciona un vínculo con la imagen original de los parches, el paciente o la posición del recorte.

Los autores de GasHisSDB indican que, durante la preparación del conjunto se alteró el orden de las imágenes de toda la base de datos, con el propósito de reducir la correlación entre recortes procedentes de una misma imagen original [3]. Esta descripción, junto con la ausencia de identificadores de origen en el inventario analizado, impide utilizar la numeración de los archivos como criterio fiable para reconstruir su procedencia.

Como consecuencia, las divisiones de entrenamiento y prueba se realizaron a nivel de

parche, sin poder garantizar que todos los recortes de una misma imagen original quedaran exclusivamente en una de ellas.

Esta circunstancia introduce el riesgo de que parches de regiones próximas del mismo tejido aparezcan tanto en entrenamiento como en evaluación. Aunque sus píxeles sean diferentes, pueden compartir características de tinción, textura o patrones que faciliten su clasificación. El barajado modifica el orden de las imágenes, pero no garantiza que desaparezca esa dependencia. Por ello, las métricas obtenidas podrían resultar optimistas respecto al rendimiento sobre muestras de pacientes no representados en el entrenamiento. Se ha encontrado entonces, durante el análisis exploratorio, una restricción de los datos disponibles que condiciona la interpretación de los resultados.

4.2. Resultados de clasificación de la configuración de referencia

La Tabla 4.5 recoge los resultados de la configuración con EfficientNetV2-B0 congelado y CatBoost diferenciando el rendimiento para cada tamaño de parche.

Tabla 4.5.: Resultados de la configuración de referencia por tamaño de parche. Media ± desviación típica de las cinco ejecuciones

Métrica	**80 píxeles**	**120 píxeles**	**160 píxeles**
Accuracy	89,64 ± 0,15	92,24 ± 0,17	93,24 ± 0,11
Balanced Accuracy	89,63 ± 0,14	92,10 ± 0,19	93,04 ± 0,13
Precisión Abnormal	85,42 ± 0,26	88,48 ± 0,41	90,87 ± 0,37
Sensibilidad Abnormal	89,61 ± 0,22	91,50 ± 0,44	92,11 ± 0,40
Especificidad	89,66 ± 0,22	92,69 ± 0,31	93,97 ± 0,28
F1 Abnormal	87,46 ± 0,17	89,96 ± 0,22	91,48 ± 0,14
F1 macro	89,31 ± 0,15	91,82 ± 0,18	92,94 ± 0,12
AUC-ROC	96,26 ± 0,04	97,63 ± 0,10	98,21 ± 0,07

En la configuración de referencia, se observa un patrón de crecimiento del rendimiento conforme aumenta también el tamaño de los parches, empieza alcanzando una media del 89,64 % en 80 píxeles, avanza a 92,24 % en 120 y del 93,24 % en 160. La diferencia entre las dos resoluciones de los extremos es notable, muy superior a la dispersión entre

semillas, por lo que se trata de un efecto remarcable. Sin embargo, esta comparación no permite atribuir la mejora exclusivamente al tamaño del parche: también cambian el contexto visual, el factor de ampliación hasta 224×224 píxeles y la cantidad y composición de las imágenes disponibles.

Con respecto al *balanced accuracy* sigue el mismo orden de mejora con el aumento de resolución, con 89,63 %, 92,10 % y 93,04 % respectivamente. La proximidad de ambas métricas indica que los resultados no se explican únicamente por el peso de la clase mayoritaria.

La sensibilidad de `Abnormal` aumenta del 89,61 % al 92,11 % entre 80 y 160 píxeles. La especificidad pasa del 89,66 % al 93,97 %. La mejora observada afecta, por tanto, a ambas clases, aunque en los tamaños mayores la especificidad supera a la sensibilidad. La precisión de `Abnormal` es inferior a su sensibilidad en las tres condiciones: 85,42 % frente a 89,61 % en 80, 88,48 % frente a 91,50 % en 120 y 90,87 % frente a 92,11 % en 160. Esto indica que la proporción de aciertos entre las señales positivas es menor que la proporción de parches `Abnormal` detectados.

4.2.1. Variabilidad y selección de hiperparámetros

La desviación típica del accuracy es de 0,15, 0,17 y 0,11 puntos porcentuales para 80, 120 y 160 píxeles. La dispersión entre las cinco ejecuciones es reducida, aunque se refiere a particiones de una misma colección. Las métricas de cada ejecución se recogen en el Anexo B.

Todas las semillas de la configuración de referencia seleccionan como mejor opción las 700 iteraciones. En 80 píxeles se repite la combinación de tasa 0,2 y profundidad 6. La resolución de 120 aporta más variabilidad, con profundidades principalmente de 6 y tasas de 0,1 o 0,2. Finalmente, en la resolución de 160 píxeles la tasa seleccionada es 0,1 y las profundidades se reparten entre 6 y 8. La Tabla B.3 del de la Sección B.3 del Anexo B recoge la combinación elegida en cada ejecución.

Las configuraciones seleccionadas utilizan 700 iteraciones, el mayor valor incluido en la búsqueda. Este resultado motiva explorar valores superiores en futuros experimentos, para comprobar si aportan una mejora adicional o si el rendimiento se estabiliza. Sin embargo, afirmar que mejoraría si se aumentasen más las iteraciones sería un error. No

se puede determinar y afirmar con los datos disponibles.

4.3. Resultados del experimento de aumento de datos

En esta sección se analizan y aportan los resultados obtenidos en el experimento de aumento de datos. Incorporar tres vistas transformadas por cada imagen en el entrenamiento aumenta el rendimiento hasta 90,76 %, 93,19 % y 94,38 % para las resoluciones 80, 120 y 160 píxeles. Los resultados se recogen en la Tabla 4.6.

Tabla 4.6.: Resultados del experimento de aumento de datos por tamaño de parche.

Métrica	**80 píxeles**	**120 píxeles**	**160 píxeles**
accuracy	90,76 ± 0,17	93,19 ± 0,13	94,38 ± 0,27
Balanced accuracy	90,76 ± 0,15	93,07 ± 0,14	94,22 ± 0,28
Precisión Abnormal	86,91 ± 0,37	89,84 ± 0,36	92,40 ± 0,49
Sensibilidad Abnormal	90,77 ± 0,15	92,55 ± 0,35	93,44 ± 0,48
Especificidad	90,76 ± 0,30	93,58 ± 0,27	95,00 ± 0,35
F1 Abnormal	88,80 ± 0,19	91,18 ± 0,17	92,92 ± 0,33
F1 macro	90,47 ± 0,17	92,82 ± 0,14	94,13 ± 0,28
AUC-ROC	96,95 ± 0,09	98,18 ± 0,05	98,68 ± 0,07

4.3.1. Comparación con la configuración de referencia

La Tabla 4.7 muestra las diferencias entre las medias del experimento con aumento de datos y las de la configuración de referencia. Las diferencias se calcularon a partir de los valores guardados (antes de redondearlos para su presentación en tablas previas). El *accuracy* mejora en 1,13, 0,95 y 1,14 puntos porcentuales para los tamaños de 80, 120 y 160 píxeles, respectivamente.

El *balanced accuracy* mejora hasta 90,76 %, 93,07 % y 94,22 %. También aumentan la precisión, la sensibilidad, F1 y el AUC-ROC en los tres tamaños. El efecto no se limita, por tanto, a aumentar los aciertos de la clase mayoritaria a costa de la minoritaria.

En 80 píxeles, la sensibilidad aumenta aproximadamente 1,16 puntos porcentuales y la precisión 1,49. En 120 píxeles, la mejora de sensibilidad es de 1,05 puntos porcentua-

Tabla 4.7.: Mejora del aumento de datos respecto a la configuración de referencia.

Métrica	**80 píxeles**	**120 píxeles**	**160 píxeles**
Accuracy	+1,13	+0,95	+1,14
Balanced accuracy	+1,13	+0,97	+1,18
Precisión `Abnormal`	+1,49	+1,37	+1,53
Sensibilidad `Abnormal`	+1,16	+1,05	+1,33
Especificidad	+1,10	+0,89	+1,02
F1 `Abnormal`	+1,34	+1,22	+1,43
F1 macro	+1,15	+1,00	+1,19
AUC-ROC	+0,69	+0,55	+0,47

les y la de precisión de 1,37. En 160 píxeles, las diferencias son de 1,33 y 1,53 puntos porcentuales, respectivamente. El patrón es compatible con una representación de entrenamiento más tolerante a cambios de orientación, aunque no demuestra invarianza completa.

4.3.2. Consistencia de las mejoras

En los tres tamaños, las cinco semillas presentan un *accuracy* mayor con aumento que con la configuración de referencia. La mejora es consistente en dirección y moderada en magnitud. En 160 píxeles, la desviación del *accuracy* aumenta de 0,11 a 0,27 puntos porcentuales, de modo que la mayor media no implica una reducción uniforme de variabilidad. En 120 la dispersión del aumento es algo menor que la de la referencia, mientras que en 80 resulta ligeramente superior. El experimento muestra que se puede mejorar la clasificación sin actualizar el extractor. Sin embargo, añade almacenamiento y filas al ajuste de CatBoost.

4.4. Resultados del experimento CBAM

En esta sección se presentan los resultados obtenidos en la configuración con atención. Este experimento alcanza valores en las medias de 91,80 %, 93,46 % y 94,70 % para las resoluciones 80, 120 y 160 píxeles. Los resultados se recogen en la Tabla 4.8 donde se recoge el efecto que tiene incorporar al sistema el módulo de atención.

Tabla 4.8.: Resultados del experimento CBAM por tamaño de parche.

Métrica	**80 píxeles**	**120 píxeles**	**160 píxeles**
Accuracy	91,80 ± 0,04	93,46 ± 0,44	94,70 ± 0,17
Balanced accuracy	91,82 ± 0,03	93,28 ± 0,45	94,51 ± 0,21
Precisión Abnormal	88,22 ± 0,23	90,45 ± 0,74	92,96 ± 0,16
Sensibilidad Abnormal	91,94 ± 0,21	92,56 ± 0,57	93,65 ± 0,39
Especificidad	91,70 ± 0,20	94,01 ± 0,50	95,38 ± 0,11
F1 Abnormal	90,04 ± 0,03	91,49 ± 0,57	93,30 ± 0,23
F1 macro	91,53 ± 0,04	93,09 ± 0,47	94,46 ± 0,18
AUC-ROC	97,57 ± 0,03	98,31 ± 0,25	98,82 ± 0,06

Para los tamaños de parche de 80, 120 y 160 píxeles, la sensibilidad de la clase `Abnormal` alcanza el 91,94 %, el 92,56 % y el 93,65 %, respectivamente, mientras que la especificidad es del 91,70 %, el 94,01 % y el 95,38 %. En el mismo orden, el *balanced accuracy* alcanza el 91,82 %, el 93,28 % y el 94,51 %. En los tres tamaños, las medias de sensibilidad y especificidad superan las de la configuración de referencia, lo que indica una mejora tanto en la detección de parches anómalos como en la identificación de parches normales.

4.4.1. Comparación con experimentos previos

Entre las tres configuraciones, CBAM obtiene la mayor media observada entre las tres configuraciones en cada tamaño. Con respecto a la referencia base las diferencias son de 2,16, 1,22 y 1,46 puntos porcentuales. Además, en 80 píxeles, CBAM supera al aumento en las cinco semillas. En 120 lo supera en tres, queda por debajo en una y empata exactamente en otra. En 160 presenta cuatro mejoras y un descenso. La ventaja no es, por tanto, igual de uniforme en los tres tamaños.

El mayor incremento de F1 de `Abnormal` aparece en 80 píxeles, donde pasa de 87,46 % a 90,04 %. En 120 aumenta de 89,96 % a 91,49 % y en 160 de 91,48 % a 93,30 %. El resultado sugiere que la adaptación supervisada de la representación puede ser especialmente útil en el tamaño más pequeño dentro de las condiciones estudiadas.

Es notable la sensibilidad en la resolución 120 que obtiene valores prácticamente iguales

a la obtenida con aumento de datos: 92,56 % frente a 92,55 %. Por lo tanto, en este tamaño de parche la mejora de CBAM va asociada principalmente a la especificidad y precisión, sin un incremento apreciable de sensibilidad.

4.5. Resultados de la evaluación entre tamaños

La Tabla 4.9 recoge el *accuracy* obtenido al entrenar con el tamaño de origen indicado en cada fila y evaluar en el tamaño de destino indicado en cada columna. Se está evaluando sobre la configuración de referencia. Las celdas diagonales contienen la referencia dentro de tamaño para facilitar la lectura, aunque su conjunto de evaluación es el 20 % reservado. Las celdas fuera de la diagonal corresponden a todas las imágenes del destino.

Tabla 4.9.: *Accuracy* entre tamaños de parche.

Origen / Destino	**80 píxeles**	**120 píxeles**	**160 píxeles**
80 píxeles	89,64 ± 0,15	89,40 ± 0,09	85,28 ± 0,32
120 píxeles	78,73 ± 0,44	92,24 ± 0,17	90,49 ± 0,09
160 píxeles	67,38 ± 0,42	83,41 ± 0,26	93,24 ± 0,11

El mejor resultado fuera de la diagonal es el caso donde se entrena con resolución 120 y se evalúa sobre 160 píxeles, con 90,49 ± 0,09 %. La transferencia de 80 a 120 obtiene 89,40 ± 0,09 %. En cambio, el peor resultado de este experimento se le atribuye al caso de entrenar con 160 y evaluar con 80 reduce el *accuracy* hasta 67,38 ± 0,42 %.

En la tabla se puede observar una asimetría entre los pares de tamaños. Entrenar en la resolución menor y evaluar en las mayores conserva mucho más rendimiento que la operación inversa. Un modelo entrenado sobre parches de 80 píxeles mantiene un comportamiento razonable al evaluarse sobre parches de 120 y 160, mientras que un modelo entrenado sobre parches de 160 píxeles se degrada de forma mucho más acusada al enfrentarse a parches de 80.

4.6. Resultados de la interpretabilidad

El análisis de interpretabilidad se aborda desde dos enfoques. En primer lugar, se examinan los mapas de atención espacial de CBAM para observar cómo se ponderan

las distintas posiciones de los mapas de características. A continuación, se analizan las contribuciones SHAP de las características utilizadas por CatBoost y su proyección espacial sobre los parches, tanto en la configuración de referencia como en la variante con CBAM.

4.6.1. Mapas de CBAM sobre parches de tejido

Se han conservado 18 visualizaciones, correspondientes a tres ejemplos de cada clase en cada tamaño. En todos ellos se observa una zona central de atención elevada y variaciones próximas a algunos bordes. Las Figuras 4.4, 4.5 y 4.6 muestran un ejemplo anómalo y uno normal para cada tamaño de parche.

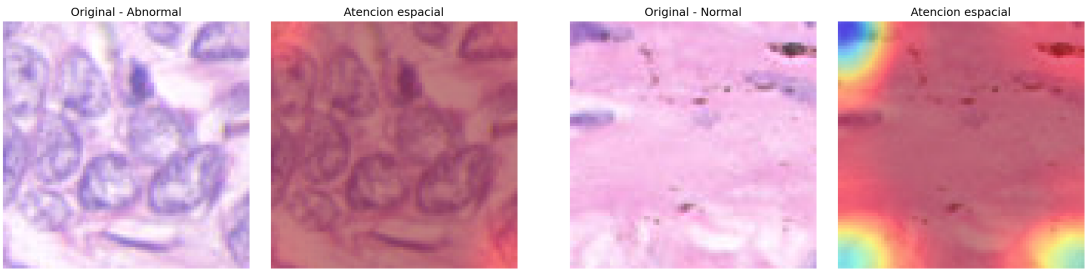


Figura 4.4.: Mapas de atención espacial de CBAM sobre parches de 80 píxeles: `Abnormal` izquierda y `Normal` derecha.

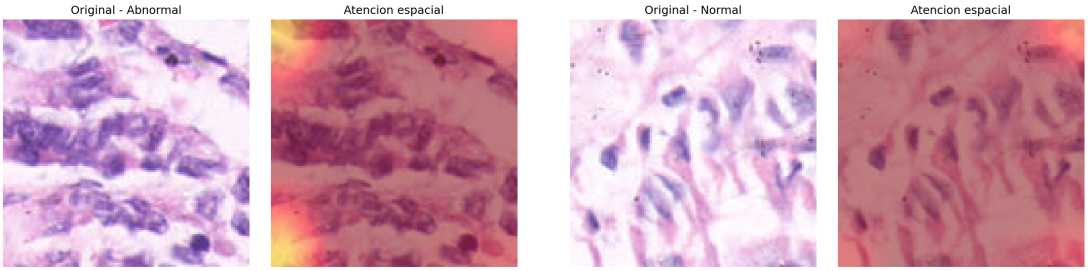


Figura 4.5.: Mapas de atención espacial de CBAM sobre parches de 120 píxeles: `Abnormal` izquierda y `Normal` derecha.

Las superposiciones de atención espacial muestran patrones amplios, con variaciones visibles próximas a algunos bordes. En los ejemplos presentados no se observa una delimitación precisa de las estructuras del tejido. Por ello, estas visualizaciones permiten describir la ponderación espacial del módulo, pero no identificar por sí solas las regiones que determinan la clasificación. Tras realizar un diagnóstico numérico se encuentran

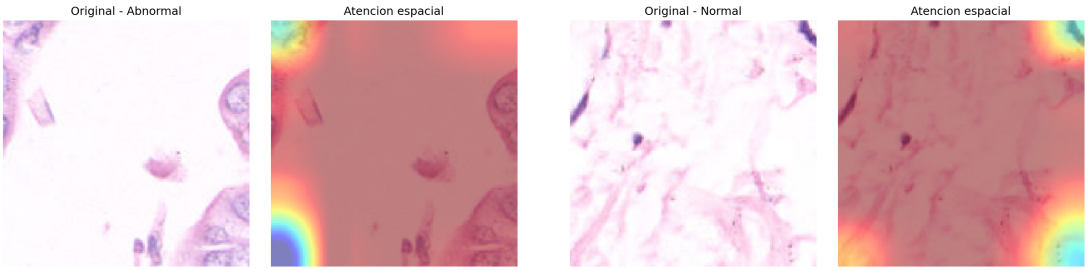


Figura 4.6.: Mapas de atención espacial de CBAM sobre parches de 160 píxeles: `Abnormal` izquierda y `Normal` derecha.

para los ejemplos de 160 píxeles amplitudes de atención entre 0,0076 y 0,0469 y máximos redondeados a 1,0000. Estos valores son compatibles con una sigmoidea próxima a saturación la cual cuenta con una capacidad limitada de discriminación espacial en esos ejemplos.

Una amplitud reducida implica que las posiciones reciben pesos muy parecidos. Al reescalar ese intervalo para dibujar el mapa, pequeñas diferencias pueden producir contrastes intensos. Por ello, las figuras no bastan para afirmar que el modelo delimita estructuras relevantes ni para cuantificar una explicación de su predicción.

Con estos resultados, la explicación más plausible tiene relación con la naturaleza de las imágenes. En los parches histopatológicos teñidos una parte considerable de la imagen está ocupada por fondo claro y por tejido con posible aspecto homogéneo entre clases. Sería lo contrario a un retrato, donde existe un objeto de interés rodeado de contexto irrelevante y la atención espacial tiene un blanco evidente, aquí la información diagnóstica está distribuida por toda la imagen. Otra teoría planteada está la resolución de los parches, al tener tamaños comprendidos entre 80 y 160 píxeles puede que imposibilite contar con todo un objeto de interés contenido por completo dentro del parche como para que el módulo de atención lo detecte.

Además, los pesos de atención describen una operación interna de CBAM, pero no cuantifican directamente la contribución de cada característica a la predicción final de CatBoost. Para estudiar esta relación se amplió el análisis mediante valores SHAP y su proyección espacial sobre las imágenes.

4.6.2. Mapas del análisis de las predicciones mediante SHAP

Cómo se leen estas visualizaciones El análisis de interpretabilidad se amplía mediante valores SHAP, que expresan la salida del modelo a partir de las contribuciones de sus características de entrada [27, 30]. En este trabajo, esas características son las 1280 componentes del vector que recibe CatBoost. A partir de sus contribuciones se construye una proyección espacial aproximada sobre el parche, que permite acercarse al objetivo de estas visualizaciones: observar qué zonas de cada parche se relacionan con la decisión del clasificador. El procedimiento se aplica tanto a la configuración de referencia como a la variante con CBAM.

En los mapas, el rojo representa valores positivos de la proyección, es decir, contribuciones a favor de la clase `Abnormal`; el azul, valores negativos, a favor de `Normal`; y el blanco, valores próximos a cero. Estos valores proceden de una proyección aproximada y no representan probabilidades ni contribuciones exactas de cada píxel. La escala de color se calcula por separado para cada combinación de configuración y tamaño de parche, por lo que las intensidades no deben compararse entre grupos. La Figura 4.7 recoge las seis escalas empleadas.

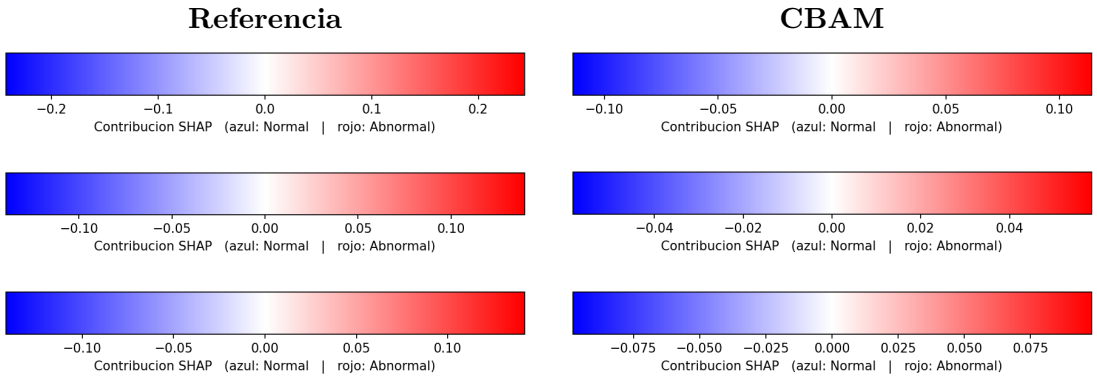


Figura 4.7.: Escalas de color de las proyecciones espaciales. De arriba abajo, parches de 80, 120 y 160 píxeles; a la izquierda, la configuración de referencia y, a la derecha, la variante con CBAM. Cada escala se aplica a todos los ejemplos de su combinación de configuración y tamaño.

Cada visualización presenta el parche original junto a su proyección y, sobre esta, la probabilidad estimada de pertenencia a la clase `Abnormal`. Se mantiene el umbral de decisión de 0,5, de modo que un parche se asigna a `Abnormal` cuando esa probabilidad iguala o supera dicho valor, y a `Normal` en caso contrario.

Ejemplos seleccionados y sus predicciones El análisis ilustrativo inicial comprende 36 visualizaciones, con seis ejemplos por combinación de variante y tamaño de parche. Las dos variantes se examinan sobre los mismos tres ejemplos de `Normal` y tres de `Abnormal` en cada tamaño, por lo que las 36 visualizaciones corresponden a 18 parches distintos analizados con ambos clasificadores. Los ejemplos se toman del conjunto de prueba según el orden de los índices devueltos por el particionado, y los identificadores 0, 1 y 2 los numeran dentro de cada clase y tamaño. Esta selección permite estudiar casos concretos, sin asumir que su proporción de aciertos sea representativa del conjunto completo de prueba.

La Tabla 4.10 recoge las probabilidades estimadas para estos 18 parches.

Tabla 4.10.: Probabilidad estimada de pertenencia a la clase `Abnormal` para los ejemplos visualizados.

Tamaño (píxeles)	Ejemplo	Referencia	CBAM
80	`Normal` 0	0,00	0,00
80	`Normal` 1	0,01	0,01
80	`Normal` 2	0,57	0,55
80	`Abnormal` 0	0,95	1,00
80	`Abnormal` 1	0,98	1,00
80	`Abnormal` 2	0,93	1,00
120	`Normal` 0	0,34	0,08
120	`Normal` 1	0,04	0,00
120	`Normal` 2	0,06	0,03
120	`Abnormal` 0	0,94	0,98
120	`Abnormal` 1	0,99	1,00
120	`Abnormal` 2	0,94	0,99
160	`Normal` 0	0,10	0,00
160	`Normal` 1	0,01	0,00
160	`Normal` 2	0,00	0,00
160	`Abnormal` 0	0,98	1,00
160	`Abnormal` 1	1,00	1,00
160	`Abnormal` 2	0,97	1,00

Con el umbral de 0,5, cada modelo clasifica correctamente 17 de los 18 parches seleccionados. El único error corresponde al ejemplo `Normal` 2 de 80 píxeles, al que la configuración de referencia asigna una probabilidad de `Abnormal` de 0,57 y la variante con CBAM, de 0,55: la probabilidad disminuye, pero ambas mantienen la clasificación incorrecta y producen un falso positivo. Los nueve ejemplos de `Abnormal` se clasifican correctamente con las dos configuraciones.

En varios casos, CBAM produce probabilidades más próximas a cero o a uno. En `Normal` 0 de 120 píxeles, la probabilidad de `Abnormal` disminuye de 0,34 a 0,08 y, en `Normal` 0 de 160 píxeles, pasa de 0,10 a un valor que se muestra como 0,00 tras el redondeo. Las probabilidades de los ejemplos de `Abnormal` también tienden a aumentar. Estos cambios no suponen más aciertos en esta selección, ya que ambos modelos cometen el mismo error, ni permiten concluir que las probabilidades de CBAM sean más fiables. Para valorar el rendimiento general deben utilizarse los resultados sobre el conjunto completo de prueba.

Parches de 80 píxeles Las proyecciones de `Normal` 0 y `Normal` 1, recogidas en las Figuras 4.8 y 4.9, presentan zonas azules cuya localización e intensidad cambian entre variantes. En `Normal` 0, CBAM concentra el azul cerca del lado derecho; en `Normal` 1, las zonas azules ocupan una superficie mayor y coinciden parcialmente con regiones de tinción violeta. Ambos parches reciben probabilidades bajas de `Abnormal` y, en los dos casos, CBAM intensifica las zonas azules ya presentes en la configuración de referencia.

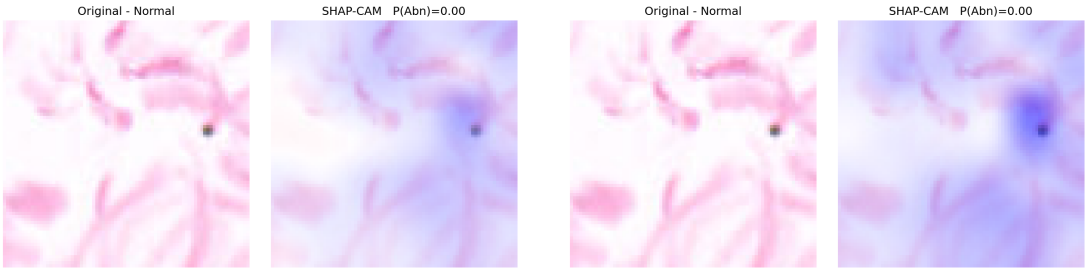


Figura 4.8.: Visualizaciones SHAP-CAM del parche `Normal` 0 de 80 píxeles: configuración de referencia (izquierda) y configuración con CBAM (derecha).

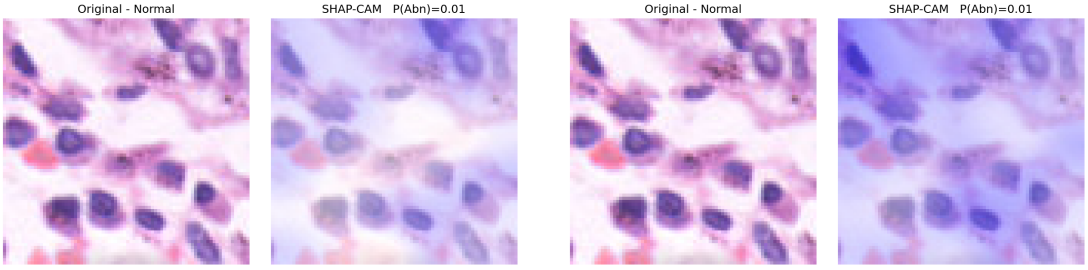
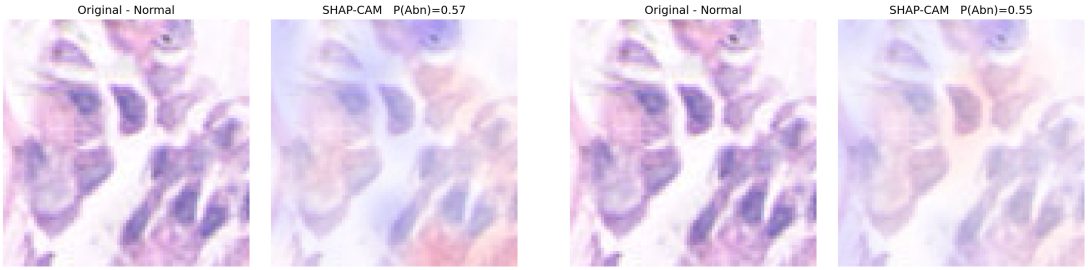


Figura 4.9.: Visualizaciones SHAP-CAM del parche `Normal` 1 de 80 píxeles: configuración de referencia (izquierda) y configuración con CBAM (derecha).

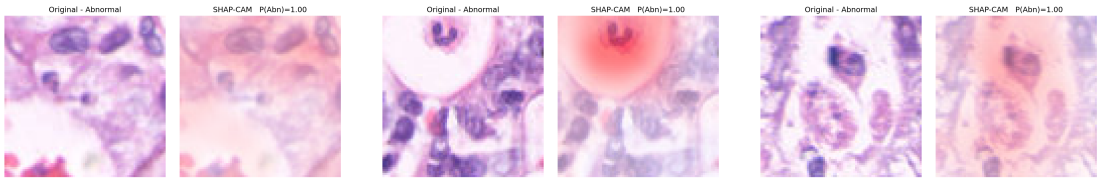
El parche `Normal` 2, que ambos modelos clasifican de forma incorrecta, resulta especialmente ilustrativo. Sus mapas, en la Figura 4.10, contienen zonas rojas y azules distribuidas de manera diferente en cada configuración. Aunque aparecen regiones azules, la predicción final es `Abnormal`, lo que muestra que la clase predicha debe consultarse en la salida del clasificador y no deducirse del color que parece predominar en la imagen.



`Normal` 2 - Referencia `Normal` 2 - CBAM

Figura 4.10.: Ejemplo `Normal` 2 de 80 píxeles, clasificado como `Abnormal` por ambas variantes. A la izquierda se muestra la referencia y a la derecha, CBAM. Las probabilidades representadas son 0,57 y 0,55.

En los tres ejemplos de `Abnormal`, mostrados con la variante CBAM en la Figura 4.11, predominan las zonas rojas. En `Abnormal` 1 aparece una zona roja intensa en la parte central, sobre una estructura teñida rodeada de entorno claro, mientras que en `Abnormal` 0 y `Abnormal` 2 las regiones rojas son más extensas y menos intensas. Los mapas resaltan, por tanto, regiones de distinto tamaño, pero no delimitan con precisión las estructuras visibles.



`Abnormal` 0 `Abnormal` 1 `Abnormal` 2

Figura 4.11.: Visualizaciones SHAP-CAM de la configuración con CBAM en los parches `Abnormal` de 80 píxeles.

Parches de 120 píxeles En `Normal` 0, la configuración de referencia muestra zonas azules marcadas en el borde izquierdo y en la mitad inferior. Con CBAM cambia su dis-

tribución y aparece también una zona rojiza en la parte inferior central, como se observa en la Figura 4.12. Pese a ello, la probabilidad de `Abnormal` disminuye de 0,34 a 0,08, lo que muestra que una reducción de esa probabilidad no implica que todo el mapa se vuelva más azul.

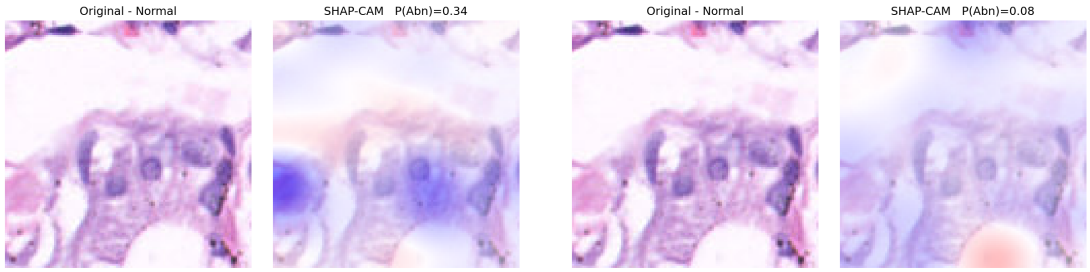


Figura 4.12.: Visualizaciones SHAP-CAM del parche `Normal` 0 de 120 píxeles: configuración de referencia (izquierda) y configuración con CBAM (derecha).

En `Normal` 1 y `Normal` 2, recogidos en la Figura 4.13, se observan principalmente zonas azules suaves, junto con otras más marcadas en algunos bordes y regiones teñidas. Los tres ejemplos de `Normal` de este tamaño se clasifican correctamente con ambos modelos.

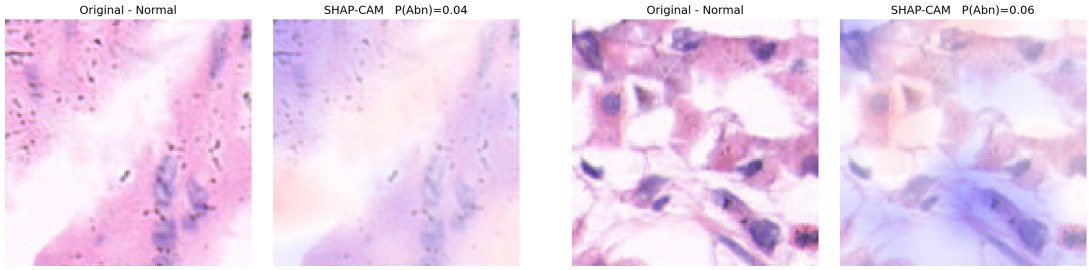


Figura 4.13.: Visualizaciones SHAP-CAM de los parches `Normal` 1 y `Normal` 2 de 120 píxeles con la configuración de referencia.

En `Abnormal` 1, CBAM muestra zonas rojas cerca del borde superior y en el lado derecho, mientras que el mapa de la referencia tiene una apariencia más tenue, pese a que las probabilidades asignadas son 0,99 y 1,00. La Figura 4.14 recoge ambas proyecciones. Como cada variante utiliza su propia escala de color, esta diferencia visual no permite afirmar que las contribuciones sean mayores con CBAM.

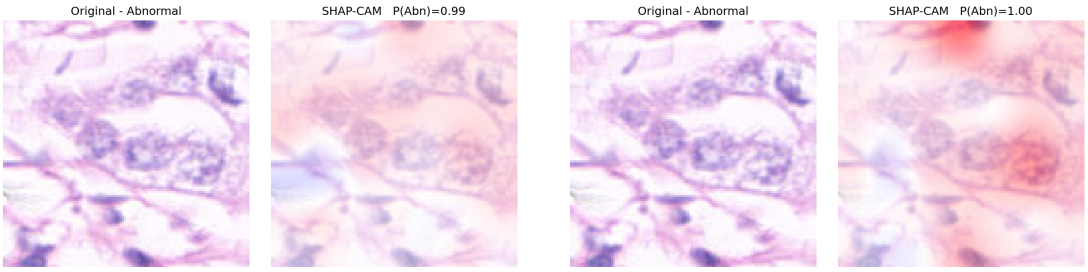


Figura 4.14.: Visualizaciones SHAP-CAM del parche `Abnormal` 1 de 120 píxeles: configuración de referencia (izquierda) y configuración con CBAM (derecha). Las probabilidades asignadas son 0,99 y 1,00, respectivamente.

Parches de 160 píxeles La Figura 4.15 reúne los tres ejemplos de `Normal` de 160 píxeles con ambas configuraciones. En `Normal` 0, cuyo parche contiene tejido densamente teñido, las dos proyecciones presentan tonos azules sobre esa región, más extensos con CBAM, y la probabilidad de `Abnormal` pasa de 0,10 a 0,00. Los parches `Normal` 1 y `Normal` 2 tienen una superficie mayoritariamente clara, con poco tejido teñido: en ambos aparecen zonas azules amplias en la mitad inferior, situadas de forma distinta en cada variante, mientras que sus probabilidades de `Abnormal` son de 0,01 y 0,00 en la referencia y se muestran como 0,00 con CBAM.

Estos ejemplos permiten observar que también aparecen zonas destacadas en partes de la imagen con escaso tejido visible, aunque el mapa no permite afirmar que el modelo base su decisión en el fondo. Muestran además que un color más intenso no implica una probabilidad más alta: la intensidad depende de la escala de cada grupo y, como se ha visto en `Abnormal` 1 de 120 píxeles, un mapa tenue puede corresponder a una predicción con probabilidad elevada.

4.6.3. Selección estratificada de ejemplos

Las visualizaciones anteriores corresponden a parches elegidos de forma manual y ordenada, por lo que no permiten distinguir si un patrón concreto es habitual o es propio del ejemplo mostrado. Para evitar esa limitación se realiza una selección estratificada sobre el conjunto de prueba de la semilla 42 y los parches de 160 píxeles, tanto en la configuración de referencia como en la variante con CBAM. Las predicciones se agrupan en cuatro categorías definidas a partir de la probabilidad estimada para la clase *Abnormal*, $P(\text{Abn})$: aciertos con alta confianza, aciertos con baja confianza, falsos positivos y falsos negativos. De cada categoría se extraen doce ejemplos, lo que supone 48 parches

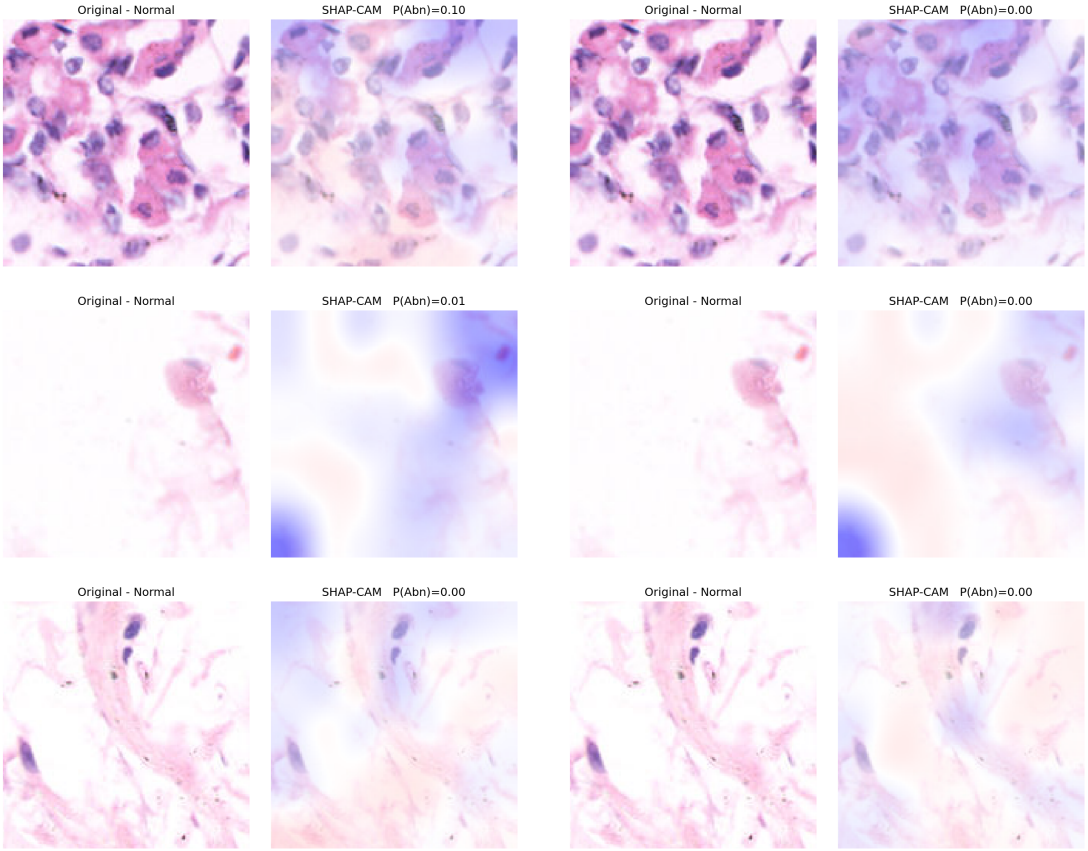
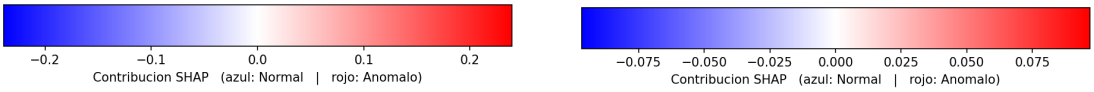


Figura 4.15.: Visualizaciones SHAP-CAM de los parches `Normal` 0, `Normal` 1 y `Normal` 2 de 160 píxeles, con la configuración de referencia (izquierda) y CBAM (derecha).

por variante y 96 en total.

Las categorías se determinan por separado en cada variante, a partir de sus propias predicciones, de modo que los parches seleccionados no coinciden entre la configuración de referencia y CBAM. Por este motivo la comparación entre ambas no se establece caso a caso, sino a nivel de grupo: se describe qué tipo de parche aparece en cada categoría y qué rango de probabilidades se le asigna. Las figuras que siguen recogen cuatro de los doce ejemplos de cada categoría, dos por variante..

Las escalas de color se calculan de forma independiente en cada variante, a partir del máximo valor absoluto de las contribuciones SHAP de sus propios ejemplos. La Figura 4.16 muestra ambas escalas. Se observa que el rango abarca menos en CBAM. La intensidad del color indica, por tanto, la importancia relativa dentro de cada variante y no debe compararse entre figuras de variantes distintas.

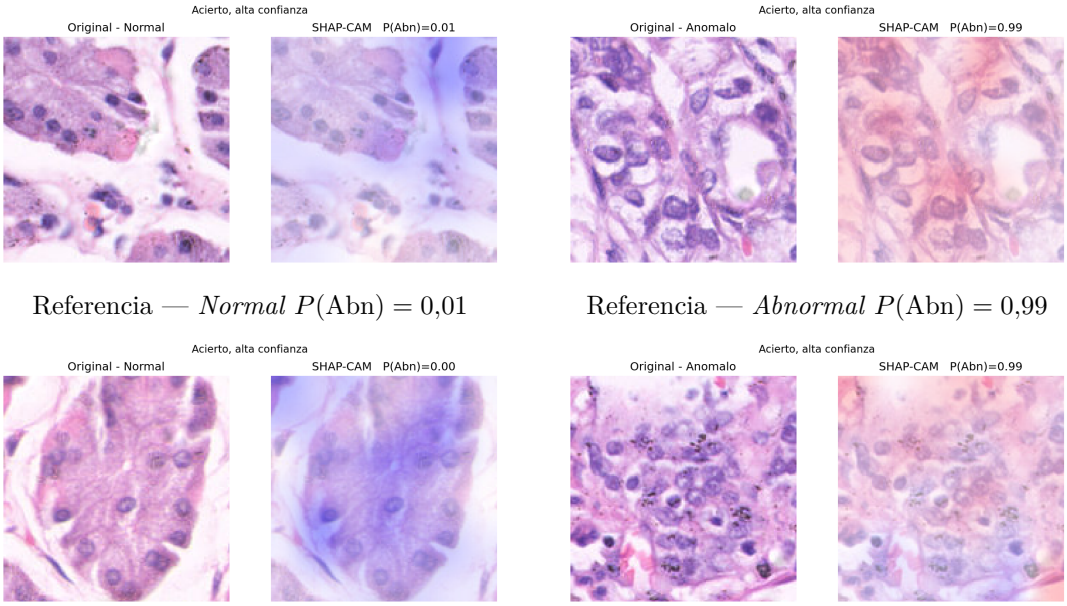


Configuración de referencia Variante con CBAM

Figura 4.16.: Escalas de color empleadas en la selección estratificada de parches de 160 píxeles. El azul indica contribución hacia la clase *Normal* y el rojo hacia *Abnormal*.

4.6.3.1. Aciertos con alta confianza

En esta categoría las probabilidades se sitúan en los extremos del intervalo. En la configuración de referencia los nueve ejemplos de clase *Normal* reciben valores de la probabilidad de *Abnormal* muy bajos, entre 0,00 y 0,05 y los tres de clase *Abnormal*, entre 0,94 y 0,99. Los parches *Normal* de ambas variantes muestran áeras teñidas de rosa y varias regiones ovaladas de tamaño uniforme teñidas de morado, mientras que los *Abnormal* presentan agrupaciones de estas estructuras ovaladas oscuras y de contorno irregular. Los mapas asociados son casi monocromáticos, azul extendido sobre la práctica totalidad del parche en los primeros y rojo igualmente extendido en los segundos, aunque uno de los mapas también presenta algo de azul esparcido.



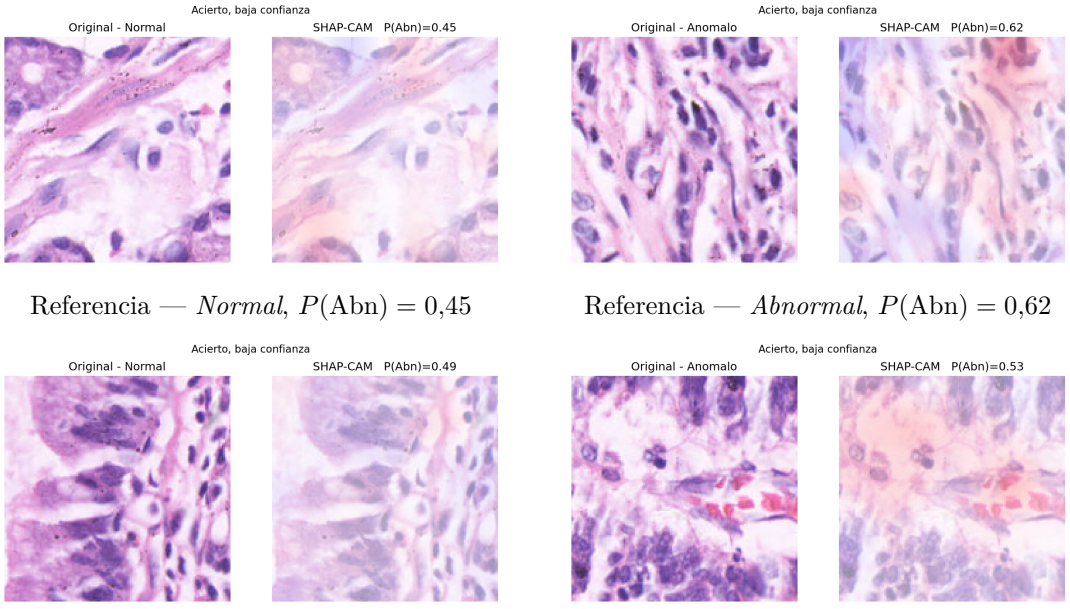
Referencia — *Normal* $P(\text{Abn}) = 0{,}01$ | Referencia — *Abnormal* $P(\text{Abn}) = 0{,}99$

CBAM — *Normal* $P(\text{Abn}) = 0{,}00$ | CBAM — *Abnormal* $P(\text{Abn}) = 0{,}99$

Figura 4.17.: Aciertos con alta confianza en parches de 160 píxeles. Fila superior: configuración de referencia. Fila inferior: variante con CBAM. En cada panel se muestra el parche original y su proyección espacial de valores SHAP.

4.6.3.2. Aciertos con baja confianza

Los aciertos con baja confianza se concentran alrededor del umbral de decisión, cerca del valor 0,5 en ambas configuraciones, con presencia de ambas clases en las dos variantes. Los mapas correspondientes son visiblemente más heterogéneos que los anteriores. A diferencia del caso anterior se observan regiones azules y rojas coexistiendo, si bien la intensidad del color es menor. Este comportamiento resulta coherente con una probabilidad próxima a 0,5. Con respecto a lo que se observa en los parches, todos ellos comparten regiones blancas que recorren las imágenes como caminos separando regiones oscuras con textura marcada.



Referencia — *Normal*, $P(\text{Abn}) = 0{,}45$ | Referencia — *Abnormal*, $P(\text{Abn}) = 0{,}62$

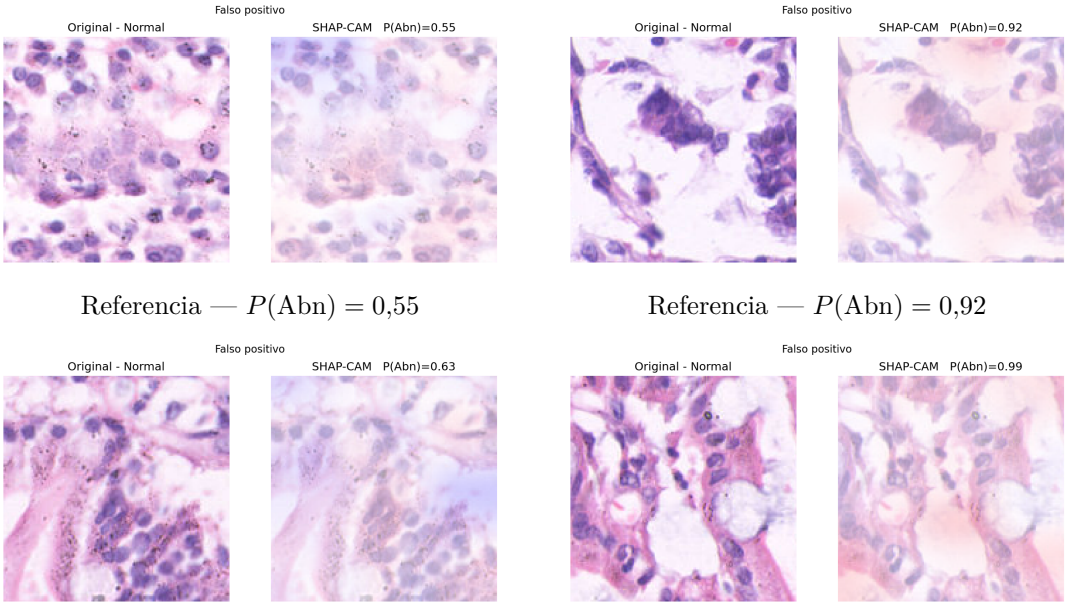
CBAM — *Normal*, $P(\text{Abn}) = 0{,}49$ | CBAM — *Abnormal*, $P(\text{Abn}) = 0{,}53$

Figura 4.18.: Aciertos con baja confianza en parches de 160 píxeles. Fila superior: configuración de referencia. Fila inferior: variante con CBAM.

4.6.3.3. Falsos positivos

Los falsos positivos son parches etiquetados como *Normal* que el modelo clasifica como *Abnormal*. En los ejemplos se observan parches con muy poco tejido sobre fondo blanco, con aspecto abstracto en los que las regiones ovaladas oscuras aparecen aglutinadas. Los mapas parecen situar las contribuciones positivas precisamente sobre esas agrupaciones.

La diferencia entre variantes se encuentra en la confianza asignada al error: en la configuración de referencia $P(\text{Abn})$ oscila entre 0,54 y 0,92, con nueve de los doce ejemplos por debajo de 0,70, mientras que con CBAM el rango va de 0,63 a 1,00 y ocho de los doce superan 0,90.



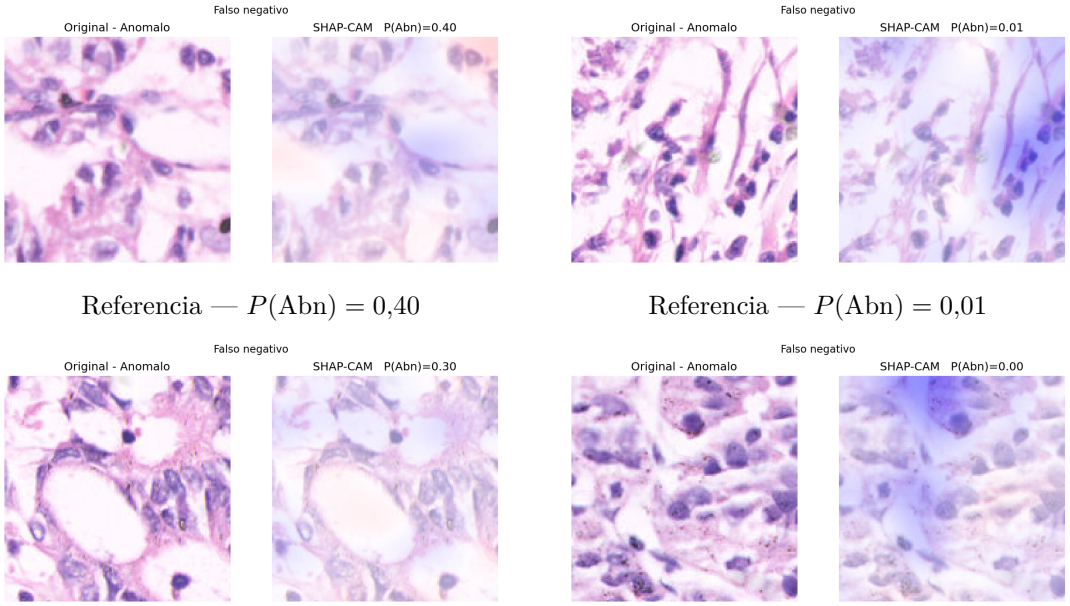
Referencia — $P(\text{Abn}) = 0{,}55$ Referencia — $P(\text{Abn}) = 0{,}92$

CBAM — $P(\text{Abn}) = 0{,}63$ CBAM — $P(\text{Abn}) = 0{,}99$

Figura 4.19.: Falsos positivos en parches de 160 píxeles. Fila superior: configuración de referencia. Fila inferior: variante con CBAM. Todos los parches pertenecen a la clase *Normal*.

4.6.3.4. Falsos negativos

Los falsos negativos corresponden a parches *Abnormal* clasificados como *Normal*. Lo más notable en estos parches es un posible patrón de pérdida de intensidad de los colores. Los mapas muestran zonas azules sobre regiones pálidas del parche y, en algunos casos, focos rojos pequeños y aislados que no han bastado para desplazar la predicción. Como en la categoría anterior, la variante con CBAM se equivoca con mayor confianza: en la configuración de referencia $P(\text{Abn})$ abarca de 0,01 a 0,50, con cuatro de los doce ejemplos por encima de 0,30, mientras que con CBAM el rango va de 0,00 a 0,31 y nueve de los doce quedan por debajo de 0,11.



Referencia — $P(\text{Abn}) = 0{,}40$ Referencia — $P(\text{Abn}) = 0{,}01$

CBAM — $P(\text{Abn}) = 0{,}30$ CBAM — $P(\text{Abn}) = 0{,}00$

Figura 4.20.: Falsos negativos en parches de 160 píxeles. Fila superior: configuración de referencia. Fila inferior: variante con CBAM. Todos los parches pertenecen a la clase *Abnormal*.

4.7. Matrices de confusión

Las siguientes figuras presentan las matrices de confusión con los valores medios obtenidos entre las cinco semillas. Cada figura corresponde a un tamaño de parche y permite comparar la configuración de referencia, el aumento de datos y CBAM.

Cada celda representa el promedio del recuento correspondiente en las cinco ejecuciones. Por este motivo pueden aparecer valores decimales. Estas matrices resumen los resultados por ejecución y no representan un recuento de imágenes únicas acumuladas entre semillas.

Las filas representan la clase real y las columnas la clase predicha por cada sistema. La diagonal principal contiene las muestras correctamente clasificadas. Se considera `Abnormal` como clase positiva, por lo que los verdaderos positivos (TP) son parches `Abnormal` clasificados correctamente y los falsos negativos (FN) son parches `Abnormal` clasificados como `Normal`. Los verdaderos negativos (TN) son parches `Normal` clasificados correctamente y los falsos positivos (FP) son parches `Normal` clasificados como `Abnormal`.

Parches de 80 píxeles La Figura 4.21 muestra una reducción de ambos tipos de error al incorporar aumento de datos y, posteriormente, al comparar esta configuración con CBAM. Los falsos positivos medios pasan de 1810,0 en la referencia a 1617,4 con aumento de datos y a 1452,2 con CBAM. Los falsos negativos disminuyen de 1229,8 a 1092,2 y 953,8, respectivamente.

Por tanto, en este tamaño, las mejoras observadas afectan tanto a la identificación de los parches `Normal` como a la detección de los parches `Abnormal`.

Parches de 120 píxeles En los parches de 120 píxeles, el aumento de datos también reduce ambos tipos de error respecto a la referencia, como muestra la Figura 4.22. Los falsos positivos medios disminuyen de 591,4 a 519,2 y los falsos negativos de 421,6 a 369,4.

La diferencia entre el aumento de datos y CBAM se concentra principalmente en los falsos positivos, que se reducen a 484,8. Los falsos negativos son prácticamente iguales en ambas configuraciones: 369,4 con aumento de datos y 369,2 con CBAM. Este resultado

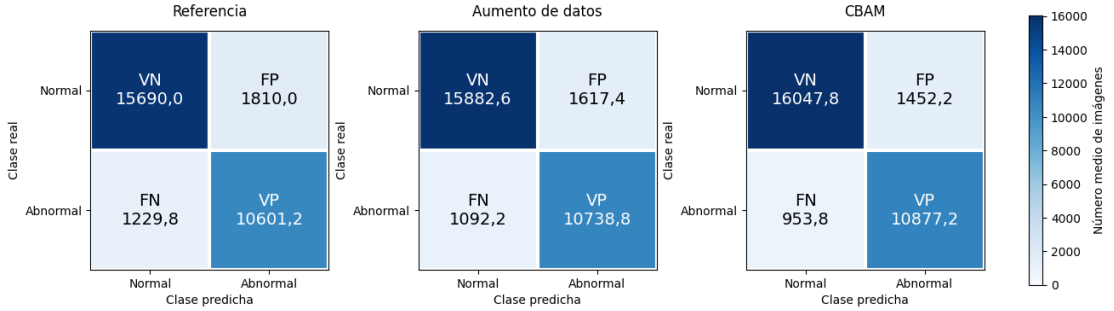


Figura 4.21.: Matrices de confusión medias para parches de 80 píxeles. De izquierda a derecha: referencia, aumento de datos y CBAM. Los valores son promedios de cinco semillas.

concuerda con la sensibilidad similar observada en las tablas de métricas.

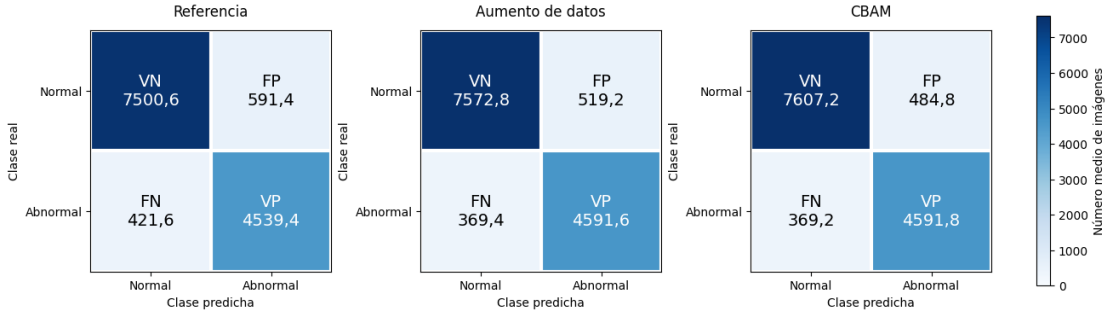


Figura 4.22.: Matrices de confusión medias para parches de 120 píxeles. De izquierda a derecha: referencia, aumento de datos y CBAM. Los valores son promedios de cinco semillas.

Parches de 160 píxeles La Figura 4.23 muestra que el aumento de datos reduce los falsos positivos medios de 243,0 a 201,8 y los falsos negativos de 207,2 a 172,2 respecto a la referencia.

CBAM presenta los menores recuentos medios de error, con 186,2 falsos positivos y 166,8 falsos negativos. Su ventaja respecto al aumento de datos se observa en ambas clases, aunque la reducción de falsos negativos es menor que la de falsos positivos.

En los tres tamaños, CBAM obtiene los menores recuentos medios de falsos positivos y falsos negativos entre las configuraciones evaluadas. No obstante, estas matrices resumen

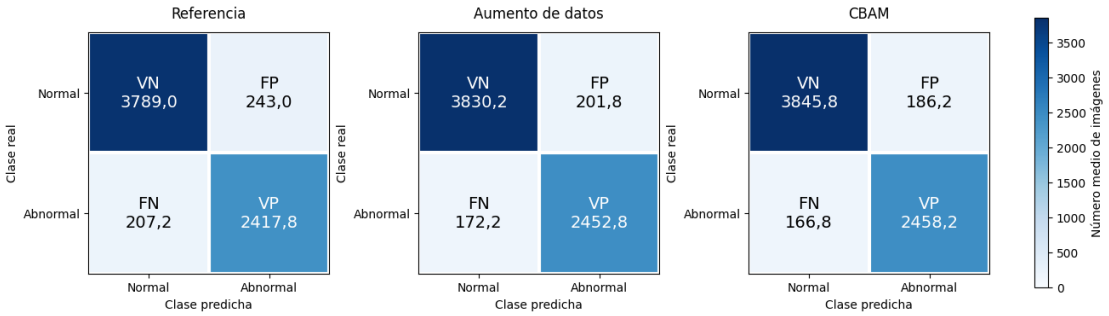


Figura 4.23.: Matrices de confusión medias para parches de 160 píxeles. De izquierda a derecha: referencia, aumento de datos y CBAM. Los valores son promedios de cinco semillas.

las ejecuciones al calcular su media y no muestran la variabilidad entre semillas, por lo que deben interpretarse junto con las desviaciones típicas recogidas en las tablas de métricas. Mientras, los resultados individuales se incluyen en el anexo B.2.

Cada figura utiliza una escala de color compartida entre las tres configuraciones. Sin embargo, las escalas cambian entre tamaños ya que los conjuntos de prueba contienen distintas cantidades de muestras. Para poder comparar la intensidad del color y directamente el rendimiento entre tamaños se presentan las matrices normalizadas en la siguiente Figura 4.24.

Para cada semilla, cada celda se divide entre el total de imágenes de su clase real, es decir, entre la suma de su fila. A continuación, se calculan los porcentajes medios de las cinco ejecuciones. Cada fila de la matriz resultante suma el 100 %.

Todas las matrices utilizan una escala de color de 0 a 100 %. Esta representación permite comparar las tasas de acierto y error dentro de cada clase, aunque los conjuntos de prueba tengan distinto número de imágenes. Las celdas diagonales corresponden a la especificidad de `Normal` y a la sensibilidad de `Abnormal`.

4.8. Comparación completa de resultados

Para facilitar la comparación entre las configuraciones evaluadas, la Tabla 4.11 reúne los resultados de la configuración base, el aumento de datos y la incorporación del módulo de atención CBAM para las tres resoluciones. Se presentan además la media y la desviación típica de las cinco semillas.

Además, se muestran los resultados en la Figura 4.25, la cual complementa los resul-

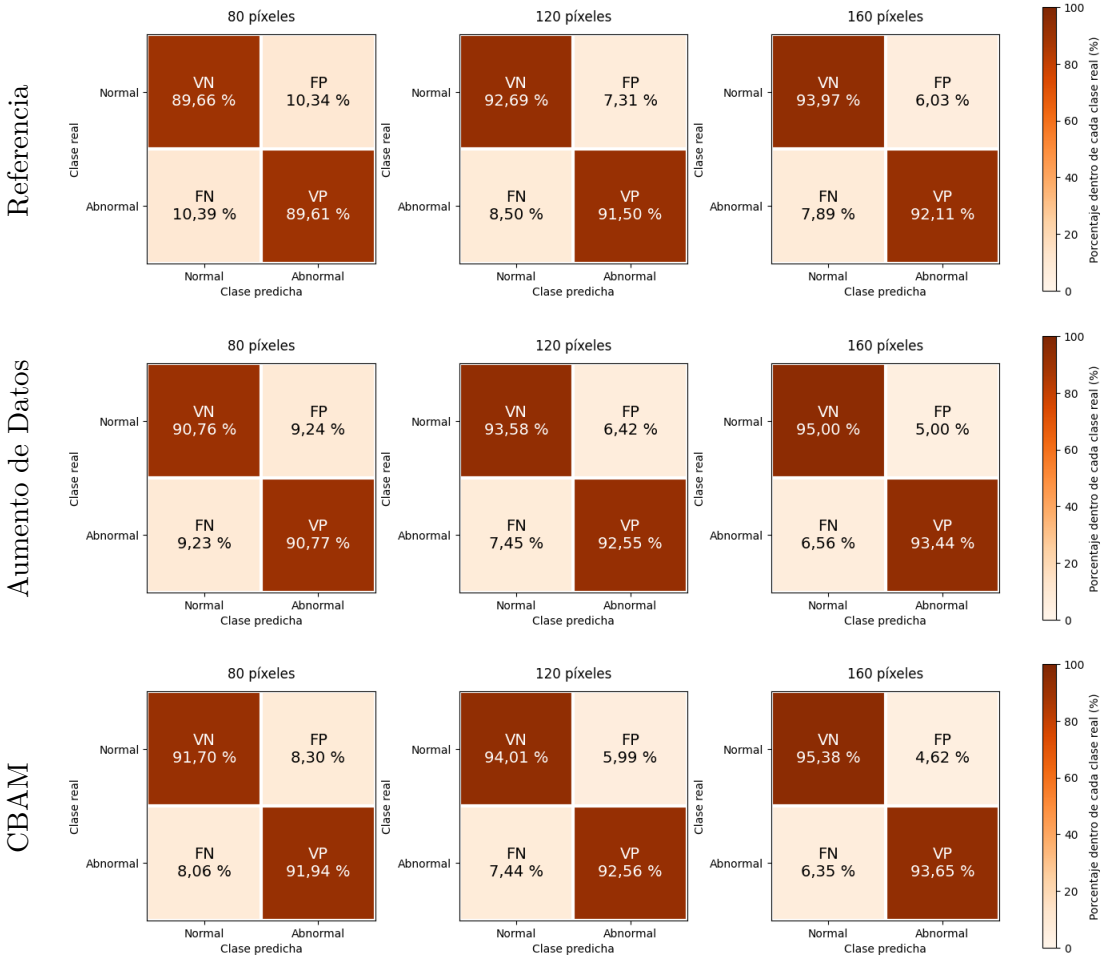


Figura 4.24.: Matrices de confusión normalizadas. De arriba abajo: configuración de referencia, aumento de datos y CBAM. En cada fila, de izquierda a derecha: parches de 80, 120 y 160 píxeles.

Tabla 4.11.: Comparación conjunta de resultados. Se presenta la media ± desviación típica de cinco semillas, con todas las métricas expresadas en escala de 0 a 100. La precisión, la sensibilidad y F1 de `Abnormal` se calculan considerando esta clase como positiva.

Tamaño	Métrica	Referencia	Aumento	CBAM
80 píxeles	*Accuracy*	$89,64 \pm 0,15$	$90,76 \pm 0,17$	$91,80 \pm 0,04$
	Balanced accuracy	$89,63 \pm 0,14$	$90,76 \pm 0,15$	$91,82 \pm 0,03$
	Precisión Abnormal	$85,42 \pm 0,26$	$86,91 \pm 0,37$	$88,22 \pm 0,23$
	Sensibilidad Abnormal	$89,61 \pm 0,22$	$90,77 \pm 0,15$	$91,94 \pm 0,21$
	Especificidad	$89,66 \pm 0,22$	$90,76 \pm 0,30$	$91,70 \pm 0,20$
	F1 Abnormal	$87,46 \pm 0,17$	$88,80 \pm 0,19$	$90,04 \pm 0,03$
	F1 macro	$89,31 \pm 0,15$	$90,47 \pm 0,17$	$91,53 \pm 0,04$
	AUC-ROC	$96,26 \pm 0,04$	$96,95 \pm 0,09$	$97,57 \pm 0,03$
120 píxeles	*Accuracy*	$92,24 \pm 0,17$	$93,19 \pm 0,13$	$93,46 \pm 0,44$
	Balanced accuracy	$92,10 \pm 0,19$	$93,07 \pm 0,14$	$93,28 \pm 0,45$
	Precisión Abnormal	$88,48 \pm 0,41$	$89,84 \pm 0,36$	$90,45 \pm 0,74$
	Sensibilidad Abnormal	$91,50 \pm 0,44$	$92,55 \pm 0,35$	$92,56 \pm 0,57$
	Especificidad	$92,69 \pm 0,31$	$93,58 \pm 0,27$	$94,01 \pm 0,50$
	F1 Abnormal	$89,96 \pm 0,22$	$91,18 \pm 0,17$	$91,49 \pm 0,57$
	F1 macro	$91,82 \pm 0,18$	$92,82 \pm 0,14$	$93,09 \pm 0,47$
	AUC-ROC	$97,63 \pm 0,10$	$98,18 \pm 0,05$	$98,31 \pm 0,25$
160 píxeles	*Accuracy*	$93,24 \pm 0,11$	$94,38 \pm 0,27$	$94,70 \pm 0,17$
	Balanced accuracy	$93,04 \pm 0,13$	$94,22 \pm 0,28$	$94,51 \pm 0,21$
	Precisión Abnormal	$90,87 \pm 0,37$	$92,40 \pm 0,49$	$92,96 \pm 0,16$
	Sensibilidad Abnormal	$92,11 \pm 0,40$	$93,44 \pm 0,48$	$93,65 \pm 0,39$
	Especificidad	$93,97 \pm 0,28$	$95,00 \pm 0,35$	$95,38 \pm 0,11$
	F1 Abnormal	$91,48 \pm 0,14$	$92,92 \pm 0,33$	$93,30 \pm 0,23$
	F1 macro	$92,94 \pm 0,12$	$94,13 \pm 0,28$	$94,46 \pm 0,18$
	AUC-ROC	$98,21 \pm 0,07$	$98,68 \pm 0,07$	$98,82 \pm 0,06$

tados numéricos mediante una representación gráfica para facilitar apreciar la diferencia de los resultados entre las distintas configuraciones y tamaños de parche.

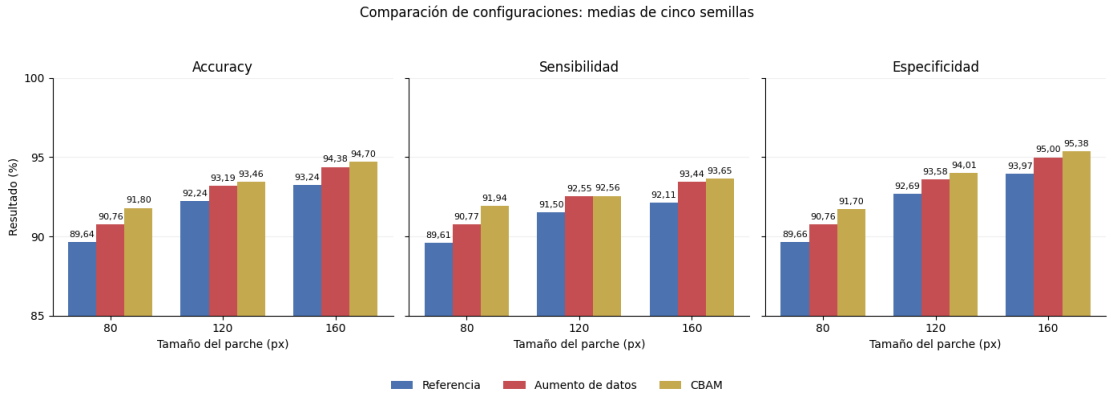


Figura 4.25.: Comparación del *accuracy*, la sensibilidad y la especificidad entre la configuración de referencia, el aumento de datos y CBAM para los tres tamaños de parche. Se muestran las medias de cinco semillas, expresadas en porcentaje.

El mejor *accuracy* medio se obtiene con CBAM y parches de 160 píxeles, con un valor de $94,70 \pm 0,17\,\%$, una sensibilidad de $93,65 \pm 0,39\,\%$ y una especificidad de $95,38 \pm 0,11\,\%$. Sin embargo, el mayor incremento de *accuracy* al incorporar CBAM respecto a la referencia se observa en los parches de 80 píxeles, con una diferencia de 2,16 puntos porcentuales. Por tanto, el tamaño que alcanza el mejor resultado absoluto no coincide con aquel en el que esta modificación aporta la mayor mejora.

El aumento de datos mejora el *accuracy* de la referencia en los tres tamaños y en las cinco semillas, manteniendo congelado el extractor. CBAM alcanza medias superiores, aunque su ventaja respecto al aumento de datos no es igual en todas las métricas. En particular, para los parches de 120 píxeles, la sensibilidad es prácticamente la misma en ambas configuraciones: 92,55 % con aumento de datos y 92,56 % con CBAM.

La incorporación de CBAM añade una etapa de aprendizaje supervisado de la representación, con las limitaciones de validación y reproducibilidad ya descritas. Estos resultados permiten, por tanto, comparar el rendimiento de las configuraciones completas bajo el protocolo empleado, pero determinar cuál ofrece una mejor relación entre coste y rendimiento requeriría mediciones adicionales.

5. Discusión

Este capítulo, en el que se interpretan los resultados obtenidos y se relacionan con los objetivos del trabajo, se divide en varios apartados: la sección 5.1, en la que se analizan el efecto del tamaño de parche y de las modificaciones evaluadas, la generalización entre tamaños y los resultados de interpretabilidad; la sección 5.2, donde se comparan los resultados con los trabajos previos, considerando las diferencias entre sus protocolos de evaluación y el coste computacional de las propuestas; la sección 5.3, en la que se exponen las limitaciones del estudio relativas a los datos, a la metodología y a la interpretabilidad; y, finalmente, la sección 5.4, en la que se resumen las principales aportaciones del trabajo.

5.1. Interpretación de los resultados

5.1.1. Efecto del tamaño del parche

En todas las configuraciones se observa un patrón relacionado con el tamaño de los parches empleado: a mayor resolución, mejores resultados.

En las tres configuraciones evaluadas, el *accuracy* medio aumenta al pasar de la colección de 80 píxeles a las de 120 y 160 píxeles. Este patrón es consistente entre las configuraciones estudiadas, aunque no permite aislar el efecto del tamaño original del parche. En la configuración de referencia, alcanza valores de 89,64 %, 92,24 % y 93,24 % respectivamente. Esto constituye una diferencia de 3,60 puntos porcentuales entre el tamaño más pequeño y el más grande, esta diferencia es mayor a cualquiera aportada entre el resto de métodos. Al desglosar la diferencia se obtiene que 2,6 puntos porcentuales pertenecen al cambio de pasar de 80 a 120 píxeles mientras que solo un punto porcentual corresponde al paso de 120 a 160. Esto podría deberse a que a partir de cierto tamaño, el parche ya contiene las estructuras necesarias para decidir, o verse afectado por la cantidad de datos y contexto en el entrenamiento en cada resolución.

Sin embargo, tampoco se puede decir que sea la decisión más influyente puesto que las tres colecciones de muestras no solo varían en su tamaño, sino también en la cantidad de

imágenes y por lo tanto, en el tamaño de sus conjuntos de entrenamiento y prueba. Por este motivo y los resultados obtenidos es importante considerar el tamaño de parche a la hora de presentar y comparar los resultados, y es por eso que a lo largo de este trabajo así se ha hecho.

Una posible explicación es que los parches de mayor tamaño incluyen más contexto espacial y permiten tanto contener estructuras completas dentro de sí como representar relaciones entre estructuras que no aparecen completas en un recorte pequeño.

Todos los parches se redimensionan a 224×224 píxeles antes de introducirlos en el extractor. Por tanto, las diferencias observadas no corresponden a distintas dimensiones de entrada de la red, sino a colecciones con diferente tamaño original de parche, contexto espacial y grado de ampliación.

5.1.2. Efecto del aumento de datos

Se puede afirmar que el aumento de datos a través de aplicar transformaciones a las imágenes del conjunto de entrenamiento mejora el *accuracy* de la configuración de referencia en los tres tamaños y en las cinco semillas. Aumenta alrededor de un punto porcentual en todas las ocasiones, de media mejora específicamente 1,13, 0,95 y 1,14 puntos porcentuales para las resoluciones ordenadas de menor a mayor. Se trata de un aumento que resalta sobre los demás por ser uniforme entre las resoluciones, lo que sugiere que el aumento de datos tiene de por sí la capacidad de mejorar el rendimiento independientemente del tamaño de parche empleado, es decir, es una propiedad intrínseca de la configuración que podría ser independiente de las muestras.

En esta configuración, cada parche de entrenamiento se acompaña de tres vistas transformadas. La representación de la imagen original y su versión rotada son puntos distintos del espacio de características, y el aumento consiste literalmente en poblar ese espacio con las versiones de cada observación para que el clasificador aprenda a asignarles la misma etiqueta. Los resultados son compatibles con la utilidad de incorporar estas variaciones al entrenamiento.

El aumento de datos se considera una modificación sencilla del sistema, ya que no añade un módulo neuronal entrenable. Sin embargo, sí incrementa el almacenamiento de características y el número de observaciones utilizadas en cada ajuste de CatBoost.

La mejora observada indica que es posible aumentar el rendimiento sin actualizar los pesos del extractor ni incorporar otro módulo neuronal entrenable. Si se compara con CBAM, el aumento de datos obtiene resultados competitivos sin incorporar un módulo neuronal entrenable adicional; no obstante, al no disponer de mediciones comparables, no puede cuantificarse la diferencia de coste computacional entre ambas configuraciones.

5.1.3. Efecto de incorporar CBAM

CBAM es la configuración que mejor rendimiento alcanza en las tres resoluciones, obtiene un *accuracy* de 91,80 %, 93,46 % y 94,70 % para 80, 120 y 160 píxeles. Respecto a la referencia, las diferencias son de 2,16, 1,22 y 1,46 puntos porcentuales, calculadas a partir de las medias redondeadas.

El mayor incremento, respecto a la configuración de referencia se observa en los parches de 80 píxeles. Una posible explicación es que la atención resulta más valiosa cuanto más pobre es la señal de entrada o conforme el parche original contiene menos contexto espacial, es decir, cuanto menos información contenga la imagen. En un parche de 80 píxeles al que se le ha hecho bastante *zoom*, y por lo tanto quitado parte del contexto, seleccionar qué características del extractor merecen peso es una ayuda sustancial para el clasificador. Una posible explicación, que los experimentos actuales no permiten confirmar, es que los parches de mayor tamaño aporten más contexto y que, por ello, la recalibración introducida por CBAM produzca una mejora adicional menor.

Las matrices de confusión permiten precisar cómo se distribuyen las mejoras. En 80 píxeles, CBAM reduce tanto los falsos positivos como los falsos negativos respecto al aumento de datos. En 120 píxeles, la diferencia se concentra principalmente en los falsos positivos, mientras que la sensibilidad permanece prácticamente igual en ambas configuraciones. En 160 píxeles también disminuyen ambos tipos de error, aunque la reducción adicional de falsos negativos es pequeña.

La distribución de los errores permite plantear posibles aplicaciones, aunque no demuestra una utilidad clínica. En un sistema destinado a priorizar parches para su revisión, reducir los falsos positivos sin disminuir la sensibilidad podría reducir las alertas innecesarias. Esta posibilidad tendría que evaluarse dentro de un procedimiento de revi-

sión definido, con participación de especialistas y datos independientes. Los experimentos realizados clasifican parches y no permiten estimar el efecto del sistema sobre la carga de trabajo, los errores diagnósticos o los resultados de los pacientes.

La implementación de CBAM cuenta con una limitación ya que la comparación debe entenderse como un bloque. CBAM introduce una etapa de aprendizaje supervisado de las características que no existe en la referencia ni en el aumento de datos.

El análisis de interpretabilidad ayuda a delimitar cómo puede explicarse la mejora obtenida con CBAM. En los ejemplos examinados, los mapas de atención espacial presentan valores próximos a uno y diferencias reducidas entre posiciones. Esto indica que en esos casos, el módulo aplica pesos espaciales similares y ofrece poca evidencia de una selección marcada de regiones concretas.

Por tanto, la mejora de clasificación no basta para afirmar que CBAM haya aprendido a localizar regiones tumorales. Una posible explicación es que la atención de canal tenga un papel relevante al modificar el peso de las características extraídas por la red. Sin embargo, los resultados disponibles no permiten separar la contribución de la atención de canal de la atención espacial ni descartar la importancia de su interacción.

Para estudiar esta hipótesis sería necesario realizar un experimento de ablación que comparase cuatro variantes: sin atención, con atención de canal, con atención espacial y con ambos mecanismos. La comparación debería mantener un protocolo común de entrenamiento y evaluación.

La aportación de este análisis consiste en distinguir la mejora observada de su posible explicación. Los resultados muestran que la configuración con CBAM mejora las métricas medias, pero las visualizaciones no permiten atribuir esa mejora a la localización de estructuras histológicas.

5.1.4. Interpretación de los mapas de atención y SHAP

Los dos análisis de interpretabilidad realizados permiten examinar aspectos diferentes del sistema. Los mapas de atención espacial muestran cómo CBAM pondera las distintas posiciones de la representación extraída por la red. El análisis mediante SHAP, en cambio, estudia cómo contribuyen las características a la predicción final de CatBoost. Esta

diferencia es importante para comprender qué información aporta cada visualización.

En los ejemplos examinados, los pesos de atención espacial de CBAM presentan valores próximos a uno y poca variación entre posiciones. Como estos pesos multiplican las activaciones, un valor próximo a uno conserva prácticamente su magnitud. Por tanto, en esos casos, CBAM mantiene la información de las distintas posiciones con una ponderación similar, en lugar de introducir diferencias espaciales marcadas.

Esto no significa que el sistema responda de la misma forma a todas las regiones del tejido. EfficientNet ya produce mapas de características con activaciones diferentes según la posición, y esas diferencias pueden mantenerse aunque CBAM aplique pesos similares. La limitación afecta a lo que puede deducirse del mapa de atención: su coloración muestra poca evidencia de que el componente espacial esté dando un peso claramente distinto a unas regiones frente a otras.

Los mapas de atención presentan también una limitación más general, la razón de después implementar SHAP, y es que sus pesos no indican directamente cuánto contribuye una característica a la decisión del clasificador. Una activación conservada por CBAM puede tener una contribución pequeña a una predicción concreta. Por este motivo, la visualización de atención por sí sola no permite explicar por qué el clasificador asigna la clase `Normal` o `Abnormal`.

La incorporación de SHAP responde mejor a esta pregunta, ya que calcula las contribuciones de las 1280 características a la salida de CatBoost para cada imagen. Una contribución positiva aumenta la puntuación de `Abnormal` respecto al valor de referencia de SHAP, mientras que una contribución negativa la reduce. Así, el análisis visual queda vinculado a la predicción del clasificador y puede aplicarse tanto a la configuración de referencia como a la variante con CBAM.

Para representar esta información sobre el parche, el procedimiento pondera los mapas de características con sus contribuciones SHAP y los combina. Las regiones destacadas proceden, por tanto, de la combinación de las activaciones espaciales y las contribuciones de sus canales. Esto explica que puedan aparecer patrones localizados aunque el mapa de atención espacial de CBAM sea poco variable ya que la información espacial ya estaba presente en los mapas del extractor.

Los ejemplos obtenidos permiten observar que los mapas pueden cambiar entre configuraciones aunque las predicciones sean similares. También muestran que pueden coexistir regiones positivas y negativas dentro de un mismo parche. Esto ocurre en el ejemplo `Normal` de 80 píxeles clasificado como `Abnormal` por ambas variantes donde se observan zonas azules pero esto no impide que la salida final favorezca `Abnormal`.

Del mismo modo, una probabilidad elevada puede acompañarse de una proyección visualmente tenue. La intensidad del mapa no equivale a la probabilidad predicha y depende también de la escala de color utilizada, que se establece por separado para cada combinación de configuración y tamaño. Por ello, la clase y su probabilidad deben consultarse en la salida del clasificador, sin deducirlas del color predominante o de la intensidad de la imagen.

La selección estratificada amplía estas observaciones a aciertos de distinta confianza y a ambos tipos de error, y lo hace sobre ejemplos por categoría en lugar de casos sueltos. En los aciertos de alta confianza el mapa es casi monocromático y cubre el parche completo, sin delimitar estructuras concretas; en los de baja confianza coexisten regiones de ambos signos con intensidades menores. Los falsos positivos corresponden mayoritariamente a parches oscuros y de textura densa, y los falsos negativos a parches claros y de textura poco marcada. Estas observaciones son compatibles con la señal cromática global descrita en el apartado 4.1.3 : si parte de la información discriminante depende de la proporción entre tejido y fondo claro, los mapas pueden destacar regiones amplias en lugar de estructuras localizadas.

La selección muestra además una diferencia entre variantes que las métricas agregadas no reflejan: CBAM asigna probabilidades más extremas que la configuración de referencia, no solo en los aciertos sino también en los dos tipos de error. La mejora en *accuracy* viene acompañada, en esta muestra, de errores con una confianza más alta y, por tanto, más difíciles de separar mediante un umbral. Sin embargo, al proceder de doce ejemplos por categoría, un único tamaño de parche y una sola semilla, la observación tiene carácter descriptivo y su comprobación requeriría un análisis de calibración sobre el conjunto de prueba completo.

5.1.5. Generalización entre tamaños de parche

El experimento entre resoluciones muestra que el rendimiento depende de la dirección de la transferencia de tamaño. Por ejemplo, entrenar con parches de 80 píxeles y evaluar con los de 160 alcanza un *accuracy* medio del 85,28 %, mientras que la operación inversa obtiene el 67,38 %. El mejor resultado entre tamaños diferentes corresponde al entrenamiento con parches de 120 píxeles y la evaluación con los de 160, con un *accuracy* del 90,49 %.

La asimetría observada indica que una representación útil en una colección no mantiene necesariamente el mismo rendimiento en otra. Entre los factores que podrían explicarla se encuentran el contexto incluido en los parches, el número de imágenes de entrenamiento y el distinto grado de ampliación hasta la entrada de 224×224 píxeles.

El redimensionado es la primera hipótesis a la que prestar atención, ya que los parches de 80 píxeles se amplían en mayor proporción que los de 160. Este proceso puede modificar la apariencia de las texturas que recibe el extractor y contribuir a las diferencias entre las representaciones obtenidas.

Otro detalle a considerar es la normalización. Las imágenes utilizadas para entrenar se normalizan con las estadísticas de la colección de origen, mientras que las imágenes evaluadas utilizan las de la colección de destino. Por tanto, CatBoost conserva sus parámetros, pero el preprocesamiento emplea estadísticas distintas.

Para determinar la contribución real de estos factores serían necesarios experimentos de control que aislasen el efecto de cada factor entre el redimensionado, la normalización y la cantidad de datos de entrenamiento. Los resultados actuales permiten identificar diferencias entre condiciones, pero no establecer su causa.

5.2. Comparación con los trabajos previos

La comparación directa de las cifras obtenidas en este trabajo con las reportadas en la literatura sobre los mismos datos cuenta con matices.

La razón principal de no hacer una comparación directa son las diferencias encontradas en los protocolos de evaluación, las cuales afectan de forma considerable a los resulta-

dos reportados. Entre las diferencias se encuentra la proporción del conjunto reservado para evaluación, el número de repeticiones realizadas, el procedimiento de selección de hiperparámetros o el tratamiento del desbalance de clases. Todos estos condicionan directamente el valor obtenido, de modo que se considera que dos cifras procedentes de protocolos distintos no son estrictamente comparables aunque se refieran al mismo conjunto de datos y a la misma tarea.

5.2.1. Respecto a la configuración arquitectónica

El antecedente mencionado en el estado del arte como motivación de la elección arquitectónica fue objeto de una retractación [18]. Por este motivo, sus cifras no se utilizan como referencia para validar los resultados obtenidos en este trabajo.

Aunque la arquitectura empleada es la misma, el protocolo de evaluación de este trabajo difiere del de la implementación publicada en varios aspectos:

1. **Partición de los datos**. El protocolo adoptado en este trabajo genera una única partición estratificada entre entrenamiento y prueba para cada semilla y se reporta la media de las cinco repeticiones. En la implementación publicada por dichos autores se reporta el mejor resultado obtenido sobre el conjunto de evaluación.. Por tanto, ambos procedimientos no estiman lo mismo, sino que se compara una media de varias ejecuciones con un resultado seleccionado por ser el más favorable. Esta selección puede producir una estimación optimista, por lo que este trabajo no tomó dicho camino en la implementación.

2. **Selección de hiperparámetros**. En este trabajo la selección de los hiperparámetros de CatBoost se realiza mediante validación cruzada de cinco particiones sobre el conjunto de entrenamiento, sin que el conjunto de evaluación intervenga ni vea los datos de entrenamiento en ningún momento. En la implementación de referencia, los hiperparámetros se ajustan atendiendo al rendimiento sobre el propio conjunto de evaluación, que actúa así como conjunto de validación. Esto último supone tener fuga de información en el proyecto y tiene consecuencias en los resultados. Por ello se tomó una decisión sobre cambiar la forma de la partición de los conjuntos de datos con respecto a esta referencia.

3. **Cantidad y distribución de los datos**. Este trabajo utiliza todas las imágenes disponibles en cada tamaño y compensa el desbalance mediante pesos de clase.

La implementación de referencia reduce el número de imágenes mediante submuestreo para obtener cantidades aproximadamente iguales de ambas clases. Por ello, los experimentos difieren tanto en la cantidad de datos utilizados como en la proporción de imágenes `Normal` y `Abnormal`.

No se puede determinar cuánto contribuyen a la diferencia de rendimiento cada uno de estos cambios entre ambos trabajos ya que no se han realizado experimentos para aislar cada uno de los cambios y poder así cuantificar y atribuir la variación a los valores a cada cambio de manera específica.

5.2.2. Relación con el trabajo que motivó la incorporación de atención

Los autores de CoAtNeXt presentan una arquitectura que combina bloques ConvNeXtV2, mecanismos de tipo *Transformer* y atención CBAM [24]. Para el subconjunto de GasHisSDB de 80×80 píxeles, reportan un *accuracy* del 98,29 % y un AUC-ROC de 0,9990, equivalentes al 99,90 %, como resultados medios de una validación cruzada de cinco pliegues. Estas cifras contextualizan el problema, pero no constituyen una comparación directa con las medias de evaluación en prueba obtenidas en este trabajo.

De CoAtNeXt se toma como referencia la incorporación del módulo de atención convolucional, con respecto al resto de elementos. La arquitectura de CoAtNeXt combina bloques convolucionales de tipo ConvNeXtV2 con etapas de tipo *Transformer*, entrenado de principio a fin sobre el dominio de GasHisSDB. En este trabajo, en cambio, se utiliza un extractor congelado preentrenado en ImageNet, seguido de un clasificador basado en árboles de decisión. Por tanto, los resultados pueden situarse como antecedentes dentro de la misma tarea, pero no constituyen una comparación directa que permita medir el efecto de incorporar atención. Para estudiar ese efecto en el sistema desarrollado, la comparación principal se realiza entre la configuración de referencia y la variante con CBAM.

Una diferencia relevante es el entrenamiento del extractor. En este proyecto, los pesos de EfficientNetV2-B0 proceden del preentrenamiento con imágenes naturales y no se actualizan con las imágenes histopatológicas. CBAM sí aprende a modificar la representación obtenida, pero no cambia los filtros del extractor. A diferencia de una arquitectura entrenada extremo a extremo sobre el conjunto de datos deseado, como la empleada en CoAtNeXt, donde también pueden adaptarse las capas encargadas de extraer las características.

En este trabajo, los pesos de EfficientNetV2-B0 permanecen congelados. La adaptación supervisada se realiza en CatBoost y, en la variante correspondiente, también en CBAM. Por tanto, aunque no se actualizan los filtros del extractor, la representación utilizada por el clasificador sí puede modificarse mediante el módulo de atención. No se ha realizado una comparación controlada que permita cuantificar el efecto de mantener congelado el extractor frente a ajustarlo con las imágenes histopatológicas.

Otra diferencia entre los sistemas se encuentra en la cantidad de parámetros que se ajustan durante el entrenamiento. En este proyecto se llegan a entrenar tanto CatBoost como, en la variante correspondiente, el módulo CBAM. Mientras, en una arquitectura entrenada completamente puede adaptar un conjunto más amplio de parámetros ya que pueden actualizarse los pesos del extractor. La diferencia, por tanto, está en qué componentes se adaptan a las imágenes histopatológicas. Permitir esa adaptación podría ser el motivo de la mejora en el rendimiento.

Finalmente, no se ha dispuesto del código de CoAtNeXt para comprobar su implementación. La comparación queda limitada a la información descrita en la publicación y no permite verificar de forma completa la equivalencia del particionado, la selección de hiperparámetros y el tratamiento de los riesgos de fuga de información.

En consecuencia, la diferencia entre las cifras publicadas y las obtenidas aquí no se atribuyen ni a un único factor ni a un error de implementación y no deben interpretarse como una medida aislada de la eficacia del mecanismo de atención.

5.2.3. Sobre el coste computacional

Además del rendimiento, la comparación entre propuestas debe considerar los recursos necesarios para entrenarlas y utilizarlas.

En este proyecto, mantener congelado el extractor evita calcular sus gradientes y actualizar sus pesos durante el entrenamiento. También permite almacenar las características y reutilizarlas en los ajustes de CatBoost, reduciendo la necesidad de procesar repetidamente las mismas imágenes con la red.

Esta reutilización depende de la configuración. Las características de referencia pueden compartirse entre semillas, mientras que el aumento de datos requiere extraer las vistas transformadas. En la variante con CBAM, las características dependen del módu-

lo entrenado para cada tamaño y semilla, por lo que no se utiliza una única extracción común a todos los experimentos.

El diseño permite evitar parte del trabajo asociado al ajuste completo de una red neuronal. No obstante, también incluye el coste de la búsqueda de hiperparámetros de CatBoost, el almacenamiento de características y el entrenamiento de CBAM.

El diseño adoptado evita actualizar los pesos del extractor y permite reutilizar parte de las características. Sin embargo, no se dispone de mediciones comparables que permitan cuantificar el ahorro computacional o establecer una mejor relación entre coste y rendimiento respecto a otros sistemas.

5.3. Limitaciones del estudio

5.3.1. Limitaciones de los datos

- **Dependencias entre parches.** Los parches de GasHisSDB proceden de una colección de 600 imágenes originales [3]. No se garantiza que los parches no compartan entre ellos tejido o imagen de origen. Por lo tanto, aunque se separen los conjuntos de entrenamiento y prueba no se puede garantizar que todo el contenido de una misma WSI acabe dentro de una única partición.

  En consecuencia, los resultados podrían ser optimistas respecto al rendimiento sobre tejidos o sobre pacientes nuevos. Las cinco semillas permiten estudiar variaciones entre divisiones, pero no eliminan esta dependencia.

- **Ausencia de identificadores de procedencia**. Los nombres de los archivos no permiten reconstruir de forma fiable la imagen de origen ni el paciente. La ausencia de identificadores de procedencia limita la posibilidad de establecer particiones independientes por imagen de origen o paciente. Esta limitación debe considerarse al interpretar los resultados y no elimina las diferencias metodológicas entre los trabajos que utilizan GasHisSDB.

- **Duplicados y contenido sin tejido**. El análisis identificó grupos de imágenes idénticas completamente blancas en las colecciones de 80 y 120 píxeles. La separación por archivos no garantiza que copias de una misma imagen queden en una única partición. Aunque estos grupos no contienen estructuras tisulares visibles, su presencia debe distinguirse de la ausencia de duplicados.

- **Ausencia de validación externa**. El estudio se limita a GasHisSDB. No se ha evaluado el sistema sobre una colección independiente que permita examinar su comportamiento ante cambios de procedencia, tinción o digitalización.

5.3.2. Limitaciones metodológicas

- **Entrenamiento de CBAM previo a la validación cruzada.** Para cada semilla, CBAM se ajusta y selecciona utilizando únicamente la partición de entrenamiento, correspondiente al 80 % de las imágenes. Después se congela y sus características se utilizan en la validación cruzada de CatBoost. Por ello, las imágenes de validación de un pliegue pueden haber intervenido previamente en el ajuste o la selección de CBAM. Las puntuaciones de esa validación cruzada no constituyen una evaluación independiente de todo el proceso de aprendizaje. No se ha cuantificado la magnitud del posible sesgo. El 20 % reservado para prueba queda excluido del ajuste supervisado de ambos componentes.

- **Número y dependencia de las repeticiones**. Las cinco semillas permiten describir la variabilidad observada entre ejecuciones, pero todas reutilizan imágenes de la misma colección. No representan cinco muestras independientes de pacientes. Además, aumentar el número de semillas permitiría caracterizar mejor la variabilidad, tampoco garantiza alcanzar mejores resultados.

- **Estimación de las estadísticas de normalización antes del particionado.** Las medias y desviaciones típicas se calcularon sobre una muestra del inventario completo, sin restringir su estimación al conjunto de entrenamiento. Por tanto, el conjunto de prueba no quedó completamente aislado del preprocesamiento. No se ha cuantificado el efecto de esta decisión sobre las métricas obtenidas.

- **Extractor congelado**. El extractor permanece congelado en todas las configuraciones. Esta decisión reduce el coste y permite estudiar las modificaciones propuestas, pero deja fuera la comparación con un *fine-tuning* completo de la red y limita la capacidad de adaptación del extractor al dominio histopatológico.

- **Mismas opciones de hiperparámetros**. Las configuraciones comparten las mismas opciones de búsqueda de CatBoost, aunque los valores seleccionados pueden cambiar según el tamaño, la variante y la semilla. La búsqueda se limita a las combinaciones definidas, esto garantiza la comparabilidad a costa de que cada una opere probablemente por debajo de su óptimo, por lo que no garantiza encontrar el mejor ajuste posible fuera de ese espacio.

5.3.3. Limitaciones de interpretabilidad

La proyección SHAP-CAM es una aproximación: se construye sobre mapas de 7×7 posiciones y la suma de sus valores no coincide, en general, con la suma de las contribuciones SHAP. Además, cada combinación de configuración y tamaño utiliza su propia escala de color, por lo que las intensidades no son comparables entre grupos.

La selección estratificada amplía la inspección visual al incorporar aciertos de alta y baja confianza, falsos positivos y falsos negativos. Sin embargo, los patrones observados no pueden generalizarse al conjunto completo de prueba ni a otros tamaños de parche.

Finalmente, no se dispone de anotaciones espaciales de especialistas ni de pruebas de perturbación que permitan evaluar la fidelidad de las regiones destacadas. Las visualizaciones sirven para explorar el comportamiento del sistema y plantear hipótesis, pero no demuestran que sus decisiones se basen en estructuras histológicas concretas.

5.4. Aportaciones del trabajo

Las aportaciones del proyecto se centran en la implementación, la comparación experimental y el análisis crítico de los resultados.

1. **Implementación de una configuración de referencia documentada.** Se ha desarrollado un sistema que combina EfficientNetV2-B0 como extractor congelado y CatBoost como clasificador, con separación de las etapas de procesamiento, extracción, selección de hiperparámetros y evaluación.

2. **Comparación de dos modificaciones del sistema.** Se han evaluado el aumento de datos y la incorporación de CBAM en los tres tamaños de parche. Ambas configuraciones mejoran las medias de *accuracy* de la referencia bajo el protocolo empleado.

3. **Análisis de la variabilidad y de los errores.** La evaluación con cinco semillas, las matrices de confusión y las métricas por clase permiten describir las mejoras con más detalle que una única cifra de *accuracy*.

4. **Exploración de la transferencia entre tamaños.** Se ha examinado el comportamiento del clasificador al cambiar el tamaño original de los parches, identificando diferencias según la dirección de transferencia y posibles factores para estudiar en experimentos posteriores.

5. **Análisis de interpretabilidad.** Se han examinado los mapas de atención espacial de CBAM y las contribuciones SHAP de CatBoost, proyectadas sobre los parches, tanto en ejemplos ilustrativos como en una selección estratificada de aciertos y errores.

6. **Identificación de limitaciones de los datos y del procedimiento.** Se han documentado la imposibilidad de recuperar la procedencia de los parches, la presencia de duplicados sin tejido visible y las restricciones de la validación y la interpretación. Estos hallazgos delimitan el alcance de los resultados y orientan las mejoras futuras.

6. Conclusiones y trabajo futuro

En este capítulo se valora el trabajo realizado con relación a los objetivos fijados al inicio. En la sección 6.1 se extraen las conclusiones principales y en la sección 6.2 se proponen líneas de trabajo que han quedado abiertas o líneas de mejora.

6.1. Conclusiones principales

El trabajo, desarrollado en cuatro fases, ha permitido construir y evaluar un sistema de clasificación binaria sobre GasHisSDB. La primera fase comprende el análisis exploratorio de los datos y la construcción de un entorno reproducible y documentado. La segunda se centra en el diseño y la evaluación de la configuración de referencia. En la tercera se diseñan e implementan los experimentos de mejora sobre esa línea base y, finalmente, la cuarta se dedica al análisis y la interpretación de los resultados obtenidos. A continuación, se sintetizan las principales conclusiones, considerando las limitaciones de los datos y del procedimiento experimental, y se valora el cumplimiento de los objetivos planteados.

- **Las diferencias entre tamaños de parche superan las mejoras aportadas por las modificaciones evaluadas.** En la configuración de referencia, el *accuracy* medio aumenta 3,60 puntos porcentuales entre las colecciones de 80 y 160 píxeles. Esta diferencia supera los incrementos obtenidos mediante el aumento de datos y CBAM respecto a la referencia. El tamaño original del parche es, por tanto, un factor relevante para interpretar los resultados, aunque su efecto no puede separarse del de la cantidad y composición de las imágenes de cada colección.

- **La arquitectura de referencia es sólida, pero mejorable.** La combinación de EfficientNetV2-B0 congelado y CatBoost ha proporcionado una configuración de referencia que alcanza entre un 89,64 % y un 93,24 % de *accuracy* según la resolución. Las métricas complementarias muestran que la clasificación reconoce ambas clases y supera ampliamente la asignación constante a Normal. Esto respalda la utilidad experimental de las características preentrenadas para la tarea. Sin

embargo, que los otros experimentos probados obtengan mejores resultados de rendimiento significa que aún existe margen de mejora.

- **El aumento de datos mejora de forma consistente la configuración de referencia con poca complejidad arquitectónica adicional.** El aumento geométrico ha mejorado el *accuracy* medio en 1,13, 0,95 y 1,14 puntos porcentuales. Las cinco semillas favorecen a esta variante frente a la referencia en los tres tamaños. Se ha observado, por tanto, una mejora consistente al incorporar orientaciones adicionales únicamente durante el ajuste del clasificador. Esta modificación no incorpora otro módulo neuronal entrenable, aunque aumenta el almacenamiento de características y el número de observaciones procesadas en cada ajuste de CatBoost.

- **CBAM obtiene el mayor *accuracy* medio entre las configuraciones evaluadas.** La variante con CBAM alcanza un *accuracy* medio del 91,80 %, 93,46 % y 94,70 % para los parches de 80, 120 y 160 píxeles, respectivamente. Supera a la configuración de referencia en las cinco semillas de cada tamaño.

- **La ventaja de CBAM es especialmente pronunciada en los parches de 80 píxeles.** Frente al aumento de datos, la mejora media del *accuracy* es de 1,04 puntos porcentuales en 80 píxeles, frente a 0,27 y 0,32 en 120 y 160 píxeles. Este resultado identifica dónde se observa la mayor ventaja, pero no permite determinar su causa.

- **La transferencia entre escalas es asimétrica**. La evaluación entre colecciones muestra diferencias según la dirección de la transferencia. Entrenar en la resolución menor generaliza mejor hacia las mayores que a la inversa. El *accuracy* medio al entrenar con parches de 80 píxeles y evaluar con los de 160 píxeles es del 85,28 %, mientras que en la dirección inversa es del 67,38 %. Esta diferencia muestra una marcada asimetría en la transferencia entre tamaños dentro de GasHisSDB. El contexto, la cantidad de datos, el redimensionado y la normalización podrían influir en este comportamiento, pero sus efectos no se han aislado.

- **La atención y SHAP aportan información complementaria para explorar las predicciones.** Los mapas espaciales de CBAM presentan pesos próximos a uno y poca variación en los ejemplos examinados. Esto limita la evidencia de una ponderación espacial diferenciada.

  SHAP permite estudiar la contribución de las características a las predicciones de CatBoost, tanto en la referencia como en la variante con CBAM. La inspección de

sus proyecciones espaciales se amplió mediante una selección de aciertos de alta y baja confianza, falsos positivos y falsos negativos en parches de 160 píxeles. Esta selección permite explorar situaciones que no estaban cubiertas por los ejemplos iniciales, especialmente los falsos negativos. Los mapas obtenidos no demuestran una localización de estructuras tumorales ni permiten determinar qué componente de CBAM explica la mejora.

- **El análisis de los datos y del protocolo delimita el alcance de los resultados.** Se ha documentado en este documento la presencia de duplicados sin tejido visible y la imposibilidad de recuperar la procedencia de los parches a partir de los identificadores disponibles.

En relación con los objetivos específicos planteados en la sección 1.3, se considera que se han alcanzado el estudio del problema y del estado del arte (objetivo 1), el análisis del conjunto de datos (objetivo 2), la evaluación del aumento de datos (objetivo 4) y el estudio del comportamiento entre tamaños de parche (objetivo 6). El (objetivo 3) se ha cumplido en cuanto al diseño, la implementación y la evaluación de la configuración de referencia, aunque la independencia del conjunto de prueba queda condicionada por la estimación de las estadísticas de normalización antes del particionado y por la ausencia de identificadores de procedencia, descritas en la sección 5.3. El objetivo 5 también se ha alcanzado, con el detalle de que CBAM se entrena antes de la validación cruzada de CatBoost, por lo que esta no constituye una validación independiente de todo el proceso de aprendizaje de la variante. El (objetivo 7) se ha abordado con carácter exploratorio, ya que los mapas de atención y las proyecciones SHAP permiten examinar el comportamiento del sistema, pero no validar la relevancia histológica de las regiones destacadas. Por último, el análisis crítico de los resultados (objetivo 8) se recoge en el capítulo 5, donde se identifican las limitaciones que orientan el trabajo futuro.

6.2. Trabajo futuro

Las ideas de continuación del trabajo pueden agruparse en dos bloques, aquellas que tienen como objetivo resolver las limitaciones encontradas a lo largo del proyecto y aquellas que exploran preguntas que el trabajo ha abierto.

- **Identificación de grupos de parches.** La prioridad metodológica es disponer de un conjunto que permita agrupar los parches por imagen de origen. Esto permitiría separar entrenamiento, validación y prueba con la seguridad de que no se comparten datos entre los conjuntos. Si en el futuro no se llegase a publicar información

de procedencia para GasHisSDB, resultaría necesario recurrir a otra colección con metadatos adecuados.

- **Otras estrategias frente al desbalance.** El desbalance se ha compensado únicamente mediante pesos de clase. Comparar esta decisión con procedimientos de remuestreo, como el submuestreo de la clase `Normal` o el sobremuestreo de `Abnormal`, y con el ajuste del umbral de decisión sobre los datos de validación, permitiría valorar si alguna de estas alternativas mejora la detección de la clase minoritaria sin penalizar la especificidad.

- **Validación externa.** Relacionado con el punto anterior, sería interesante evaluar la configuración seleccionada sobre un conjunto independiente de imágenes histopatológicas gástricas, procedente de otros pacientes y centros. Esta evaluación permitiría estudiar si el rendimiento se mantiene ante diferencias de preparación, tinción y digitalización realizada por el personal de los centros, siempre que las etiquetas y la tarea fueran compatibles con las utilizadas en este trabajo.

- **Ampliar el número de semillas.** Una posible continuación del trabajo consiste en ampliar el número de semillas utilizadas en los experimentos. Las cinco repeticiones realizadas permiten obtener una primera estimación del rendimiento medio y de su variabilidad. Sin embargo, superar las cinco semillas permitiría caracterizar mejor la sensibilidad de los resultados a la partición de los datos y a las fuentes de aleatoriedad del entrenamiento.

- **Entrenar CBAM dentro de cada pliegue de validación cruzada.** Repetir la selección de hiperparámetros entrenando CBAM exclusivamente con las imágenes de entrenamiento de cada pliegue y reservando, dentro de ellas, la partición necesaria para determinar la parada del entrenamiento. Las imágenes de validación del pliegue deben permanecer ajenas tanto al ajuste como a la selección de CBAM. Se deberá evaluar el coste temporal y la memoria máxima del procedimiento, considerando la ejecución secuencial de los entrenamientos y la liberación de recursos entre ellos.

- ***Fine-tuning* del extractor**. Descongelar EfficientNetV2-B0 permitiría comparar el resultado obtenido con la configuración de referencia y así determinar cuánto rendimiento se sacrifica por mantener el extractor fijo. Además, si se registraran los tiempos, la memoria y el tamaño de los modelos, permitiría comparar la utilidad y el coste de forma rigurosa. Esta información ayudaría a decidir si una mejora pequeña compensa el almacenamiento adicional de vistas o el aprendizaje del módulo

de atención. La selección de una configuración práctica debe apoyarse en ambos aspectos y en la validez de su evaluación.

- **Estimación de la normalización dentro del entrenamiento.** Las estadísticas de normalización se calcularon antes del particionado. Como mejora, las medias y desviaciones típicas podrían estimarse únicamente a partir de las imágenes de entrenamiento y aplicarse sin cambios a validación y prueba. En la validación cruzada, este procedimiento debería repetirse dentro de cada pliegue, excluyendo los datos utilizados para validarlo.

- **Medición del coste computacional.** La ausencia de mediciones comparables impide cuantificar la relación entre rendimiento y recursos de las configuraciones. Por ello, se propone repetir el proyecto añadiendo un registro de los tiempos de extracción de características, entrenamiento y predicción, así como la memoria máxima y el almacenamiento necesarios. Estas mediciones permitirían valorar mejor la relación entre el coste y la mejora de los experimentos realizados.

- **Validación de las explicaciones.** Comprobar la fidelidad de las proyecciones SHAP mediante comparaciones con anotaciones de especialistas. Además, extender la selección estratificada al resto de tamaños y semillas, con una selección pareada que permita comparar ambos modelos sobre los mismos parches.

- **Combinación del aumento de datos y CBAM.** Las dos modificaciones se han evaluado por separado sobre la misma configuración de referencia, pero actúan en puntos distintos del sistema: el aumento de datos incorpora orientaciones adicionales durante el ajuste de CatBoost, mientras que CBAM modifica la representación antes de la agrupación global promedio. Evaluarlas de forma conjunta permitiría comprobar si sus mejoras se acumulan, se solapan parcialmente o se anulan.

- **Estudio de ablación de CBAM.** Comparar variantes sin atención, con atención de canal, con atención espacial y con ambos mecanismos, bajo un protocolo común, para determinar qué componente explica la mejora observada.

- **Ampliación del espacio de búsqueda.** Todas las ejecuciones seleccionaron 700 iteraciones, el valor máximo explorado. Ampliar este límite, junto con las tasas de aprendizaje y las profundidades evaluadas, permitiría comprobar si el rendimiento continúa mejorando o se estabiliza.

Bibliografía

[1] Saleh Albelwi and Ausif Mahmood. A framework for designing the architectures of deep convolutional neural networks. *Entropy*, 19(6):242, 2017. doi: 10.3390/e19060242. URL https://doi.org/10.3390/e19060242.

[2] Wanderson Gonçalves e Gonçalves, Marcelo Henrique Paula dos Santos, Leonardo Miranda Brito, Helber Gonzales Almeida Palheta, Fábio Manoel França Lobato, Samia Demachki, Ândrea Ribeiro-dos Santos, and Gilderlanio Santana de Araújo. DeepHP: A new gastric mucosa histopathology dataset for *Helicobacter pylori* infection diagnosis. *International Journal of Molecular Sciences*, 23(23):14581, 2022. doi: 10.3390/ijms232314581. URL https://doi.org/10.3390/ijms232314581.

[3] Weiming Hu, Chen Li, Xiaoyan Li, Md Mamunur Rahaman, Jiquan Ma, Yong Zhang, Haoyuan Chen, Wanli Liu, Changhao Sun, Yudong Yao, Hongzan Sun, and Marcin Grzegorzek. Gashissdb: A new gastric histopathology image dataset for computer aided diagnosis of gastric cancer. *Computers in Biology and Medicine*, 142:105207, 2022. ISSN 0010-4825. doi: https://doi.org/10.1016/j.compbiomed.2021.105207. URL https://www.sciencedirect.com/science/article/pii/S0010482521010015.

[4] Sociedad Española de Oncología Médica. Las cifras del cáncer en españa 2025, 2025. URL https://seom.org/images/LAS_CIFRAS_DMC2025.pdf.

[5] National Cancer Institute. Cancer Stat Facts: Stomach Cancer. Surveillance, Epidemiology, and End Results (SEER) Program. URL https://seer.cancer.gov/statfacts/html/stomach.html. Datos de supervivencia de 2016–2022.

[6] Instituto Nacional del Cáncer. Diagnóstico del cáncer de estómago, 2023. URL https://www.cancer.gov/espanol/tipos/estomago/diagnostico. Actualizado el 31 de mayo de 2023.

[7] Yann LeCun, Léon Bottou, Yoshua Bengio, and Patrick Haffner. Gradient-based learning applied to document recognition. *Proceedings of the IEEE*, 86(11):2278–2324, 1998. doi: 10.1109/5.726791. URL https://doi.org/10.1109/5.726791.

[8] Ian Goodfellow, Yoshua Bengio, and Aaron Courville. *Deep Learning*. MIT Press, 2016. http://www.deeplearningbook.org.

[9] Jia Deng, Wei Dong, Richard Socher, Li-Jia Li, Kai Li, and Li Fei-Fei. ImageNet: A large-scale hierarchical image database. In *2009 IEEE Conference on Computer Vision and Pattern Recognition*, pages 248–255, 2009. doi: 10.1109/CVPR.2009.5206848. URL https://doi.org/10.1109/CVPR.2009.5206848.

[10] Jason Yosinski, Jeff Clune, Yoshua Bengio, and Hod Lipson. How transferable are features in deep neural networks? In Z. Ghahramani, M. Welling, C. Cortes, N. Lawrence, and K. Weinberger, editors, *Advances in Neural Information Processing Systems*, volume 27. Curran Associates, Inc., 2014. URL https://proceedings.neurips.cc/paper_files/paper/2014/file/532a2f85b6977104bc93f8580abbb330-Paper.pdf.

[11] Neeta Kumar, Ruchika Gupta, and Sanjay Gupta. Whole slide imaging (WSI) in pathology: Current perspectives and future directions. *Journal of Digital Imaging*, 33(4):1034–1040, 2020. doi: 10.1007/s10278-020-00351-z. URL https://doi.org/10.1007/s10278-020-00351-z.

[12] Richard J. Chen, Tong Ding, Ming Y. Lu, et al. Towards a general-purpose foundation model for computational pathology. *Nature Medicine*, 30:850–862, 2024. doi: 10.1038/s41591-024-02857-3. URL https://doi.org/10.1038/s41591-024-02857-3.

[13] Mingxing Tan and Quoc Le. EfficientNet: Rethinking model scaling for convolutional neural networks. In *Proceedings of the 36th International Conference on Machine Learning*, volume 97 of *Proceedings of Machine Learning Research*, pages 6105–6114, 2019. URL https://proceedings.mlr.press/v97/tan19a.html.

[14] Mingxing Tan and Quoc V. Le. Efficientnetv2: Smaller models and faster training, 2021. URL https://arxiv.org/abs/2104.00298.

[15] PyTorch Image Models. Model card for tf_efficientnetv2_b0.in1k. Ficha oficial del modelo en Hugging Face. URL https://huggingface.co/timm/tf_efficientnetv2_b0.in1k.

[16] Liudmila Prokhorenkova, Gleb Gusev, Aleksandr Vorobev, Anna Veronika Dorogush, and Andrey Gulin. CatBoost: unbiased boosting

with categorical features. In *Advances in Neural Information Processing Systems*, volume 31, 2018. URL https://papers.nips.cc/paper/7898-catboost-unbiased-boosting-with-categorical-features.

[17] Danial Khayatian, Alireza Maleki, Hamid Nasiri, and Morteza Dorrigiv. Histopathology image analysis for gastric cancer detection: a hybrid deep learning and catboost approach. *Multimedia Tools and Applications*, 84:21777–21803, 2025. doi: 10.1007/s11042-024-19816-2. URL https://doi.org/10.1007/s11042-024-19816-2. Artículo retractado el 16 de junio de 2026. Véase doi:10.1007/s11042-026-21725-5.

[18] Danial Khayatian, Alireza Maleki, Hamid Nasiri, and Morteza Dorrigiv. Retraction note: Histopathology image analysis for gastric cancer detection: a hybrid deep learning and catboost approach. *Multimedia Tools and Applications*, 85, 2026. doi: 10.1007/s11042-026-21725-5. URL https://doi.org/10.1007/s11042-026-21725-5. Artículo 565. Publicado el 16 de junio de 2026.

[19] scikit-learn developers. Cross-validation: evaluating estimator performance. Documentación de scikit-learn 1.5, . URL https://scikit-learn.org/1.5/modules/cross_validation.html.

[20] scikit-learn developers. Common pitfalls and recommended practices. Documentación de scikit-learn 1.5, . URL https://scikit-learn.org/1.5/common_pitfalls.html.

[21] Nicole Bussola, Alessia Marcolini, Valerio Maggio, Giuseppe Jurman, and Cesare Furlanello. AI slipping on tiles: data leakage in digital pathology, 2019. URL https://arxiv.org/abs/1909.06539. Prepublicación en arXiv:1909.06539. Versión revisada en 2020.

[22] David Tellez, Geert Litjens, Péter Bándi, Wouter Bulten, John-Melle Bokhorst, Francesco Ciompi, and Jeroen van der Laak. Quantifying the effects of data augmentation and stain color normalization in convolutional neural networks for computational pathology. *Medical Image Analysis*, 58:101544, 2019. ISSN 1361-8415. doi: https://doi.org/10.1016/j.media.2019.101544. URL https://www.sciencedirect.com/science/article/pii/S1361841519300799.

[23] Sanghyun Woo, Jongchan Park, Joon-Young Lee, and In So Kweon. Cbam: Convolutional block attention module, 2018. URL https://arxiv.org/abs/1807.06521.

[24] Mustafa Yurdakul and Sakir Tasdemir. Coatnext:an attention-enhanced convnextv2-transformer hybrid model for gastric tissue classification, 2025. URL https://arxiv.org/abs/2509.09242.

[25] Bolei Zhou, Aditya Khosla, Agata Lapedriza, Aude Oliva, and Antonio Torralba. Learning deep features for discriminative localization. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 2921–2929, 2016. doi: 10.1109/CVPR.2016.319.

[26] Ramprasaath R. Selvaraju, Michael Cogswell, Abhishek Das, Ramakrishna Vedantam, Devi Parikh, and Dhruv Batra. Grad-CAM: Visual explanations from deep networks via gradient-based localization. In *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, pages 618–626, 2017. doi: 10.1109/ICCV.2017.74.

[27] Scott M Lundberg and Su-In Lee. A unified approach to interpreting model predictions. In I. Guyon, U. Von Luxburg, S. Bengio, H. Wallach, R. Fergus, S. Vishwanathan, and R. Garnett, editors, *Advances in Neural Information Processing Systems*, volume 30. Curran Associates, Inc., 2017. URL https://proceedings.neurips.cc/paper_files/paper/2017/file/8a20a8621978632d76c43dfd28b67767-Paper.pdf.

[28] Docker, Inc. What is a Container?, s. f. URL https://www.docker.com/resources/what-container/.

[29] Diederik P. Kingma and Jimmy Ba. Adam: A method for stochastic optimization, 2017. URL https://arxiv.org/abs/1412.6980.

[30] CatBoost. ShapValues. Documentación oficial de CatBoost. URL https://catboost.ai/docs/en/concepts/shap-values.

[31] scikit-learn developers. Metrics and scoring: quantifying the quality of predictions. Documentación de scikit-learn 1.5, . URL https://scikit-learn.org/stable/modules/model_evaluation.html.

A. Guía de reproducibilidad

Este anexo reúne las indicaciones generales para reconstruir el entorno y ejecutar los experimentos del trabajo. Las especificaciones del equipo, las versiones principales de las bibliotecas y la organización del proyecto se describen en la Sección 3.1.

A.1. Repositorio y documentación del entorno

El repositorio asociado al proyecto es:

`https://github.com/lvs42/GastricCancer`

La construcción del contenedor se define mediante `Dockerfile` y `docker-compose.yml`, junto con las dependencias declaradas en `requirements.txt`. Estos archivos permiten consultar la configuración concreta del entorno sin reproducir su contenido en la memoria.

El archivo `requirements-lock.txt` recoge el inventario de paquetes del entorno consultado. Algunas entradas contienen rutas locales, por lo que debe interpretarse como documentación del entorno y no como un archivo de instalación portable.

A.2. Secuencia general de ejecución

Para repetir el procedimiento experimental, deben seguirse los siguientes pasos:

1. Obtener una copia del repositorio.
2. Disponer de GasHisSDB y configurar las rutas de acceso a las imágenes y de almacenamiento de los resultados.
3. Construir el entorno mediante los archivos de Docker y comprobar la disponibilidad de la GPU para las operaciones que requieren aceleración.
4. Ejecutar el programa de experimentos, seleccionando el tamaño de parche y la configuración correspondiente: referencia, aumento de datos o CBAM. Deben mantenerse el preprocesamiento y los parámetros descritos en Metodología.

B. Resultados detallados por semilla

Este anexo presenta el desglose de las 45 ejecuciones correspondientes a las tres configuraciones, los tres tamaños de parche y las cinco semillas evaluadas. Cada registro contiene el resultado de una evaluación final sobre la partición de prueba de esa ejecución.

Los identificadores `baseline`, `augmentation` y `cbam` corresponden, respectivamente, a la configuración de referencia, al aumento de datos y a la incorporación de CBAM. El tamaño indicado es el lado del parche original, expresado en píxeles.

B.1. Métricas de clasificación

La Tabla B.1 recoge las principales métricas por ejecución. Se expresan en la escala de 0 a 1 y se redondean a cuatro decimales únicamente para su presentación.

Las columnas Exact. y Bal. representan el *accuracy* y el *balanced accuracy*. Prec. y Sens. corresponden a la precisión y sensibilidad de la clase positiva `Abnormal`. Esp. representa la especificidad, F1m el F1 macro y AUC el área bajo la curva ROC.

Tabla B.1.: Métricas de clasificación por configuración, tamaño de parche y semilla.

Config.	px	Sem.	Exact.	Bal.	Prec.	Sens.	Esp.	F1m	AUC
baseline	80	42	0,8941	0,8942	0,8507	0,8946	0,8938	0,8909	0,9619
baseline	80	43	0,8956	0,8960	0,8512	0,8981	0,8939	0,8925	0,9624
baseline	80	44	0,8986	0,8987	0,8565	0,8992	0,8982	0,8954	0,9633
baseline	80	45	0,8970	0,8966	0,8564	0,8946	0,8986	0,8937	0,9626
baseline	80	46	0,8965	0,8961	0,8561	0,8938	0,8984	0,8932	0,9626
augmentation	80	42	0,9045	0,9048	0,8633	0,9067	0,9030	0,9015	0,9677
augmentation	80	43	0,9073	0,9077	0,8668	0,9100	0,9054	0,9044	0,9695
augmentation	80	44	0,9091	0,9090	0,8716	0,9085	0,9095	0,9062	0,9702
augmentation	80	45	0,9081	0,9080	0,8700	0,9077	0,9083	0,9052	0,9701
augmentation	80	46	0,9091	0,9086	0,8738	0,9055	0,9116	0,9061	0,9699
cbam	80	42	0,9178	0,9182	0,8813	0,9203	0,9162	0,9152	0,9761
cbam	80	43	0,9178	0,9181	0,8814	0,9199	0,9163	0,9151	0,9756

Config.	px	Sem.	Exact.	Bal.	Prec.	Sens.	Esp.	F1m	AUC
cbam	80	44	0,9177	0,9185	0,8795	0,9225	0,9145	0,9152	0,9760
cbam	80	45	0,9188	0,9184	0,8862	0,9163	0,9205	0,9161	0,9759
cbam	80	46	0,9177	0,9178	0,8828	0,9179	0,9176	0,9151	0,9752
baseline	120	42	0,9229	0,9221	0,8827	0,9192	0,9251	0,9188	0,9765
baseline	120	43	0,9256	0,9240	0,8903	0,9174	0,9307	0,9215	0,9776
baseline	120	44	0,9216	0,9191	0,8876	0,9087	0,9294	0,9171	0,9754
baseline	120	45	0,9209	0,9206	0,8784	0,9192	0,9220	0,9168	0,9769
baseline	120	46	0,9210	0,9190	0,8848	0,9107	0,9273	0,9167	0,9749
augmentation	120	42	0,9326	0,9312	0,9000	0,9254	0,9370	0,9288	0,9824
augmentation	120	43	0,9324	0,9320	0,8959	0,9303	0,9338	0,9288	0,9814
augmentation	120	44	0,9330	0,9306	0,9047	0,9206	0,9406	0,9291	0,9816
augmentation	120	45	0,9324	0,9316	0,8972	0,9284	0,9348	0,9287	0,9822
augmentation	120	46	0,9293	0,9281	0,8943	0,9230	0,9331	0,9254	0,9811
cbam	120	42	0,9393	0,9370	0,9142	0,9274	0,9466	0,9358	0,9851
cbam	120	43	0,9383	0,9374	0,9063	0,9341	0,9408	0,9349	0,9856
cbam	120	44	0,9369	0,9347	0,9097	0,9258	0,9436	0,9332	0,9845
cbam	120	45	0,9291	0,9267	0,8991	0,9163	0,9370	0,9251	0,9805
cbam	120	46	0,9293	0,9283	0,8934	0,9242	0,9324	0,9255	0,9797
baseline	160	42	0,9304	0,9290	0,9037	0,9219	0,9360	0,9274	0,9821
baseline	160	43	0,9326	0,9310	0,9069	0,9238	0,9382	0,9296	0,9812
baseline	160	44	0,9320	0,9287	0,9139	0,9135	0,9439	0,9288	0,9821
baseline	160	45	0,9332	0,9317	0,9073	0,9250	0,9385	0,9303	0,9819
baseline	160	46	0,9338	0,9316	0,9118	0,9211	0,9420	0,9308	0,9834
augmentation	160	42	0,9426	0,9402	0,9259	0,9288	0,9516	0,9400	0,9870
augmentation	160	43	0,9407	0,9392	0,9185	0,9322	0,9462	0,9380	0,9858
augmentation	160	44	0,9431	0,9410	0,9251	0,9310	0,9509	0,9405	0,9869
augmentation	160	45	0,9441	0,9436	0,9189	0,9413	0,9459	0,9417	0,9865
augmentation	160	46	0,9486	0,9469	0,9316	0,9387	0,9551	0,9463	0,9878
cbam	160	42	0,9473	0,9458	0,9281	0,9390	0,9526	0,9449	0,9879
cbam	160	43	0,9465	0,9442	0,9315	0,9330	0,9554	0,9440	0,9877
cbam	160	44	0,9453	0,9432	0,9284	0,9333	0,9531	0,9428	0,9877
cbam	160	45	0,9501	0,9489	0,9315	0,9429	0,9549	0,9479	0,9892
cbam	160	46	0,9456	0,9436	0,9284	0,9341	0,9531	0,9431	0,9886

Las cinco ejecuciones reutilizan imágenes de la misma colección. Por ello, sus resultados permiten describir la variabilidad entre particiones, pero no representan cinco muestras independientes de pacientes.

B.2. Matrices de confusión por ejecución

La Tabla B.2 presenta los recuentos de cada ejecución. Se considera positiva la clase `Abnormal` y negativa la clase `Normal`.

VN representa los verdaderos negativos; FP, los falsos positivos; FN, los falsos negativos; y VP, los verdaderos positivos.

Tabla B.2.: Recuentos de las matrices de confusión por configuración, tamaño de parche y semilla.

Config.	px	Sem.	VN	FP	FN	VP
baseline	80	42	15642	1858	1247	10584
baseline	80	43	15643	1857	1205	10626
baseline	80	44	15718	1782	1193	10638
baseline	80	45	15725	1775	1247	10584
baseline	80	46	15722	1778	1257	10574
augmentation	80	42	15802	1698	1104	10727
augmentation	80	43	15845	1655	1065	10766
augmentation	80	44	15917	1583	1082	10749
augmentation	80	45	15896	1604	1092	10739
augmentation	80	46	15953	1547	1118	10713
cbam	80	42	16033	1467	943	10888
cbam	80	43	16036	1464	948	10883
cbam	80	44	16004	1496	917	10914
cbam	80	45	16108	1392	990	10841
cbam	80	46	16058	1442	971	10860
baseline	120	42	7486	606	401	4560
baseline	120	43	7531	561	410	4551
baseline	120	44	7521	571	453	4508
baseline	120	45	7461	631	401	4560
baseline	120	46	7504	588	443	4518
augmentation	120	42	7582	510	370	4591
augmentation	120	43	7556	536	346	4615
augmentation	120	44	7611	481	394	4567
augmentation	120	45	7564	528	355	4606
augmentation	120	46	7551	541	382	4579
cbam	120	42	7660	432	360	4601
cbam	120	43	7613	479	327	4634
cbam	120	44	7636	456	368	4593
cbam	120	45	7582	510	415	4546
cbam	120	46	7545	547	376	4585
baseline	160	42	3774	258	205	2420
baseline	160	43	3783	249	200	2425

Config.	px	Sem.	VN	FP	FN	VP
baseline	160	44	3806	226	227	2398
baseline	160	45	3784	248	197	2428
baseline	160	46	3798	234	207	2418
augmentation	160	42	3837	195	187	2438
augmentation	160	43	3815	217	178	2447
augmentation	160	44	3834	198	181	2444
augmentation	160	45	3814	218	154	2471
augmentation	160	46	3851	181	161	2464
cbam	160	42	3841	191	160	2465
cbam	160	43	3852	180	176	2449
cbam	160	44	3843	189	175	2450
cbam	160	45	3850	182	150	2475
cbam	160	46	3843	189	173	2452

Los recuentos de distintas semillas no deben sumarse como si correspondieran a imágenes diferentes, ya que una misma imagen puede formar parte de la partición de prueba en varias ejecuciones.

B.3. Hiperparámetros seleccionados

La Tabla B.3 recoge los hiperparámetros de CatBoost seleccionados para cada configuración, tamaño y semilla. Las columnas Iter., Prof. y Tasa corresponden al número de iteraciones, la profundidad de los árboles y la tasa de aprendizaje.

Tabla B.3.: Hiperparámetros seleccionados de CatBoost por configuración, tamaño de parche y semilla.

Config.	px	Sem.	Iter.	Prof.	Tasa
baseline	80	42	700	6	0,20
baseline	80	43	700	6	0,20
baseline	80	44	700	6	0,20
baseline	80	45	700	6	0,20
baseline	80	46	700	6	0,20
augmentation	80	42	700	8	0,20
augmentation	80	43	700	8	0,20
augmentation	80	44	700	8	0,20
augmentation	80	45	700	8	0,20
augmentation	80	46	700	8	0,20
cbam	80	42	700	6	0,10

Config.	px	Sem.	Iter.	Prof.	Tasa
cbam	80	43	700	6	0,10
cbam	80	44	700	4	0,20
cbam	80	45	700	8	0,10
cbam	80	46	700	4	0,10
baseline	120	42	700	6	0,10
baseline	120	43	700	6	0,20
baseline	120	44	700	6	0,20
baseline	120	45	700	6	0,10
baseline	120	46	700	8	0,10
augmentation	120	42	700	6	0,20
augmentation	120	43	700	6	0,20
augmentation	120	44	700	8	0,20
augmentation	120	45	700	8	0,10
augmentation	120	46	700	8	0,20
cbam	120	42	700	6	0,10
cbam	120	43	700	6	0,05
cbam	120	44	700	6	0,10
cbam	120	45	700	8	0,10
cbam	120	46	700	6	0,10
baseline	160	42	700	6	0,10
baseline	160	43	700	6	0,10
baseline	160	44	700	8	0,10
baseline	160	45	700	8	0,10
baseline	160	46	700	8	0,10
augmentation	160	42	700	8	0,20
augmentation	160	43	700	8	0,20
augmentation	160	44	700	8	0,10
augmentation	160	45	700	8	0,10
augmentation	160	46	700	8	0,20
cbam	160	42	700	6	0,05
cbam	160	43	700	8	0,05
cbam	160	44	700	8	0,05
cbam	160	45	700	8	0,05
cbam	160	46	700	8	0,10

La tabla documenta las combinaciones seleccionadas dentro del espacio de búsqueda definido. Su selección no implica que constituyan la mejor configuración posible fuera de dicho espacio.

C. Resultados de transferencia entre tamaños de parche

Este anexo recoge las 30 evaluaciones correspondientes a las seis direcciones de transferencia entre tamaños de parche y las cinco semillas utilizadas.

Origen identifica el tamaño de parche empleado para entrenar el clasificador y destino el tamaño de la colección sobre la que se evalúa. Ambos se expresan como la longitud del lado del parche original en píxeles.

La Tabla C.1 presenta las métricas seleccionadas en la escala de 0 a 1, con cuatro decimales. Exact. representa el *accuracy*; Sens., la sensibilidad de `Abnormal`; Esp., la especificidad; F1m, el F1 macro; y AUC, el área bajo la curva ROC.

Tabla C.1.: Resultados de transferencia entre tamaños de parche por semilla.

Origen	Destino	Sem.	Exact.	Sens.	Esp.	F1m	AUC
80	120	42	0,8955	0,7938	0,9578	0,8857	0,9650
80	120	43	0,8928	0,7780	0,9632	0,8821	0,9663
80	120	44	0,8939	0,7879	0,9589	0,8838	0,9659
80	120	45	0,8934	0,7812	0,9623	0,8829	0,9661
80	120	46	0,8945	0,7923	0,9571	0,8846	0,9656
80	160	42	0,8557	0,7102	0,9504	0,8419	0,9450
80	160	43	0,8498	0,6723	0,9654	0,8327	0,9506
80	160	44	0,8565	0,7018	0,9572	0,8420	0,9479
80	160	45	0,8483	0,6670	0,9664	0,8308	0,9502
80	160	46	0,8534	0,6968	0,9554	0,8385	0,9471
120	80	42	0,7821	0,9628	0,6599	0,7821	0,9323
120	80	43	0,7935	0,9595	0,6813	0,7935	0,9336
120	80	44	0,7901	0,9589	0,6760	0,7901	0,9316
120	80	45	0,7825	0,9619	0,6611	0,7825	0,9316
120	80	46	0,7883	0,9608	0,6718	0,7883	0,9335
120	160	42	0,9064	0,7959	0,9784	0,8985	0,9779
120	160	43	0,9040	0,7873	0,9800	0,8957	0,9778
120	160	44	0,9053	0,7923	0,9788	0,8972	0,9774
120	160	45	0,9050	0,7904	0,9796	0,8968	0,9780

Origen	Destino	Sem.	Exact.	Sens.	Esp.	F1m	AUC
120	160	46	0,9040	0,7879	0,9796	0,8957	0,9781
160	80	42	0,6727	0,9769	0,4670	0,6683	0,8888
160	80	43	0,6746	0,9753	0,4713	0,6705	0,8913
160	80	44	0,6769	0,9762	0,4746	0,6729	0,8891
160	80	45	0,6784	0,9754	0,4775	0,6745	0,8929
160	80	46	0,6664	0,9750	0,4578	0,6615	0,8872
160	120	42	0,8301	0,9749	0,7413	0,8287	0,9636
160	120	43	0,8347	0,9731	0,7499	0,8332	0,9640
160	120	44	0,8344	0,9732	0,7494	0,8329	0,9633
160	120	45	0,8382	0,9722	0,7560	0,8365	0,9645
160	120	46	0,8330	0,9735	0,7469	0,8315	0,9641

Estas evaluaciones utilizan colecciones de distintos tamaños del mismo conjunto de datos. No constituyen una validación externa ni garantizan independencia por paciente o imagen de origen.

Además, las imágenes de destino se preprocesan utilizando las estadísticas de normalización de su propia colección. Por tanto, las diferencias observadas no permiten aislar exclusivamente el efecto del tamaño del parche.